CHALEUR ET PERFORMANCE EN COURSE À PIED

Modéliser l'allure à effort égal à partir des résultats de compétition

Rédigé par G.LEPERE

De combien la chaleur ralentit-elle un coureur à effort égal ? Pour répondre à cette question sans aucune mesure physiologique, nous avons rassemblé environ 21 000 performances de compétition, du 800 m au marathon, courues entre 2023 et 2026 dans cent villes de 36 pays. Chaque performance est rapportée au record personnel que l'athlète détenait avant la course, et chaque course est associée à la contrainte thermique qu'elle a subie, mesurée par le WBGT reconstitué heure par heure à partir de réanalyses météorologiques. Trois difficultés structurent l'étude : les listes de résultats sont tronquées par le temps, ce qui atténue l'effet apparent de la chaleur ; la météo n'est pas distribuée au hasard entre épreuves, pays et plateaux ; enfin, les coureurs d'une même course ne sont pas des observations indépendantes, si bien que 10 398 performances ne valent qu'environ 1 900 observations indépendantes. Nous comparons, sur des villes jamais vues à l'apprentissage, des modèles de complexité croissante : régressions pénalisées, modèles à effets mixtes, gradient boosting d'arbres et réseaux de neurones. Leurs précisions sont statistiquement indiscernables ; leurs courbes de dégradation, elles, ne le sont pas. Nous retenons donc un modèle mixte interprétable, dont l'effet de la chaleur dépend du groupe d'épreuves : à WBGT de 25 °C, le ralentissement estimé est nul en demi-fond et atteint 3,1 % au marathon (intervalle à 95 % : 2,3 à 4,1 %) par rapport à un WBGT de 15 °C. Ce modèle, inversé, fournit une conversion d'allure « à effort égal » accompagnée de son incertitude, et refuse d'extrapoler hors du domaine observé.

Mots-clés. Thermorégulation, WBGT, troncature, modèles à effets mixtes, validation croisée groupée, gradient boosting, réseaux de neurones, prédiction conforme.

Sommaire

1 Introduction **4**

2 Cadre physiologique et formulation du problème **5**
2.1 La thermorégulation à l'effort . . . 5
2.2 Mesurer la contrainte thermique : le WBGT . . . 5
2.3 Que prédit-on ? La cible . . . 6
2.4 Deux pièges : la troncature et les facteurs confondants . . . 6
2.5 Du modèle à l'allure : utiliser le modèle dans les deux sens . . . 7

3 Les données et ce qu'elles imposent **7**
3.1 Constitution du jeu de données . . . 8
3.2 Distribution de la cible et conditions couvertes . . . 8
3.3 Une première relation brute, et le paradoxe de Simpson . . . 11
3.4 Les facteurs confondants . . . 11
3.5 La troncature : démonstration et remède . . . 12
3.6 Une structure de dépendance forte . . . 14

4 Un protocole de validation à l'épreuve des fuites **15**
4.1 Fuites d'information et regroupement par lieu . . . 15
4.2 Métriques d'évaluation . . . 16
4.3 Variables dérivées et décomposition de Mundlak . . . 17
4.4 Un prétraitement appris sur l'apprentissage seulement . . . 17
4.5 La validation croisée et sa variabilité . . . 17

5 Premiers modèles : régressions linéaires **18**
5.1 Modèles naïfs . . . 18
5.2 Moindres carrés ordinaires et régression ridge . . . 18
5.3 Une base polynomiale pour le WBGT . . . 19
5.4 Ce que les modèles linéaires nous ont appris . . . 19

6 Tenir compte de la dépendance : modèles à effets mixtes **20**
6.1 Le modèle à intercept aléatoire . . . 20
6.2 Des moindres carrés ordinaires aux moindres carrés généralisés . . . 21
6.3 Le quasi-centrage . . . 21
6.4 Estimer γ : maximum de vraisemblance et REML . . . 22
6.5 Prédire l'effet d'un groupe : le BLUP . . . 23
6.6 Quel groupe, quel estimateur ? . . . 23
6.7 Choisir la complexité : la règle d'un écart-type . . . 25

7 Laisser les données choisir la forme : le gradient boosting d'arbres **25**
7.1 Arbres de régression et boosting . . . 26
7.2 Le critère de coupure au second ordre . . . 26
7.3 LightGBM et contrainte de monotonie . . . 27
7.4 Choisir le nombre d'arbres sans tricher . . . 28
7.5 Le WBGT résume-t-il bien la météo ? Que coûte une validation mal construite ? . . . 29

8 Une troisième famille : les réseaux de neurones **29**
8.1 Qu'est-ce qu'un réseau de neurones ? . . . 29
8.2 Comment un réseau apprend . . . 30
8.3 Le réseau retenu . . . 31
8.4 Le surapprentissage, observé . . . 32

9 Régler, puis comparer sur des villes jamais vues 33
9.1 La recherche aléatoire des hyperparamètres . . . 33
9.2 L'évaluation finale . . . 34

10 Ce que les modèles ont appris de la chaleur 36
10.1 Attribuer une prédiction aux variables : les valeurs de Shapley . . . 36
10.2 Dépendance partielle et courbe de dégradation . . . 37
10.3 Incertitude sur la courbe : le bootstrap des lieux . . . 38
10.4 Le modèle retenu pour l'outil . . . 39

11 L'incertitude de prédiction 41
11.1 Régression quantile et perte pinball . . . 41
11.2 La prédiction conforme . . . 42
11.3 Une garantie qui ne tient pas, et pourquoi . . . 42

12 L'outil : la vitesse à effort égal 43
12.1 Du modèle à la vitesse équivalente . . . 43
12.2 L'inversion : de la vitesse courue à la vitesse de référence . . . 44
12.3 Quelques exemples . . . 44
12.4 Un abaque température–humidité . . . 44

13 Discussion 46
13.1 La troncature, revisitée avec le modèle final . . . 46
13.2 Validité de la cible . . . 46
13.3 Les biais possibles et leur sens . . . 47
13.4 Généralisation et pistes d'amélioration . . . 47

14 Conclusion 47

1 Introduction

L'été 2026 a donné au lien entre météo et performance sportive une actualité particulière. Juin 2026 a été le mois de juin le plus chaud jamais mesuré en France (+3,8 °C au-dessus des normales) ; juillet a ensuite battu le record absolu de chaleur mensuelle depuis le début des mesures, avec une moyenne nationale de 24,9 °C (Météo-France). Ces conditions n'ont pas empêché les sportifs d'élite de s'exprimer, au prix d'aménagements. Le Tour de France a raccourci pour la première fois de son histoire une étape à cause de la chaleur (Malemort–Ussel, le 12 juillet). Au meeting de la Diamond League de Paris, le 28 juin, seules les épreuves professionnelles ont été maintenues, et elles ont produit des chronos de premier plan : 1 min 53 s 80 pour Audrey Werro sur 800 m, troisième performance de l'histoire, et 3 min 28 s 00 pour Cameron Myers sur 1 500 m. Les sportifs amateurs ont en revanche beaucoup souffert : sans encadrement médical ni horaires aménagés, ils ont dû maintenir leurs séances d'entraînement pendant plusieurs semaines de canicule.

Dans le même temps, l'entraînement à la chaleur s'est popularisé. Les championnats du monde d'athlétisme de Tokyo, en septembre 2025, se sont disputés par plus de 30 °C et plus de 80 % d'humidité. Les fédérations y ont préparé leurs athlètes en chambre climatique, en stage sous climat chaud et avec des protocoles de refroidissement, et World Athletics a lancé une étude sur l'acclimatation de ses marathoniens et marcheurs. Elle s'appuie sur les championnats de Doha (2019) : 63 % des athlètes interrogés y avaient suivi une préparation spécifique à la chaleur, et ceux-là avaient en général mieux performé.

Les amateurs n'ont évidemment pas accès aux chambres climatiques ni au suivi physiologique des professionnels. Les bénéfices de l'acclimatation sont pourtant bien établis. Le consensus d'experts de Racinais et al. (2015) en fait l'intervention la plus efficace pour réduire la contrainte physiologique et préserver la performance en ambiance chaude : des expositions répétées à l'effort au chaud pendant une à deux semaines. Lorenzo et al. (2010) ont même observé, chez des cyclistes entraînés, un gain de performance d'environ 7 % après dix jours d'acclimatation, y compris en ambiance fraîche, et Rønnestad et al. (2022) ont montré que cinq semaines d'entraînement en combinaison chauffante augmentent la masse d'hémoglobine de skieurs de fond d'élite d'environ 30 g par rapport à un groupe témoin.

Au-delà de toute préparation volontaire, on ne choisit pas la météo. Un coureur est régulièrement amené à faire une séance planifiée par forte chaleur ou forte humidité, et la même allure n'y correspond plus au même effort. Courir à l'allure prévue revient alors à faire une séance plus dure que prévu, avec un risque pour le plan d'entraînement, voire pour la santé. Les sensations restent le guide le plus sûr : ralentir quand l'effort devient trop coûteux protège mieux que n'importe quelle allure cible. Reste une question plus délicate : *de combien les conditions météorologiques ralentissent-elles réellement un coureur à effort égal ?* Y répondre permettrait d'ajuster son allure à l'avance plutôt qu'au ressenti, d'interpréter honnêtement un chrono réalisé par forte chaleur, ou de comparer deux séances courues dans des conditions différentes.

Plusieurs travaux ont abordé cette question. Ely et al. (2007) ont analysé sept grands marathons : chez les meilleurs hommes, l'écart au record de l'épreuve passe de 1,7 % pour un WBGT de 5 à 10 °C à 4,5 % entre 20 et 25 °C, et les coureurs plus lents sont plus touchés encore. Mantzios et al. (2022) ont élargi l'analyse à 1 258 courses d'endurance (du 3 000 m steeple au marathon, de 1936 à 2019, dans 42 pays). Ils situent les meilleures performances entre 7,5 et 15 °C de WBGT, avec une baisse de 0,3 à 0,4 % par degré au-delà. L'indicateur de référence de ces études est le WBGT (*Wet Bulb Globe Temperature*), qui combine la température de l'air, l'humidité, le vent et le rayonnement solaire en une seule mesure de la contrainte thermique ; l'American College of Sports Medicine et World Athletics l'utilisent pour fixer leurs seuils de risque. Ces études décrivent cependant des performances de vainqueurs, agrégées par course. Elles ne disent pas directement à un coureur à quelle allure courir aujourd'hui pour fournir le même effort que dans des conditions idéales.

C'est l'objet de ce travail. La question que nous nous posons est la suivante :

> *Pour une température T et une humidité relative HR données (et, si on les connaît, le vent, le rayonnement solaire et l'altitude), à quelle vitesse réelle X faut-il courir pour fournir le même effort qu'à la vitesse Y en conditions de référence ?*

L'effort n'étant pas mesuré, la démarche est nécessairement indirecte. Nous apprenons d'abord, sur des performances réelles de compétition, *de combien les conditions ralentissent un athlète par rapport à son propre niveau*, puis nous *inversons* ce modèle pour convertir une vitesse de référence en vitesse à effort égal. Nous avons constitué pour cela un jeu de données d'environ 21 000 performances, du 800 m au marathon, réalisées entre 2023 et 2026 dans 100 villes de 36 pays. Chaque performance est rapportée au record personnel de l'athlète avant la course, et la météo est reconstituée à l'heure et au lieu de la course à partir de réanalyses horaires (ERA5), d'où l'on calcule le WBGT moyen sur la durée de course par le modèle physique de Liljegren et al. (2008).

L'article suit l'ordre dans lequel le travail s'est construit. La section 2 rappelle les bases physiologiques de la thermorégulation, définit le WBGT et formule le problème : choix de la cible, conditions de référence, et deux pièges identifiés d'emblée, la troncature des listes de résultats et les facteurs confondants. L'exploration des données (section 3) précise ces pièges, les mesure, et révèle une forte dépendance entre coureurs d'une même course ; elle dicte le protocole de validation de la section 4. Les sections 5 à 8 construisent des modèles de complexité croissante, des régressions linéaires aux réseaux de neurones, en passant par les modèles mixtes et le gradient boosting ; la section 9 les règle et les compare sur des villes jamais vues. La section 10 interprète ce que ces modèles ont appris et en tire le modèle de l'outil final, dont la section 11 quantifie l'incertitude de prédiction et la section 12 décrit l'usage. La section 13 discute les limites de l'ensemble.

2 Cadre physiologique et formulation du problème

2.1 La thermorégulation à l'effort

Le bilan thermique d'un coureur s'écrit, en watts,

$$S = M - W_{\text{méca}} \pm R \pm C - E,$$

où S est la chaleur *stockée* par le corps, M la production *métabolique* d'énergie par les muscles et $W_{\text{méca}}$ le *travail mécanique* fourni. Le rendement musculaire n'étant que de 20 à 25 %, les trois quarts environ de M finissent en chaleur. R et C sont les échanges par *rayonnement* (soleil, sol, environnement) et par *convection* (contact avec l'air en mouvement) ; ils peuvent refroidir le coureur comme le réchauffer, d'où le signe ±. E est la perte par *évaporation* de la sueur. Si $S > 0$ durablement, la température centrale monte.

Les ordres de grandeur sont considérables. Le coût énergétique de la course est d'environ $4\ \text{J kg}^{-1}\ \text{m}^{-1}$: à 5,5 m/s, le rythme d'un marathon en 2 h 08, un athlète de 60 kg dépense $4 \times 60 \times 5{,}5 \approx 1\,300$ W. Avec un rendement de 20 à 25 %, plus de 1 000 W de chaleur doivent être évacués en permanence, l'équivalent d'un radiateur électrique. Quand la température de l'air se rapproche de celle de la peau (33 à 35 °C), les échanges C et R deviennent faibles, voire négatifs, et il ne reste que l'évaporation. Celle-ci dépend de l'écart de pression de vapeur d'eau entre la peau et l'air : elle est freinée par l'humidité, et un air chaud et saturé constitue le cas le plus défavorable. Le rayonnement solaire ajoute une charge de plusieurs centaines de W/m^2, tandis que le vent augmente au contraire les échanges convectifs et évaporatifs.

Si la chaleur n'est pas évacuée, la température centrale monte. Le débit sanguin cutané, nécessaire pour transporter la chaleur vers la peau, entre alors en concurrence avec le débit musculaire : le cœur ne peut pas irriguer les deux au maximum. La consommation maximale d'oxygène effective $\dot{V}\text{O}_2$ max baisse et l'athlète ralentit, souvent par anticipation : il règle son allure pour ne pas atteindre une température critique, avant même d'y être. L'effet croît avec la durée de l'effort, puisque la chaleur stockée S s'accumule au fil du temps. Il est faible sur 800 m (environ deux minutes), où la température centrale n'a pas le temps de monter et où un air chaud, moins dense, peut même aider en réduisant la résistance aérodynamique ; il devient important au marathon, qui dure deux à trois heures. Sur des championnats internationaux, Mantzios et al. (2022) trouvent un optimum de WBGT entre 7,5 et 15 °C et une dégradation de 0,3 à 0,4 % par degré au-delà ; Ely et al. (2007) observent au marathon un ralentissement progressif de 5 à 25 °C de WBGT, plus marqué chez les coureurs lents.

L'altitude agit par un autre mécanisme. La pression atmosphérique, et avec elle la pression partielle d'oxygène, diminue d'environ 11 % par 1 000 m. Le sang transporte moins d'oxygène, et $\dot{V}\text{O}_2$ max baisse d'environ 6 à 8 % par 1 000 m au-dessus de 500 à 1 000 m. Les épreuves d'endurance, limitées par l'apport en oxygène, en pâtissent, alors que les épreuves courtes profitent de la moindre densité de l'air. Nos données contiennent des courses à Mexico (environ 2 200 m), Bogotá (2 600 m), Kigali, Boulder, Guadalajara ou Lanzhou (environ 1 500 m).

2.2 Mesurer la contrainte thermique : le WBGT

Le WBGT combine en un seul indice, exprimé en degrés Celsius, les quatre facteurs du bilan thermique que sont la température, l'humidité, le vent et le rayonnement :

$$\text{WBGT} = 0{,}7\,T_{nwb} + 0{,}2\,T_g + 0{,}1\,T_a. \tag{1}$$

T_{nwb} est la température d'un thermomètre à bulbe *humide naturel* : entouré d'une mèche mouillée, non ventilé artificiellement et exposé au soleil, il est refroidi par l'évaporation de l'eau, d'autant plus que l'air est sec et venté. Il mesure donc la

capacité de l'environnement à évacuer la chaleur par évaporation, comme le fait la sueur ; par air saturé, l'évaporation cesse et T_{nwb} rejoint T_a. T_g est la température d'un *globe noir* creux, qui absorbe le rayonnement du soleil et du sol et se refroidit au vent : il mesure la charge radiative. T_a est enfin la température de l'air à l'ombre. Les poids traduisent le rôle dominant de l'évaporation dans la thermorégulation à l'effort : avec 70 % du poids sur T_{nwb}, l'humidité augmente fortement le WBGT à température égale, et le WBGT n'est pas une simple température.

L'American College of Sports Medicine (Armstrong et al., 2007) associe au WBGT des drapeaux de risque pour les courses : blanc sous 10 °C (risque d'hypothermie), vert de 10 à 18 °C, jaune de 18 à 23 °C, rouge de 23 à 28 °C et noir au-delà de 28 °C, seuil qui recommande l'annulation de l'épreuve.

Les trois températures de (1) ne sont pas mesurées sur les parcours. Nous les avons *calculées* avec le modèle physique de Liljegren et al. (2008), la méthode de référence pour estimer le WBGT à partir de mesures météorologiques standard. Ce modèle écrit le bilan d'énergie de la mèche mouillée et celui du globe (rayonnement solaire direct et diffus, rayonnement thermique, convection, évaporation) et les résout numériquement à partir de la température, de l'humidité, de la vitesse du vent, du rayonnement solaire global, de la pression et de la position du soleil, elle-même déduite de la date, de l'heure et des coordonnées du lieu. Notre implémentation reproduit le code de référence d'Argonne à moins de 0,01 °C près. Le WBGT a été calculé *toutes les cinq minutes, du départ jusqu'à l'arrivée de chaque athlète*, puis moyenné : un marathonien en 2 h 50 subit ainsi la montée de la température en fin de matinée, contrairement à un vainqueur en 2 h 05. Nous verrons que cette dérive atteint en médiane 3,7 °C au marathon.

2.3 Que prédit-on ? La cible

Notre approche est purement fondée sur les données : aucune mesure physiologique (fréquence cardiaque, lactatémie, perception de l'effort) n'est disponible. Nous approchons donc l'effort par la *performance en compétition*, en supposant qu'un athlète en course fournit un effort maximal : s'il court plus lentement que d'habitude par forte chaleur, c'est que la chaleur lui coûte de la vitesse à effort égal. Cette hypothèse a ses limites, certains athlètes choisissant de « gérer » leur course par forte chaleur ; nous y reviendrons en section 13. Pour neutraliser le niveau, le sexe et l'épreuve de chaque athlète, il faut comparer chaque performance à une *référence propre à l'athlète*. Pour la performance i, de temps t_i, d'un athlète dont le record personnel *avant la course* vaut t_i^{RP}, la cible est

$$y_i = 100 \, \ln \frac{t_i}{t_i^{\mathrm{RP}}}. \tag{2}$$

Le logarithme a quatre vertus. La première est une lecture en pourcentage : pour x petit, $\ln(1+x) \approx x$, donc si $t = 1{,}02\, t^{\mathrm{RP}}$, alors $y = 100 \ln 1{,}02 \approx 1{,}98$; y s'exprime en « pourcents logarithmiques », et $y = 2$ signifie environ 2 % plus lent que son record. La deuxième est la symétrie : $\ln(t/t^\star) = -\ln(t^\star/t)$, si bien que courir 2 points au-dessus ou au-dessous de son record se traite de la même façon, ce qui n'est pas le cas du rapport $t/t^\star - 1$. La troisième est l'équivalence entre temps et vitesse : sur une distance d fixée, $v = d/t$, donc $\ln(t/t^\star) = \ln(v^\star/v)$, et y est aussi un écart relatif de vitesse, ce qui permettra de convertir directement le résultat en allure. La dernière est l'additivité : des effets multiplicatifs sur le temps deviennent additifs sur y. Si la chaleur multiplie le temps par $e^{\delta_1/100}$ et l'altitude par $e^{\delta_2/100}$, y augmente de $\delta_1 + \delta_2$; c'est la forme qui convient aux modèles linéaires. Une valeur $y < 0$ correspond à un nouveau record personnel.

Le choix du record d'avant course comme référence n'est pas anodin. Ce record est publié avant la course et a été établi ailleurs, dans d'autres conditions : il mesure le niveau de l'athlète indépendamment de la météo du jour. Une référence qui contiendrait la course elle-même créerait un artefact. Avec la meilleure performance de la saison, course comprise, une course disputée dans d'excellentes conditions deviendrait sa propre référence, et l'on aurait $y \geq 0$ par construction. Le record d'avant course est en outre renseigné pour 71 % des performances, contre 36 % pour la meilleure performance de la saison d'avant course, que nous utiliserons seulement comme indicateur de *forme*.

2.4 Deux pièges : la troncature et les facteurs confondants

Dès la constitution des données, deux difficultés sont apparues, qui menacent toute estimation naïve de l'effet de la chaleur.

La troncature des listes de résultats. Les listes de résultats sont tronquées par le temps. Les grands marathons ne publient que les hommes sous 2 h 37 et les femmes sous 3 h 05, et les petites courses seulement leurs premiers. Notons $T_c^{\max}$

le temps du dernier coureur listé dans la course c. Un athlète n'apparaît dans les données que si $t_i \le T_c^{\max}$, c'est-à-dire si

$$y_i \le m_i = 100 \ln \frac{T_c^{\max}}{t_i^{\mathrm{RP}}},$$

où m_i est la *marge de troncature* de la performance i : le ralentissement maximal qui reste observable. Par forte chaleur, un athlète au record proche du seuil qui ralentit disparaît des données ; on ne voit que ceux qui ont bien couru par rapport à leur niveau. La moyenne observée de y est alors tirée vers le bas, et l'effet de la chaleur est sous-estimé. La section 3.5 en donne une démonstration formelle, une mesure empirique et le remède que nous avons retenu.

Les facteurs confondants. Un facteur confondant est une variable Z qui influence à la fois l'exposition étudiée, ici le WBGT noté W, et la performance y. Si on l'omet, son effet est attribué à tort au WBGT. Supposons que le vrai modèle soit $y = \beta_0 + \beta_W W + \beta_Z Z + \varepsilon$, avec ε non corrélé à W et à Z, et que l'on régresse y sur W seul. La pente estimée tend vers

$$\frac{\mathrm{Cov}(W, y)}{\mathrm{Var}(W)} = \frac{\beta_W \,\mathrm{Var}(W) + \beta_Z \,\mathrm{Cov}(W, Z)}{\mathrm{Var}(W)} = \beta_W + \beta_Z \,\frac{\mathrm{Cov}(W, Z)}{\mathrm{Var}(W)}. \tag{3}$$

C'est le *biais de variable omise*. Son signe est celui du produit $\beta_Z \,\mathrm{Cov}(W, Z)$: pour prévoir dans quel sens un facteur biaise l'effet de la chaleur, il faut connaître à la fois son effet sur y et son lien avec le WBGT. Nous avons d'emblée exclu les courses de championnat, trop sujettes aux tactiques de course. Parmi les facteurs confondants inévitables, nous prêtons une attention particulière au profil de l'athlète (niveau, âge, sexe), à l'épreuve, au parcours et à l'horaire de la course.

2.5 Du modèle à l'allure : utiliser le modèle dans les deux sens

Supposons disposer d'un modèle f qui prédit y à partir des conditions $\mathscr{C}$ et des caractéristiques x de l'athlète et de la course. La dégradation due aux conditions $\mathscr{C}$, par rapport à des conditions de référence $\mathscr{C}_{\mathrm{ref}}$, est

$$\Delta(\mathscr{C}) = f(\mathscr{C}, x) - f(\mathscr{C}_{\mathrm{ref}}, x), \tag{4}$$

exprimée en points de y. Considérons un athlète qui court à la vitesse Y (temps t_Y) en conditions de référence et à la vitesse X (temps t_X) dans les conditions $\mathscr{C}$, pour le même effort. La différence de cible entre les deux situations vaut

$$\Delta = 100 \ln \frac{t_X}{t^{\mathrm{RP}}} - 100 \ln \frac{t_Y}{t^{\mathrm{RP}}} = 100 \ln \frac{t_X}{t_Y} = 100 \ln \frac{Y}{X},$$

et le record personnel disparaît. La vitesse à effort égal est donc

$$X = Y \exp\!\left(-\frac{\Delta(\mathscr{C})}{100}\right), \qquad \text{soit } X \approx Y\left(1 - \frac{\Delta}{100}\right) \text{ au premier ordre.} \tag{5}$$

La dégradation Δ dépend du niveau et de la durée de course de l'athlète, donc de Y lui-même. L'opération inverse, « j'ai couru à la vitesse X par 30 °C, combien cela vaut-il en conditions de référence ? », demande donc de résoudre numériquement l'équation $Y\, e^{-\Delta(\mathscr{C};\,Y)/100} = X$ (section 12).

Reste à fixer les conditions de référence. Nous retenons un WBGT de référence $W_{\mathrm{ref}} = 15$ °C, haut de la plage « neutre » de 10 à 15 °C de la littérature. Une référence plus fraîche sortirait du domaine des données de piste, qui ne descendent jamais sous 13,5 °C : on ne pourrait pas y évaluer le modèle sans extrapoler. Le vent de référence est une brise légère (2 m/s à 10 m de hauteur), l'altitude de référence est inférieure à 500 m, et la référence est sans pluie.

3 Les données et ce qu'elles imposent

L'analyse exploratoire n'a pas été une fin en soi. Elle a servi à repérer ce qui conditionnerait la modélisation : les plages de conditions couvertes et les combinaisons absentes, les facteurs confondants, et la structure de dépendance entre observations. C'est elle qui a transformé les deux pièges pressentis plus haut en difficultés mesurées, et qui en a fait apparaître une troisième.

3.1 Constitution du jeu de données

Le jeu de données a été construit en cinq étapes. Nous avons d'abord rassemblé les résultats de compétitions internationales sur piste et sur route, de 2023 à 2026, à raison d'une ligne par performance : sexe, année de naissance, épreuve, meeting, ville, date, heure locale, temps, ainsi que la meilleure performance de la saison et le record personnel publiés avant la course. Les villes ont ensuite été géocodées (coordonnées, fuseau horaire, altitude). La météo horaire a été extraite, par le service Open-Meteo (Zippenfenig, 2023), des réanalyses ERA5 (Hersbach et al., 2020) et ERA5-Land et du modèle IFS, puis interpolée au pas de cinq minutes. Une *réanalyse* reconstitue la météo passée sur une grille régulière, de 9 à 30 km de côté environ, en assimilant les observations disponibles dans un modèle numérique de prévision : c'est une estimation de la météo locale, et non une mesure sur le parcours. Le WBGT de Liljegren a alors été calculé toutes les cinq minutes et moyenné sur la course de chaque athlète (section 2.2). Restaient enfin à calculer la cible et les variables de contexte, puis à appliquer les exclusions.

Les quinze épreuves présentes ont été regroupées en cinq *groupes d'épreuves*, selon le support (piste ou route) et la durée de l'effort, qui conditionne l'effet attendu de la chaleur (tableau 1). La structure des données est décrite par quatre niveaux de regroupement emboîtés. Une *course* est définie par le meeting, la ville, la date, l'épreuve et le sexe ; un *meeting* est une réunion (meeting, ville et date) qui compte plusieurs courses ; un *parcours* réunit une ville et une épreuve, toutes éditions confondues ; un *lieu* est une ville. Une course appartient ainsi à un meeting et à un parcours, qui appartiennent eux-mêmes à un lieu.

Six variables de contexte décrivent chaque performance. L'âge est l'année de la saison moins l'année de naissance. Le *niveau* vaut $100 \ln(t^{\mathrm{RP}}/t^{\mathrm{RP}}_{\mathrm{méd}})$, où $t^{\mathrm{RP}}_{\mathrm{méd}}$ est le record médian du sexe et de l'épreuve : il est négatif pour un athlète plus rapide que la médiane. La *forme* vaut $100 \ln(\mathrm{MPS}/t^{\mathrm{RP}}) \geq 0$, où MPS est la meilleure performance de la saison d'avant course ; elle est manquante en l'absence de MPS. La durée de course attendue vaut $t^{\mathrm{RP}}/60$, en minutes. L'heure locale de départ est, sur piste, celle du début de la réunion. Enfin, la marge de troncature m_i a été définie en section 2.4.

Sur les 21 126 lignes collectées, 6 222 n'ont pas de record d'avant course, donc pas de référence, et 81 ont une cible aberrante, hors de l'intervalle $[-15\,;\,30]$: elles sont exclues. Il reste 14 823 performances valides, toutes associées à une météo. L'*échantillon d'analyse* ne garde que celles dont la marge de troncature vaut au moins 5 %, pour des raisons exposées en section 3.5. Il compte 10 398 performances, réparties en 396 courses, 135 meetings, 172 parcours et 100 lieux dans 36 pays.

Tableau 1 : Composition de l'échantillon d'analyse par groupe d'épreuves. $\bar{y}$ est la moyenne de la cible (2), en points de pourcentage.

Groupe	Épreuves	Durée typique	Perf.	Courses	Lieux	$\bar{y}$	Femmes / hommes
demi-fond piste	800 m, 1 000 m, 1 500 m, mile	2 à 4 min	2 498	95	21	1,19	981 / 1 517
fond piste	2 000 m et 3 000 m steeple, 3 000 m, 5 000 m, 10 000 m	5 à 35 min	1 019	64	14	0,90	315 / 704
route courte	mile, 5 km et 10 km sur route	4 à 35 min	1 890	87	30	1,44	438 / 1 452
semi-marathon	semi-marathon	1 h à 1 h 30	1 134	56	28	1,58	392 / 742
marathon	marathon	2 à 3 h	3 857	94	41	2,18	1 575 / 2 282

Le marathon est le groupe le plus représenté (37 % des performances), le fond sur piste le moins (10 %). Les hommes représentent 64 % des performances, avec un déséquilibre marqué sur route courte, où l'on compte trois hommes pour une femme. Le $\bar{y}$ est positif dans tous les groupes et croît du fond sur piste (0,90 %) au marathon (2,18 %). Les épreuves sur piste se concentrent dans peu de lieux (21 et 14) : leurs conditions météorologiques reposent sur peu de situations distinctes.

3.2 Distribution de la cible et conditions couvertes

Pour décrire la forme d'une distribution au-delà de sa moyenne $\bar{y}$ et de son écart-type s, nous utilisons deux indicateurs. Le *coefficient d'asymétrie* $\mathrm{asym}(y) = \frac{1}{n}\sum_i \left(\frac{y_i-\bar{y}}{s}\right)^3$ est nul pour une distribution symétrique et positif quand la queue de droite est plus longue que celle de gauche. Le *kurtosis en excès* $\mathrm{kurt}(y) = \frac{1}{n}\sum_i \left(\frac{y_i-\bar{y}}{s}\right)^4 - 3$ est nul pour une loi normale et positif quand les valeurs extrêmes sont plus fréquentes que sous une loi normale, autrement dit quand les queues sont épaisses.

La forme de la cible. Sur les 10 398 performances, 32 % sont plus rapides que le record d'avant course (figure 1). La médiane vaut 1,1 %, la moyenne 1,6 %, et les centiles 5 et 95 sont à −2,8 % et +7,5 %. La distribution est asymétrique à droite (coefficient d'asymétrie 0,87) et à queues épaisses (kurtosis en excès 2,5) : 13,5 % des performances sont à plus de 5 %

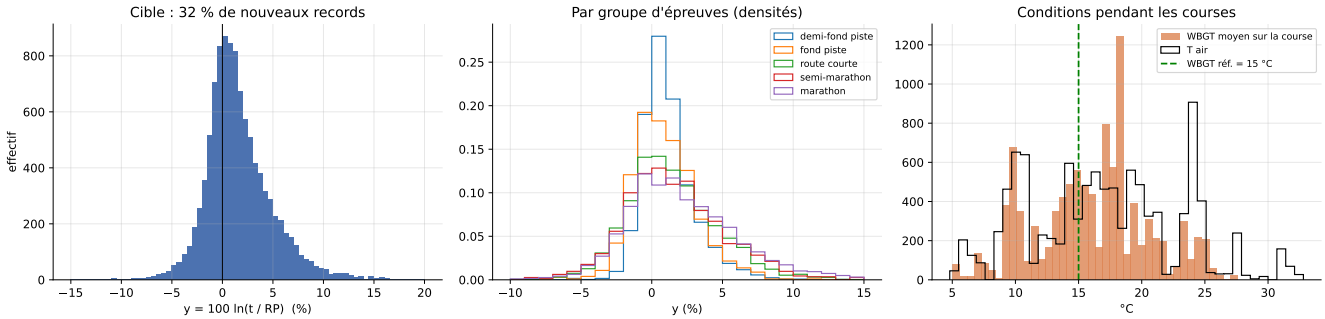


Figure 1 : À gauche, distribution de la cible y sur les 10 398 performances de l'échantillon d'analyse ; au centre, densités de y par groupe d'épreuves ; à droite, distributions du WBGT moyen sur la course et de la température de l'air, avec le WBGT de référence de 15 °C.

au-dessus du record, contre 1,2 % à plus de 5 % en dessous. On peut courir bien plus lentement que son record, un jour sans, lors d'une course tactique ou d'une blessure, ou simplement parce que le record date ; on court rarement beaucoup plus vite.

Que y soit positif en moyenne est attendu et ne doit rien à la météo. Le record est le *minimum* des performances passées : une course quelconque est donc en moyenne plus lente que ce minimum, et l'écart est d'autant plus grand que les performances d'un athlète sont dispersées. C'est ce qu'on observe : la moyenne croît avec la dispersion, de 0,9 à 1,2 % sur piste à 2,2 % au marathon. Les 32 % de records viennent surtout d'athlètes en progression, jeunes ou dont le record est ancien ou établi sur peu de courses.

La dispersion croît avec la distance : l'écart-type de y vaut 1,9 point en demi-fond, 2,2 en fond sur piste, 3,3 à 3,6 sur route et 4,0 au marathon, soit une variance quatre fois plus grande au marathon qu'en demi-fond. Les données sont donc fortement *hétéroscédastiques*. Le demi-fond est aussi le groupe le plus concentré autour de 0 et le plus asymétrique (1,52) : les coureurs de 800 à 1 500 m courent souvent, leur record est récent et proche de leur niveau du moment, et seuls les mauvais jours les en éloignent. À l'inverse, 21 % des marathoniens finissent à plus de 5 % de leur record. Nous en avons tiré deux conséquences : une perte quadratique sera dominée par les erreurs sur route et au marathon, si bien que les métriques devront être lues par groupe d'épreuves et pas seulement globalement ; et les queues épaisses rendent l'erreur quadratique sensible à quelques contre-performances extrêmes, ce qui fait de l'erreur absolue un complément utile. L'écart entre sexes est faible (moyenne 1,7 % chez les femmes et 1,6 % chez les hommes, écarts-types 3,5 et 3,2) et s'explique en partie par la répartition entre épreuves.

Les conditions couvertes. Le WBGT moyen sur la course va de 5 à 27,6 °C, avec une médiane de 16,4 °C. Selon les seuils de l'ACSM, 12 % des performances ont lieu sous 10 °C, 53 % entre 10 et 18 °C, 26 % entre 18 et 23 °C, 9 % entre 23 et 28 °C, et aucune au-delà de 28 °C. Les plages diffèrent beaucoup selon le groupe. Le demi-fond et le fond sur piste, courus lors de réunions d'été en soirée, vers 20 h, ne descendent jamais sous 13,5 °C, avec une médiane de 18,3 °C en demi-fond. Le semi-marathon et le marathon, courus entre 8 h 30 et 10 h et en saison intermédiaire, vont de 5 à 22 °C et de 6 à 26 °C, avec des médianes de 10,3 et 14,2 °C.

La météo est une variable de course. Le WBGT varie très peu entre les coureurs d'une même course : l'écart entre le premier et le dernier listé ne dépasse jamais 1,2 °C, avec une médiane de 0,24 °C au marathon. C'est encore un effet de la troncature : les listes ne gardent que des coureurs rapides, arrivés à quelques minutes d'écart. L'information disponible sur l'effet de la météo repose donc sur 396 courses, et non sur 10 398 lignes. Ces courses ont de plus des tailles très inégales : 14 performances en médiane, 293 au maximum (10 km de Lille), et les 20 plus grosses courses représentent 32 % des lignes. Or ces grosses courses (marathons de Valencia, Tokyo ou Berlin, semi de Boulogne) se courent au frais, et les courses chaudes sont plus petites : 19 % des courses ont un WBGT supérieur à 23 °C, contre 9 % des performances. Une régression ordinaire, qui pondère chaque ligne de la même façon, donnerait donc beaucoup de poids à quelques marathons frais et peu aux courses chaudes. Cette observation sera au cœur du protocole de validation (section 4) et des modèles mixtes (section 6).

La composition du WBGT. Le WBGT n'a pas la même composition selon le groupe d'épreuves. Sur piste, les réunions du soir combinent un air chaud (température médiane de 23,8 °C en demi-fond), sec (humidité relative de 52 %) et un soleil bas (190 W/m^2). Les marathons du matin combinent un air plus frais (13,2 °C), plus humide (64 %) et un fort rayonnement

(430 W/m²). Deux exemples extrêmes atteignent le même WBGT par des chemins opposés : le meeting de Dessau 2026 (31,5 °C, humidité de 38 %, 200 W/m², WBGT de 26,0 °C) et le marathon de Guiyang 2026 (21,2 °C seulement, mais 73 % d'humidité et 540 W/m², WBGT de 25,8 °C). Un modèle qui ne verrait que la température de l'air classerait mal ces deux courses. À l'inverse, il n'est pas acquis qu'un même WBGT ait le même effet physiologique quelle que soit sa composition ; la section 7.5 confronte le WBGT aux variables météorologiques brutes.

La *dérive pendant la course* est importante sur les longues distances : du départ au maximum, le WBGT monte en médiane de 2,4 °C sur semi-marathon et de 3,7 °C au marathon, alors qu'elle est nulle sur piste. Le WBGT au départ, seule valeur souvent publiée, sous-estime donc la contrainte subie, ce qui justifie a posteriori l'usage du WBGT moyen sur la durée de course.

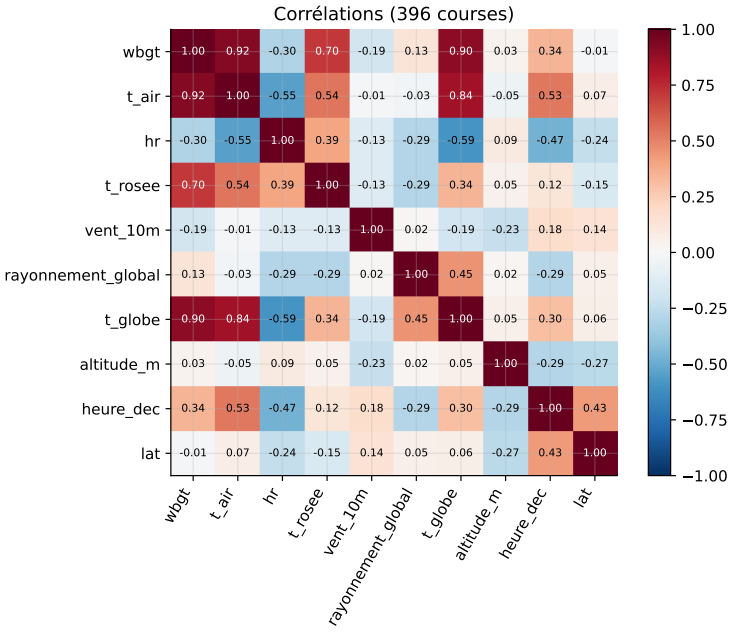


Figure 2 : Corrélations de Pearson entre variables météorologiques et de contexte, calculées sur une ligne par course (396 courses).

Les corrélations entre variables météorologiques. Les conditions étant communes à tous les coureurs d'une course, nous calculons leurs corrélations sur une ligne par course : sans cela, une course de 293 coureurs compterait 293 fois. Le coefficient de corrélation de Pearson entre deux variables u et v,

$$r = \frac{\sum_c (u_c - \bar{u})(v_c - \bar{v})}{\sqrt{\sum_c (u_c - \bar{u})^2}\sqrt{\sum_c (v_c - \bar{v})^2}} \in [-1\,;\,1],$$

mesure la force d'une relation linéaire ; $r = 0$ n'exclut pas une relation non linéaire. Le WBGT est très corrélé à la température de l'air (0,92) et à celle du globe (0,90), plus modérément au point de rosée (0,70), et peu au rayonnement global pris seul (0,13), car les courses les plus chaudes sont les réunions du soir, sans soleil (figure 2). L'humidité relative est anticorrélée à la température (−0,55) : c'est le cycle diurne, au cours duquel l'humidité relative baisse quand l'air se réchauffe. Les combinaisons « chaud et humide » sont donc rares, et il sera difficile de séparer les effets de la température et de l'humidité à partir des seules données. C'est l'un des intérêts du WBGT : il combine ces grandeurs par un modèle physique, au lieu de demander au modèle statistique d'apprendre cette combinaison. L'heure de départ est liée à la température (0,53) et à la latitude (0,43) : elle encode surtout le type de réunion (piste le soir en Europe du Nord, route le matin) et sera un facteur confondant à contrôler avec le groupe d'épreuves. L'altitude n'est presque pas corrélée au WBGT (0,03), ce qui permet en principe d'estimer son effet séparément ; la pression, quasi déterminée par l'altitude, n'apporte rien de plus. Les villes extrêmes illustrent d'ailleurs la saison plus que le climat : Houston (marathon et semi de janvier, 5,9 °C), Buenos Aires (semi d'août, en hiver austral, 6,9 °C) ou Cape Elizabeth (10 km d'août, 26,5 °C). Avec une ou deux courses par ville, ces moyennes ne caractérisent pas le climat local.

Les combinaisons mal représentées. Plusieurs situations sont rares ou absentes : la piste au frais (moins de 16 °C), le semi-marathon au chaud (aucune course au-delà de 22 °C), le marathon très chaud (8 courses seulement au-dessus de

23 °C, soit 102 performances) et toute condition extrême (WBGT supérieur à 28 °C). Le croisement entre épreuve et chaleur est défavorable : la moitié des courses au-dessus de 23 °C sont des courses de demi-fond, là où l'effet attendu de la chaleur est le plus faible. Pour les longues distances, où l'effet est le plus fort, l'information sur la chaleur est rare, et l'effet au marathon par forte chaleur reposera sur peu de courses. Les autres facteurs sont peu variés. La pluie ne concerne que 37 courses (plus de 0,1 mm/h), et le vent à 10 m ne dépasse pas 6,3 m/s. L'altitude n'est observée que sur route, dans 18 courses (168 performances, 1,6 % des données) et 8 lieux au-dessus de 1 000 m, dont certains sont aussi chauds (Guiyang, Kigali, Lanzhou) : son effet sera difficile à séparer de celui de la chaleur et du plateau.

Trois conséquences pour la modélisation se dégagent de cette description. Le groupe d'épreuves, ou la durée de course, doit entrer dans le modèle en interaction avec le WBGT, puisque les plages de WBGT, le niveau moyen de y et sa dispersion diffèrent tous selon le groupe. La météo étant une variable de course, l'unité d'information est la course, ce qui impose une validation groupée et une structure d'effets de course ou de parcours. Enfin, le domaine de validité d'un outil fondé sur ces données est un WBGT de 5 à 27 °C, sans altitude marquée ni pluie forte ; au-delà, il faudra signaler l'extrapolation à l'utilisateur.

3.3 Une première relation brute, et le paradoxe de Simpson

La première idée, pour avoir une idée de l'effet du WBGT, est de tracer la moyenne de y par classe de WBGT. Nous découpons le WBGT en classes de 3 °C. Dans la classe b, qui compte n_b performances, nous calculons la moyenne $\bar{y}_b$ et son *erreur type*

$$\mathrm{se}(\bar{y}_b) = \frac{s_b}{\sqrt{n_b}}, \qquad s_b^2 = \frac{1}{n_b - 1} \sum_{i \in b} (y_i - \bar{y}_b)^2.$$

L'erreur type est l'écart-type de l'*estimateur* $\bar{y}_b$, c'est-à-dire sa variabilité d'un échantillon à l'autre ; il ne faut pas la confondre avec l'écart-type s_b des observations. Le diviseur $n_b - 1$ rend s_b^2 sans biais, la moyenne ayant été estimée sur les mêmes données. D'après le théorème central limite, $\bar{y}_b$ suit approximativement une loi normale, d'où l'intervalle de confiance à 95 % $\bar{y}_b \pm 1{,}96\,\mathrm{se}(\bar{y}_b)$, où 1,96 est le quantile d'ordre 0,975 de la loi normale centrée réduite. Ces barres d'erreur reposent sur une hypothèse cachée : la formule $\mathrm{Var}(\bar{y}_b) = \sigma^2 / n_b$ suppose des observations indépendantes. Les coureurs d'une même course partageant la météo et le déroulement de la course, ces barres sont trop étroites ; nous le mesurerons en section 3.6.

Une seconde difficulté tient à la composition des classes. La moyenne de toutes les épreuves dans la classe b est une moyenne pondérée des moyennes de chaque groupe d'épreuves e :

$$\bar{y}_b = \sum_e \pi_{e|b}\, \bar{y}_{e,b},$$

où $\pi_{e|b}$ est la part du groupe e dans la classe b. Si cette composition change d'une classe à l'autre, par exemple beaucoup de demi-fond dans les classes chaudes et beaucoup de marathons dans les classes fraîches, la courbe globale peut monter, descendre ou s'aplatir alors même que chaque groupe présente une relation nette. Une tendance agrégée peut ainsi différer, voire s'inverser, par rapport aux tendances de chaque sous-groupe : c'est le *paradoxe de Simpson*. D'où l'intérêt de lire les courbes par groupe d'épreuves.

La figure 3 illustre exactement ce phénomène. Toutes épreuves confondues, $\bar{y}$ monte de 0,6 % (WBGT de 5 à 8 °C) à 1,0 % (8 à 11 °C), reste vers 1,5 % entre 11 et 20 °C, puis passe à 3,2 % entre 20 et 23 °C. Il *retombe* ensuite à 2,1 % entre 23 et 26 °C, une classe composée à 69 % de demi-fond sur piste, avant d'atteindre 5,6 % au-delà de 26 °C, sur 25 performances seulement. Par groupe, le contraste est net. Au marathon, $\bar{y}$ vaut environ 1 % jusqu'à 11 °C, 1,9 à 2,3 % entre 11 et 20 °C, puis 4,6 % entre 20 et 23 °C et 6,2 % entre 23 et 26 °C : le ralentissement est fort et convexe, cohérent avec Ely et al. (2007). Le demi-fond et le fond sur piste sont presque plats (0,8 à 1,5 %) sur toute leur plage, de 12 à 26 °C. La route courte et le semi-marathon présentent des profils irréguliers, comme le pic du semi-marathon entre 14 et 17 °C (4,2 %) ; mais chaque classe n'y réunit qu'une poignée de courses (2 à 20), et ces moyennes mélangent l'effet de la chaleur et celui du lieu. La moyenne globale est donc trompeuse : sa forme dépend surtout du groupe d'épreuves qui domine chaque classe.

3.4 Les facteurs confondants

Le WBGT n'est pas distribué au hasard. Les courses chaudes ont lieu dans certains pays (Asie du Sud-Est, Afrique de l'Ouest, Golfe) et à certaines saisons, avec des plateaux différents en niveau, en âge et en proportion d'athlètes établissant un record ; l'altitude se concentre dans quelques villes. D'après (3), un facteur confondant n'est dangereux que s'il est lié

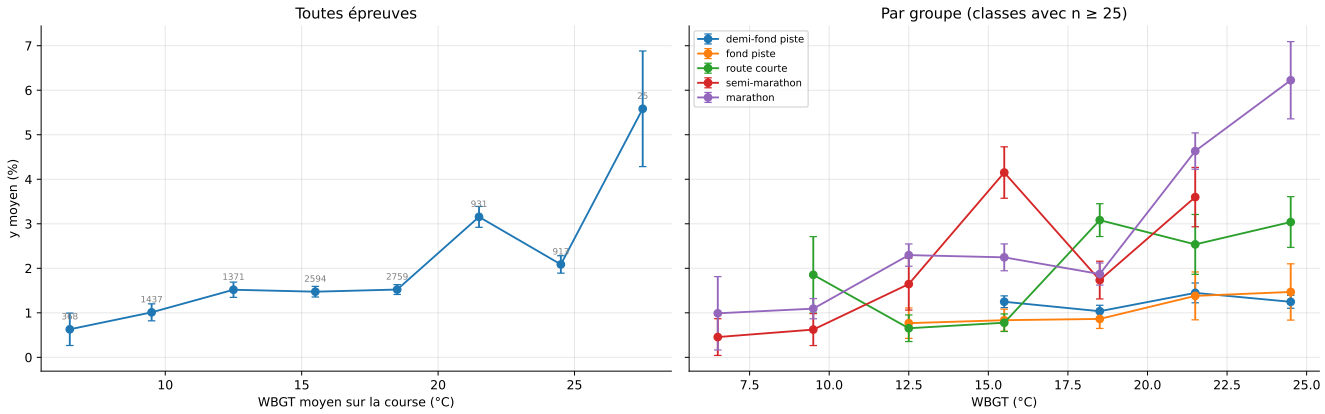


Figure 3 : Moyenne de y par classe de WBGT de 3 °C, avec intervalles de confiance à 95 % calculés sous hypothèse d'indépendance. À gauche, toutes épreuves confondues (effectifs indiqués au-dessus des points) ; à droite, par groupe d'épreuves, pour les classes d'au moins 25 performances.

au WBGT. Nous avons donc mesuré, au niveau des courses, la corrélation entre le WBGT et chaque variable de contexte. Chaque course c reçoit un poids $w_c = n_c / \sum_{c'} n_{c'}$ proportionnel à son nombre de coureurs, pour refléter son poids dans les données individuelles, et la corrélation pondérée s'écrit

$$r_w = \frac{\sum_c w_c\,(u_c - \bar{u}_w)(v_c - \bar{v}_w)}{\sqrt{\sum_c w_c\,(u_c - \bar{u}_w)^2}\,\sqrt{\sum_c w_c\,(v_c - \bar{v}_w)^2}}, \qquad \bar{u}_w = \sum_c w_c\,u_c.$$

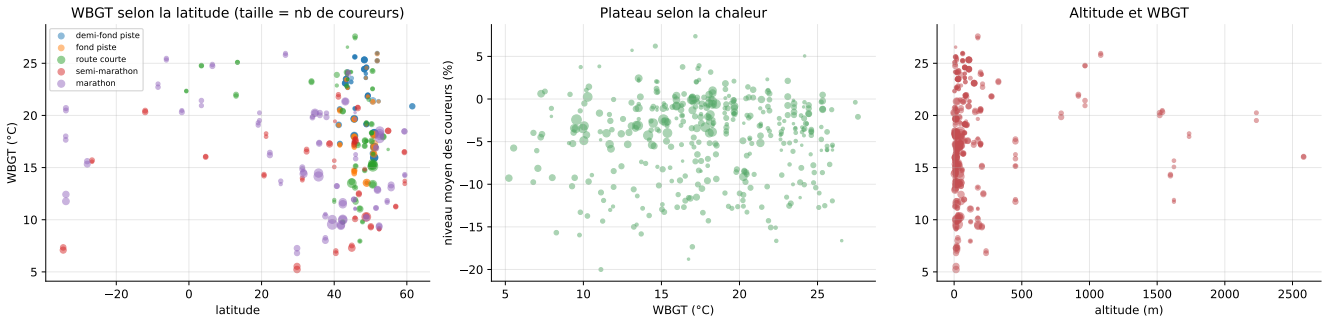


Figure 4 : Trois facteurs confondants potentiels, au niveau des courses (taille des points proportionnelle au nombre de coureurs). À gauche, WBGT selon la latitude et le groupe d'épreuves ; au centre, niveau moyen des coureurs selon le WBGT ; à droite, WBGT selon l'altitude.

Au niveau des courses, le WBGT est corrélé à l'âge moyen des coureurs (−0,43), à l'heure de départ (+0,42), à la forme (−0,15) et à l'altitude (+0,13), mais presque pas au niveau (+0,05, figure 4). La formule (3) permet alors d'anticiper le sens des biais d'une régression simple de y sur le WBGT. La composition des épreuves est le premier d'entre eux : les courses chaudes sont surtout des réunions de piste (38 des 75 courses au-dessus de 23 °C sont du demi-fond), où la chaleur pèse peu, et les courses fraîches sont des marathons et des semis ; l'effet moyen sous-estime donc celui du marathon et surestime celui du demi-fond. L'âge ensuite : y augmente fortement avec l'âge (0,7 % avant 23 ans, 3,5 à 3,8 % après 38 ans), car le record d'un coureur âgé est ancien ; les courses chaudes réunissant des coureurs plus jeunes, $\beta_Z > 0$ et $\mathrm{Cov}(W, Z) < 0$, et le biais est négatif. L'altitude joue en sens inverse : les lieux d'altitude (Kigali, Mexico, Guiyang, Lanzhou) sont aussi chauds, et l'hypoxie ralentit, d'où un biais positif si l'altitude est omise. Le pays et le parcours induisent un biais de sens inconnu : le WBGT est élevé sous les tropiques (Jakarta, Chon Buri, Lagos, Cali) et lors des réunions d'été européennes, et ces courses diffèrent aussi par le profil, le plateau et l'enjeu. Enfin, la sélection biaise vers le bas : par forte chaleur, des coureurs renoncent, abandonnent ou « gèrent », et la troncature des listes coupe les performances lentes.

3.5 La troncature : démonstration et remède

Revenons sur le piège de la troncature, qui nous a longtemps occupés. Considérons deux coureurs de même niveau, dont le record au marathon est de 2 h 30, dans une course qui ne liste que les hommes sous 2 h 37. Par temps frais, tous deux

finissent entre 2 h 30 et 2 h 35 : ils sont sous le seuil et apparaissent dans les résultats. Par fort WBGT, le premier court en 2 h 36 et reste listé ; le second, davantage affecté par les conditions, court en 2 h 45, dépasse le seuil et disparaît des résultats. Seul le coureur le plus résistant à la chaleur figure donc dans les données. Pour les athlètes dont le record est proche du seuil, c'est-à-dire les moins rapides de la liste, on n'observe par forte chaleur que ceux qui ont bien couru par rapport à leur niveau : leur ralentissement moyen est sous-estimé, et l'effet de la chaleur est biaisé vers zéro.

Pour s'en convaincre, modélisons cette situation. Supposons qu'en l'absence de troncature, $y_i = \mu_i + \varepsilon_i$ avec $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, où $\mu_i = \mathbb{E}[y_i]$ est le ralentissement moyen attendu pour l'athlète i dans les conditions de sa course ; une hausse du WBGT augmente μ_i. On n'observe pourtant y_i que si $y_i \le m_i$, et la quantité réellement observée en moyenne est $\mathbb{E}[y_i \mid y_i \le m_i]$. Notons φ et Φ la densité et la fonction de répartition de la loi normale centrée réduite, et $a_i = (m_i - \mu_i)/\sigma$ la marge exprimée en écarts-types. Comme $z\varphi(z) = -\varphi'(z)$,

$$\mathbb{E}[\varepsilon \mid \varepsilon \le \sigma a] = \frac{1}{\Phi(a)} \int_{-\infty}^{a} \sigma z\, \varphi(z)\, \mathrm{d}z = -\sigma\, \frac{\varphi(a)}{\Phi(a)},$$

d'où l'espérance d'une loi normale tronquée par le haut :

$$\mathbb{E}[y_i \mid y_i \le m_i] = \mu_i - \sigma\, \Lambda(a_i), \qquad \Lambda(a) = \frac{\varphi(a)}{\Phi(a)}, \tag{6}$$

où Λ est l'inverse du ratio de Mills. Si la chaleur augmente μ_i de δ, la moyenne observée n'augmente donc que de $\delta\, \partial_\mu \mathbb{E}[y \mid y \le m]$. Pour calculer cette dérivée, notons que $a = (m - \mu)/\sigma$ dépend de μ, avec $\partial a/\partial \mu = -1/\sigma$, et que, puisque $\varphi'(a) = -a\, \varphi(a)$,

$$\Lambda'(a) = \frac{\varphi'(a)\, \Phi(a) - \varphi(a)^2}{\Phi(a)^2} = -\Lambda(a)\big(a + \Lambda(a)\big).$$

Il vient

$$\frac{\partial}{\partial \mu}\big[\mu - \sigma \Lambda(a)\big] = 1 + \Lambda'(a) = 1 - \Lambda(a)\big(a + \Lambda(a)\big). \tag{7}$$

Ce facteur est compris entre 0 et 1 : c'est aussi le rapport $\mathrm{Var}(y \mid y \le m)/\sigma^2$, et la variance d'une loi tronquée est toujours inférieure à celle de la loi complète. La pente estimée est donc *atténuée*, d'autant plus que la marge a est faible. Quand la marge est grande, la troncature devient négligeable : $\Lambda(a) \to 0$, le facteur tend vers 1 et le biais disparaît.

Cette analyse suggère directement le remède : ne garder que les athlètes dont la marge au seuil est suffisante, $m_i \ge M$ pour une marge minimale M fixée. Pour eux, tout ralentissement jusqu'à M % reste observable. Il est essentiel que ce filtre porte sur le *record* de l'athlète comparé au dernier temps listé, et non sur son résultat du jour : il écarte les athlètes proches du seuil, pas ceux qui ont mal couru, et ne crée donc pas lui-même de sélection sur y. Son coût est celui d'un échantillon plus petit et de meilleur niveau. Il réduit le biais sans l'éliminer : un ralentissement supérieur à la marge, ou un abandon, reste invisible.

Les données confirment le mécanisme. Parmi les 4 425 performances valides dont la marge est inférieure à 5 %, 63 % sont des records personnels, contre 32 % dans l'échantillon d'analyse : un athlète dont le record est proche du dernier temps listé n'apparaît que s'il court vite.

Pour mesurer l'effet du choix de M, nous avons comparé la pente de y en fonction du WBGT pour plusieurs marges minimales (0, 2, 5, 8, 10 et 12 %). Si la troncature biaise vers zéro, la pente doit augmenter avec M. L'outil est la régression linéaire simple $y = \beta_0 + \beta_1 W + \varepsilon$, où β_1 est la pente en points de y par degré, et ε un aléa de moyenne nulle et de variance σ^2. Les moindres carrés retiennent les valeurs de (β_0, β_1) qui minimisent $S(\beta_0, \beta_1) = \sum_i (y_i - \beta_0 - \beta_1 W_i)^2$. La condition $\partial S/\partial \beta_0 = 0$ donne $\hat\beta_0 = \bar y - \hat\beta_1 \bar W$: la droite passe par le point moyen. La condition $\partial S/\partial \beta_1 = 0$ donne alors $\sum_i (W_i - \bar W)(y_i - \bar y) = \hat\beta_1 \sum_i (W_i - \bar W)^2$, d'où

$$\hat\beta_1 = \frac{\sum_i (W_i - \bar W)(y_i - \bar y)}{\sum_i (W_i - \bar W)^2} = \frac{\widehat{\mathrm{Cov}}(W, y)}{\widehat{\mathrm{Var}}(W)} = r\, \frac{s_y}{s_W}.$$

La pente combine la force du lien linéaire r et le rapport des échelles des deux variables. Puisque $\sum_i (W_i - \bar W) = 0$, on peut écrire $\hat\beta_1 = S_{WW}^{-1} \sum_i (W_i - \bar W)\, y_i$ avec $S_{WW} = \sum_i (W_i - \bar W)^2$: c'est une combinaison linéaire des y_i. Avec des aléas indépendants de variance σ^2,

$$\mathbb{E}[\hat\beta_1] = \beta_1, \qquad \mathrm{Var}(\hat\beta_1) = \frac{\sigma^2}{S_{WW}}, \qquad \widehat{\mathrm{se}}(\hat\beta_1) = \frac{\hat\sigma}{\sqrt{S_{WW}}}.$$

L'erreur type diminue quand les données sont plus nombreuses, quand le WBGT varie sur une plage plus large et quand le bruit est plus faible. Reste à estimer σ^2, à partir des résidus $\hat{\varepsilon}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 W_i$. Ceux-ci vérifient deux contraintes, $\sum_i \hat{\varepsilon}_i = 0$ et $\sum_i W_i \hat{\varepsilon}_i = 0$, et ne varient librement que dans un espace de dimension $n-2$, le nombre de *degrés de liberté*. On montre que $\mathbb{E}\big[\sum_i \hat{\varepsilon}_i^2\big] = (n-2)\,\sigma^2$, d'où l'estimateur sans biais $\hat{\sigma}^2 = \sum_i \hat{\varepsilon}_i^2 / (n-2)$; diviser par n sous-estimerait σ^2, la droite étant ajustée au plus près des points. Pour n grand, $\hat{\beta}_1$ est approximativement normal, d'où l'intervalle de confiance à 95 % $\hat{\beta}_1 \pm 1{,}96\,\widehat{\mathrm{se}}(\hat{\beta}_1)$.

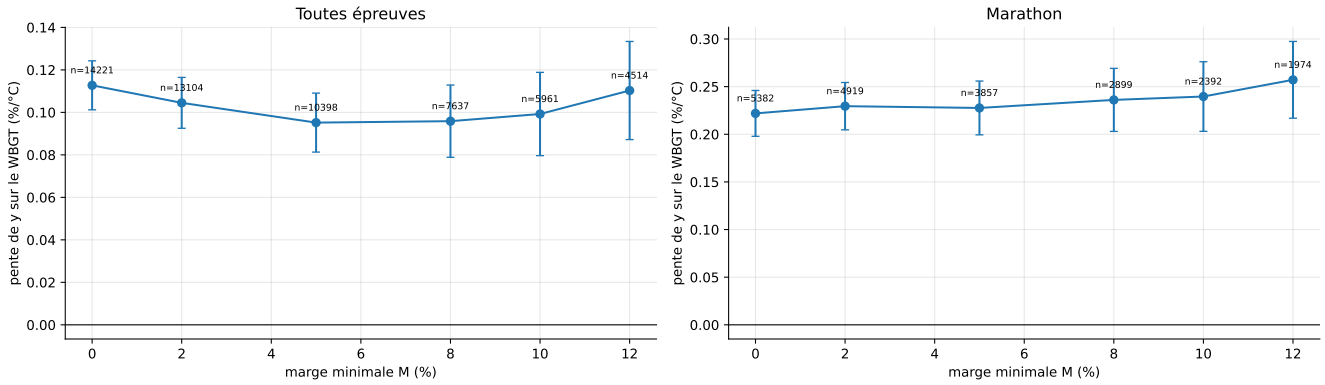


Figure 5 : Pente de la régression simple de y sur le WBGT selon la marge minimale M exigée, toutes épreuves confondues (à gauche) et au marathon (à droite), avec intervalles de confiance à 95 % calculés sous hypothèse d'indépendance. Les effectifs sont indiqués au-dessus des points.

Trois points guident la lecture de l'expérience. Sans troncature, la pente serait à peu près constante : le sous-échantillon change, pas la vraie pente. Un M plus grand réduit le biais mais retire des données, si bien que l'intervalle de confiance s'élargit ; c'est un compromis entre biais et variance, et l'échantillon change aussi de nature, puisqu'il ne garde que des athlètes plus rapides. Enfin, les sous-échantillons sont emboîtés (celui de $M = 12$ est inclus dans celui de $M = 5$) : les pentes sont très corrélées entre elles, et des intervalles qui se chevauchent ne suffisent pas à conclure que deux pentes sont égales.

La pente globale bouge peu avec la marge (figure 5) : 0,113 point par degré sans filtre ($M = 0$, 14 221 performances), 0,095 pour $M = 5$ et 0,110 pour $M = 12$ (4 514 performances). Au marathon, seul pour éviter le paradoxe de Simpson, elle croît avec M : 0,222, puis 0,228 et 0,257 point par degré. C'est le sens attendu : exiger une marge plus grande retire les courses où l'atténuation est possible. L'ampleur reste modeste, +15 % entre $M = 0$ et $M = 12$, dans les marges d'incertitude, alors que l'échantillon est divisé par 2,7. Nous avons retenu $M = 5$ % comme compromis, et nous reviendrons sur ce choix en section 13 avec le modèle final. Deux réserves s'imposent : la pente globale mêle les épreuves, et les intervalles affichés supposent des performances indépendantes. La section suivante montre qu'ils sont en réalité environ deux fois trop étroits.

3.6 Une structure de dépendance forte

Les coureurs d'une même course partagent la météo, le déroulement de la course (lièvres, tactique) et le plateau ; les éditions d'un même parcours partagent son profil. Nous avons voulu mesurer la part de la variance de y commune aux coureurs d'une même course, d'un même meeting, d'un même parcours ou d'un même lieu. L'outil naturel est la *corrélation intra-classe*.

Supposons les observations réparties en G groupes et écrivons, pour l'athlète j du groupe g,

$$y_{gj} = \mu + u_g + \varepsilon_{gj}, \qquad u_g \sim \mathcal{N}(0, \tau^2), \qquad \varepsilon_{gj} \sim \mathcal{N}(0, \sigma^2), \tag{8}$$

tous indépendants. L'effet u_g est partagé par toutes les observations du groupe (même météo, même train de course, même parcours) ; ε_{gj} est la part propre à l'individu. Deux coureurs d'un même groupe partagent le même u_g, d'où

$$\mathrm{Var}(y_{gj}) = \tau^2 + \sigma^2, \qquad \mathrm{Cov}(y_{gj}, y_{gj'}) = \mathrm{Var}(u_g) = \tau^2 \quad (j \neq j'), \qquad \mathrm{ICC} = \mathrm{Corr}(y_{gj}, y_{gj'}) = \frac{\tau^2}{\tau^2 + \sigma^2}.$$

L'ICC a deux lectures équivalentes : la part de la variance totale due aux groupes, et la corrélation entre deux observations d'un même groupe. Elle est nulle si les groupes ne jouent aucun rôle, et vaut 1 si toutes les observations d'un même groupe sont identiques.

Pour l'estimer avec des groupes de tailles inégales, nous utilisons l'estimateur de l'analyse de la variance. Avec N observations, n_g observations dans le groupe g, $\bar{y}_g$ la moyenne du groupe et $\bar{y}$ la moyenne générale, la variation totale se décompose en une part entre groupes et une part intra-groupes :

$$\underbrace{\sum_g \sum_j (y_{gj} - \bar{y})^2}_{\text{totale}} = \underbrace{\sum_g n_g (\bar{y}_g - \bar{y})^2}_{\text{entre groupes}} + \underbrace{\sum_g \sum_j (y_{gj} - \bar{y}_g)^2}_{\text{intra-groupes}}.$$

Divisant chaque somme par son nombre de degrés de liberté, on définit les carrés moyens et une taille de groupe effective n_0 :

$$\mathrm{MSB} = \frac{\sum_g n_g (\bar{y}_g - \bar{y})^2}{G - 1}, \qquad \mathrm{MSW} = \frac{\sum_g \sum_j (y_{gj} - \bar{y}_g)^2}{N - G}, \qquad n_0 = \frac{N - \sum_g n_g^2 / N}{G - 1}.$$

Sous le modèle (8), $\mathbb{E}[\mathrm{MSW}] = \sigma^2$ et $\mathbb{E}[\mathrm{MSB}] = \sigma^2 + n_0\,\tau^2$. Au sein d'un groupe, en effet, u_g est commun à tous et disparaît des écarts $y_{gj} - \bar{y}_g$, qui ne contiennent que le bruit individuel ; il reste $N - G$ degrés de liberté, puisque G moyennes ont été estimées. Les moyennes de groupe varient au contraire pour deux raisons : les vraies différences entre groupes, de variance τ^2, et le bruit d'échantillonnage, de variance σ^2 / n_g. En développant l'espérance de la somme entre groupes, on obtient $(G-1)\,\sigma^2 + \left(N - \sum_g n_g^2 / N\right) \tau^2$, d'où le facteur n_0. Si tous les groupes ont la même taille n, $n_0 = n$; s'ils sont déséquilibrés, n_0 est inférieur à l'effectif moyen N/G, car les gros groupes apportent moins d'information sur τ^2 que leur taille ne le suggère. En égalant chaque carré moyen à son espérance, on obtient l'estimateur des moments

$$\hat{\sigma}^2 = \mathrm{MSW}, \qquad \hat{\tau}^2 = \frac{\mathrm{MSB} - \mathrm{MSW}}{n_0}, \qquad \widehat{\mathrm{ICC}} = \frac{\mathrm{MSB} - \mathrm{MSW}}{\mathrm{MSB} + (n_0 - 1)\,\mathrm{MSW}}.$$

Quand la vraie ICC est proche de 0, MSB peut être inférieur à MSW par hasard, et l'estimateur légèrement négatif ; nous ne le tronquons pas à 0, ce qui introduirait un biais vers le haut.

La conséquence pratique de l'ICC se lit sur la variance d'une moyenne. Pour n observations d'un même groupe, corrélées deux à deux avec la corrélation ρ et de variance $\sigma_t^2 = \tau^2 + \sigma^2$,

$$\mathrm{Var}(\bar{y}) = \frac{1}{n^2}\left[n\,\sigma_t^2 + n(n-1)\,\rho\,\sigma_t^2\right] = \frac{\sigma_t^2}{n}\left[1 + (n-1)\rho\right].$$

Le facteur $\mathrm{deff} = 1 + (\bar{n} - 1)\rho$, appelé *effet de plan* (Kish, 1965), mesure de combien la corrélation multiplie la variance par rapport à des observations indépendantes. La *taille d'échantillon effective* N/deff est le nombre d'observations indépendantes qui apporteraient la même information.

Le résultat a été l'une des surprises de l'étude. Environ 17 % de la variance de y est commune aux coureurs d'une même course (ICC de 0,18), d'un même meeting (0,17), d'un même parcours (0,17) ou d'un même lieu (0,16). Ces valeurs sont presque égales : l'essentiel de ce qui est partagé l'est déjà au niveau du lieu (météo, parcours, plateau, chrono du jour), et l'on ne gagne presque rien à descendre à la course. Avec en moyenne 26 performances par course, l'effet de plan vaut environ $1 + 25 \times 0{,}18 \approx 5{,}5$: les 10 398 performances ne valent qu'environ 1 900 observations indépendantes, et seulement 396 situations météorologiques distinctes. Quatre conséquences en découlent : les intervalles de confiance calculés sous hypothèse d'indépendance sont environ $\sqrt{5{,}5} \approx 2{,}3$ fois trop étroits ; des plis de validation aléatoires laisseraient fuiter les effets de lieu ; les intervalles de confiance devront rééchantillonner des lieux, et non des lignes ; enfin, un modèle à effet aléatoire de course est naturel.

4 Un protocole de validation à l'épreuve des fuites

L'outil final servira à estimer l'effet des conditions météorologiques dans une ville et une course qui n'ont jamais été observées. Le protocole d'évaluation doit reproduire cette situation : un modèle n'est jugé que sur des données absentes de son apprentissage, et ces données doivent en être aussi indépendantes que le seront celles d'un usage réel. La structure de dépendance mise au jour en section 3.6 rend cette exigence décisive.

4.1 Fuites d'information et regroupement par lieu

Notons ℓ une fonction de perte et f un prédicteur. L'erreur mesurée sur un ensemble de validation n'estime sans biais le risque de généralisation $\mathcal{R}(f) = \mathbb{E}[\ell(f(x), y)]$ que si les ensembles d'apprentissage et de validation sont indépendants.

Lorsqu'une information partagée entre les deux ensembles est disponible à l'évaluation mais ne le sera pas lors de l'usage réel, l'erreur mesurée est trop optimiste : on parle de *fuite d'information*. Trois structures de dépendance sont en cause ici. La météo et les aléas sont d'abord partagés au sein d'une course et d'un meeting : tous les coureurs d'une course subissent presque le même WBGT et le même déroulement (lièvres, tactique, vent de face dans la dernière ligne droite). Un découpage aléatoire des lignes placerait une même course des deux côtés, et le modèle pourrait associer l'aléa du jour à une valeur de WBGT et être récompensé pour ce surapprentissage. La vitesse d'un parcours est ensuite partagée entre ses éditions : Boston reste vallonné d'une année à l'autre, Valencia reste rapide. Si l'édition 2023 est en apprentissage et l'édition 2026 en validation, le modèle peut reconnaître le parcours, par son altitude et ses conditions typiques, et en tirer profit sans avoir rien appris de l'effet de la météo. Les athlètes, enfin, peuvent apparaître plusieurs fois ; c'est rare dans nos données, et leur niveau est déjà absorbé par le record personnel.

Nous avons donc regroupé les données au niveau le plus englobant, le lieu : toutes les courses, éditions et épreuves d'une même ville sont placées du même côté de chaque découpage. Ce choix prudent ne coûte presque rien, puisque l'ICC de lieu (0,16) est proche de celle de la course (0,18).

Environ 20 % des lieux sont d'abord mis de côté pour former l'*ensemble de test*. Les conditions chaudes étant rares, le tirage est stratifié : les lieux sont répartis en trois tiers de climat selon leur WBGT moyen, puis $\lceil 0{,}2\, n_{\text{tiers}} \rceil$ lieux sont tirés au hasard dans chaque tiers, où n_{tiers} est le nombre de lieux du tiers. L'ensemble de test contient ainsi des lieux chauds, frais et intermédiaires. Il n'est utilisé *qu'une seule fois*, pour l'évaluation finale (section 9) : choisir un modèle ou un hyperparamètre sur le test rendrait son erreur optimiste.

Sur les lieux restants, les modèles et leurs hyperparamètres sont choisis par *validation croisée* à $K = 5$ plis. Pour chaque pli k, un modèle est entraîné sur les quatre autres plis, notés $\mathcal{A}_k$, puis évalué sur le pli k, noté $\mathcal{V}_k$; le risque est estimé par la moyenne des K erreurs. Chaque pli est formé de lieux entiers. Pour équilibrer les plis en nombre de performances, les lieux sont affectés de façon gloutonne : on les ordonne par effectif décroissant, puis on place chacun dans le pli le moins rempli.

L'ensemble de test ainsi obtenu compte 21 lieux et 2 355 performances (23 % des données). Il couvre bien la plage de climats, avec un WBGT moyen par lieu allant de 9,5 °C (marathon de Chicago) à 26,5 °C (Cape Elizabeth) : des lieux frais (Chicago, Valencia, Auxerre, Cholet), intermédiaires (Annecy, Brest, Le Cap) et chauds (Ordizia, Smederevo, Chon Buri, Jakarta). Deux lieux y pèsent lourd : Portland (686 performances de piste) et Valencia (415 performances de marathon). Les 79 lieux restants (8 043 performances) forment cinq plis équilibrés de 1 607 à 1 611 performances, soit 14 à 17 lieux chacun. Aucun identifiant de lieu, de parcours, de meeting ou de course n'est commun à l'apprentissage et à la validation. À titre de comparaison, un découpage aléatoire des lignes, à raison de 80 % pour l'apprentissage, partagerait 77 des 79 lieux, 119 parcours, 105 meetings et 247 courses entre apprentissage et validation : presque toutes les structures de dépendance identifiées seraient présentes des deux côtés. La section 7.5 mesurera le coût de cette fuite.

4.2 Métriques d'évaluation

Pour n observations y_i et leurs prédictions $\hat{y}_i$, nous utilisons trois métriques :

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}, \qquad \mathrm{MAE} = \frac{1}{n}\sum_i |y_i - \hat{y}_i|, \qquad R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

La racine de l'erreur quadratique moyenne (RMSE) s'exprime dans l'unité de y, en points de pourcentage, et pénalise fortement les grandes erreurs. Elle correspond à la perte quadratique, dont le minimiseur est l'espérance conditionnelle $\mathbb{E}[y \mid x]$: c'est notre métrique principale, cohérente avec la perte utilisée par les modèles. L'erreur absolue moyenne (MAE) correspond à la perte absolue, dont le minimiseur est la médiane conditionnelle ; elle est plus robuste aux valeurs extrêmes, et constitue un complément utile pour une cible asymétrique, à queues épaisses et hétéroscédastique. Le coefficient R^2 mesure la part de la variance de y expliquée par le modèle, par comparaison avec la prédiction constante $\bar{y}$ calculée sur l'échantillon évalué. Hors échantillon, il peut être négatif : le modèle fait alors moins bien que cette moyenne. Même le modèle constant obtient un R^2 de validation légèrement négatif, puisqu'il prédit la moyenne de l'apprentissage et non celle du pli évalué.

Nous attendions des R^2 modestes. L'essentiel de la variance de y vient de la variabilité d'une course à l'autre et d'un coureur à l'autre (forme du jour, tactique, ancienneté du record), que la météo n'explique qu'en partie. Pour l'outil final, la qualité de l'*estimation de l'effet* de la chaleur, c'est-à-dire de la courbe de dégradation, compte d'ailleurs autant que la précision des prédictions individuelles.

4.3 Variables dérivées et décomposition de Mundlak

Trois variables ont été ajoutées. Elles sont calculées à l'intérieur d'une ligne ou d'un parcours ; un parcours appartenant à un seul lieu, leur calcul n'introduit aucune fuite entre les plis. La première est le logarithme de la durée de course attendue : l'effet de la chaleur croît avec la durée de l'effort, et le logarithme place sur une même échelle un 800 m (environ deux minutes) et un marathon (environ 150 minutes). La deuxième est l'*altitude utile* $\max(0,\ \text{altitude} - 500)/1000$, en kilomètres au-delà de 500 m : cette fonction charnière traduit l'hypothèse physiologique d'un effet de l'hypoxie négligeable sous 500 m et linéaire au-delà.

La troisième répond à la question des facteurs confondants entre lieux. Notons $\bar{W}_g$ le WBGT moyen du parcours g, toutes éditions et tous coureurs confondus. Tout WBGT se décompose en

$$W_{gj} = \underbrace{\bar{W}_g}_{\text{inter-parcours}} + \underbrace{(W_{gj} - \bar{W}_g)}_{\text{intra-parcours}}. \tag{9}$$

La composante intra-parcours varie d'une édition à l'autre, ou entre coureurs rapides et lents d'une même course qui ne courent pas pendant les mêmes heures : elle compare un parcours à lui-même, et reste à l'abri des différences entre parcours. La composante inter-parcours compare au contraire des parcours différents et reste exposée aux facteurs confondants de la section 3.4. Introduire $\bar{W}_g$ comme régresseur supplémentaire permet au coefficient du WBGT de ne capter que l'effet intra-parcours (Mundlak, 1978) ; nous en verrons la justification formelle en section 6.6.

Cette décomposition a révélé une limite sérieuse des données : l'écart-type du WBGT est de 4,52 °C sur l'ensemble des données, mais de 1,04 °C seulement au sein d'un parcours. La variation intra-parcours ne représente donc qu'environ 5 % de la variance du WBGT ($1{,}04^2/4{,}52^2 \approx 0{,}05$). L'essentiel de l'information sur la chaleur provient de la comparaison entre lieux, exposée aux facteurs confondants ; une estimation fondée sur la seule variation intra-parcours sera mieux protégée de ces biais, mais reposera sur une faible variation et devra être extrapolée pour décrire un écart de 10 °C. Par ailleurs, l'altitude au-delà de 1 000 m ne concerne que 168 performances, dans 8 lieux, et les valeurs manquantes se limitent à l'âge (9,2 %) et à la forme (45,1 %, faute de meilleure performance de la saison d'avant course).

4.4 Un prétraitement appris sur l'apprentissage seulement

Les modèles opèrent sur une matrice numérique $X \in \mathbb{R}^{n \times p}$. Tous les paramètres du prétraitement (médianes, moyennes, écarts-types, modalités) sont appris sur $\mathcal{A}_k$ seulement, puis appliqués tels quels à $\mathcal{V}_k$ ou au test : les estimer sur l'ensemble des données constituerait une fuite, puisque le prétraitement « connaîtrait » les lieux de validation. Les valeurs manquantes sont imputées par la médiane d'apprentissage, robuste aux valeurs extrêmes, et une indicatrice de manquant est ajoutée, car l'absence d'une donnée peut être informative : un athlète sans meilleure performance de la saison d'avant course n'a souvent pas couru l'épreuve plus tôt dans l'année. Les variables sont enfin standardisées, $z = (x - \bar{x})/s$. La standardisation est nécessaire à la pénalité ridge, qui dépend de l'échelle des coefficients, et facilite l'optimisation des réseaux de neurones ; elle est inutile pour les arbres, invariants par transformation monotone des variables.

Chaque modalité d'une variable catégorielle vue à l'apprentissage reçoit une colonne indicatrice (encodage *one-hot*) ; une modalité inconnue produit une ligne de zéros. Si toutes les modalités sont encodées et que le modèle comporte une constante, la somme des indicatrices est égale à la colonne constante : X n'est plus de rang plein et $X^\top X$ n'est pas inversible. Lorsque c'est nécessaire, nous omettons donc une modalité dite de référence, dont les autres coefficients mesurent l'écart. Appliqué aux variables de contexte, ce prétraitement produit 15 colonnes : 6 variables numériques, 2 indicatrices de manquant, 5 groupes d'épreuves et 2 sexes.

4.5 La validation croisée et sa variabilité

La validation croisée est une procédure générique : pour chaque pli k, un modèle neuf est créé, de sorte qu'aucune information ne passe d'un pli à l'autre, entraîné sur $\mathcal{A}_k$ puis évalué sur $\mathcal{V}_k$. La procédure conserve aussi les *prédictions hors pli* : chaque performance d'apprentissage reçoit la prédiction d'un modèle qui ne l'a pas vue, ce qui permet d'analyser les erreurs sur l'ensemble des données d'apprentissage.

Le modèle constant, qui prédit la moyenne de y sur l'apprentissage, fournit le premier point de référence. Sa RMSE de validation croisée vaut 3,30 en moyenne, mais varie beaucoup d'un pli à l'autre : de 2,65 sur le pli 0 à 3,67 sur le pli 1. L'écart-type entre plis (0,43) donne une erreur type de la moyenne d'environ $0{,}43/\sqrt{5} \approx 0{,}19$. Cette variabilité fixe l'échelle

des comparaisons à venir : un écart de quelques centièmes de RMSE entre deux modèles ne sera pas significatif. Comme les plis sont communs à tous les modèles, les comparaisons devront être faites pli par pli, un pli difficile pesant sur tous les modèles à la fois. Les R^2 du modèle constant sont légèrement négatifs, de −0,017 à −0,0001, comme attendu.

5 Premiers modèles : régressions linéaires

Avant de recourir à des modèles flexibles, nous avons établi des points de référence simples. Ils répondent à deux questions : quelle part de la variance de y est prévisible sur un lieu nouveau, et quelle part de cette prévisibilité revient à la météo plutôt qu'au profil des athlètes ? Ils fournissent aussi une première estimation de l'effet de la chaleur, dont la section 3.4 a montré qu'elle était exposée à plusieurs biais.

5.1 Modèles naïfs

Deux modèles sans aucune variable explicative servent de plancher. Le modèle constant prédit la moyenne de y sur l'apprentissage ; tout modèle utile doit faire mieux. Le modèle des moyennes par groupe prédit la moyenne de y dans la cellule épreuve × sexe de la performance, et la moyenne globale pour une cellule absente de l'apprentissage : il teste si le seul niveau moyen de chaque groupe se transpose à des lieux nouveaux.

Le modèle constant obtient une RMSE de validation croisée de 3,300, et le modèle des moyennes par groupe 3,303 : connaître l'épreuve et le sexe n'apporte rien en moyenne. Le détail par pli est instructif. Les moyennes par groupe font mieux sur trois plis, jusqu'à 0,10 de moins sur le pli 0, et moins bien sur les deux autres, jusqu'à 0,15 de plus sur le pli 1. Les écarts de y moyen entre groupes, de l'ordre d'un point, sont faibles devant la variabilité d'un lieu à l'autre, et les moyennes apprises sur certains lieux ne se transposent pas aux autres : estimer dix moyennes ajoute de la variance d'estimation sans information transposable.

5.2 Moindres carrés ordinaires et régression ridge

On ajoute à X une colonne de 1, la constante, et l'on cherche les coefficients w qui minimisent $\mathscr{L}(w) = \|y - Xw\|^2$. Le gradient $\nabla\mathscr{L}(w) = -2X^\top(y - Xw)$ s'annule pour les *équations normales*

$$X^\top X\,\hat{w} = X^\top y, \qquad \text{soit} \qquad \hat{w} = (X^\top X)^{-1}X^\top y \quad \text{si } X^\top X \text{ est inversible.}$$

Géométriquement, $X\hat{w}$ est la projection orthogonale de y sur l'espace engendré par les colonnes de X, et le résidu $y - X\hat{w}$ est orthogonal à chacune d'elles. Si des colonnes sont colinéaires, $X^\top X$ n'est pas inversible et il existe une infinité de solutions ; nous retenons alors la solution de norme minimale $\hat{w} = X^+ y$, où X^+ est la pseudo-inverse de Moore-Penrose, calculée par décomposition en valeurs singulières.

La régression ridge, ou régularisation de Tikhonov, ajoute à la perte une pénalité sur la taille des coefficients, sans pénaliser la constante b :

$$\mathscr{L}(b, w) = \frac{1}{n}\sum_i (y_i - b - x_i^\top w)^2 + \lambda\|w\|^2.$$

La constante fixe le niveau moyen de y, qui n'a aucune raison d'être proche de 0 : la pénaliser biaiserait toutes les prédictions. L'annulation de la dérivée en b donne $\hat{b} = \bar{y} - \bar{x}^\top\hat{w}$. En reportant, le problème ne porte plus que sur les données centrées $X_c = X - \mathbf{1}\bar{x}^\top$ et $y_c = y - \bar{y}\,\mathbf{1}$, et l'annulation du gradient en w conduit à

$$\hat{w} = (X_c^\top X_c + n\lambda I)^{-1}X_c^\top y_c, \qquad \hat{b} = \bar{y} - \bar{x}^\top\hat{w}.$$

La matrice $X_c^\top X_c + n\lambda I$ est définie positive dès que $\lambda > 0$: la solution existe toujours, même avec des colonnes colinéaires. L'effet de la pénalité se lit sur la décomposition en valeurs singulières $X_c = UDV^\top$, de colonnes u_j et de valeurs singulières d_j : la prédiction s'écrit

$$X_c\hat{w} = \sum_j u_j\,\frac{d_j^2}{d_j^2 + n\lambda}\,u_j^\top y_c.$$

Chaque direction de l'espace des variables est rétrécie par le facteur $d_j^2/(d_j^2 + n\lambda) \in]0\,;\,1[$: les directions de faible variance, mal déterminées par les données et instables par moindres carrés, sont les plus atténuées. Le ridge accepte un biais, des

coefficients tirés vers 0, en échange d'une moindre variance. Deux conséquences nous serviront : la pénalité dépend de l'échelle des variables, d'où la standardisation ; et, face à deux variables presque colinéaires, le ridge tend à répartir l'effet entre elles, puisque pour une somme $w_1 + w_2$ donnée, $w_1^2 + w_2^2$ est minimale quand $w_1 = w_2$.

5.3 Une base polynomiale pour le WBGT

La figure 3 suggère une relation non linéaire entre WBGT et performance, au moins au marathon. Pour la représenter dans un modèle linéaire en ses paramètres, nous remplaçons le WBGT W par la base polynomiale

$$\psi(W) = \left(z, z^2, \dots, z^D\right), \qquad z = \frac{W - W_{\text{ref}}}{5},$$

de degré D, où 5 °C est une échelle fixée. Centrer et réduire avant d'élever à la puissance évite des colonnes d'ordres de grandeur très différents ($25^3 \approx 15\,600$ contre 25), qui rendraient $X^\top X$ mal conditionnée. Le centre et l'échelle sont fixés a priori, car estimés sur les données ils changeraient d'un pli à l'autre ; la puissance 0 est exclue, la constante étant gérée par le modèle. Les termes en WBGT peuvent en outre interagir avec le groupe d'épreuves, ce qui permet à la courbe de différer d'un groupe à l'autre.

5.4 Ce que les modèles linéaires nous ont appris

Nous avons comparé trois familles de modèles en validation croisée par lieux : les moindres carrés sur le WBGT seul, qui reproduisent la régression simple de la section 3.5 ; le ridge polynomial sur le WBGT seul, avec un degré $D \in \{1, 2, 3, 4\}$ et $\lambda \in [10^{-3}\,;\,10]$ choisis par validation croisée ; et le ridge complet, qui ajoute au WBGT (de degré $D \le 3$) les variables de contrôle (niveau, âge, forme, durée, altitude, heure, vent, pluie, groupe d'épreuves, sexe), avec ou sans interactions entre WBGT et groupe d'épreuves, et avec ou sans terme de Mundlak, soit 48 configurations.

Pour résumer l'effet de la chaleur selon un modèle f, nous utilisons l'effet moyen d'une hausse de 10 °C du WBGT au-dessus de la référence,

$$\overline{\Delta}_{10} = \frac{1}{n} \sum_i \Big[f(x_i \mid W = W_{\text{ref}} + 10) - f(x_i \mid W = W_{\text{ref}}) \Big],$$

toutes les autres variables gardant leurs valeurs observées. Pour un modèle linéaire de degré 1 sans interaction, c'est exactement dix fois la pente du WBGT.

Le WBGT seul n'apporte presque rien en prédiction. Les moindres carrés sur le WBGT obtiennent une RMSE de 3,301, légèrement moins bonne que celle du modèle constant (3,300). Le meilleur ridge polynomial ($D = 1, \lambda = 1$) atteint 3,291, soit un gain de 0,009 seulement, et toute la grille tient entre 3,291 et 3,323. Les degrés 2 à 4 ne font jeu égal avec le degré 1 qu'avec une pénalité forte, qui ramène le polynôme vers une droite : rien ne justifie une courbure à ce stade. Ce résultat n'implique pas que la chaleur soit sans effet. La variance de y est dominée par les différences entre courses et entre coureurs, et l'effet brut du WBGT est brouillé par la composition des épreuves et par les facteurs confondants ; un modèle qui ne voit que le WBGT ne peut pas séparer ces contributions.

Les variables de contrôle changent tout. Avec les contrôles, la RMSE tombe de 3,30 à 2,988 et le R^2 de validation atteint 0,18 : environ un cinquième de la variance de y devient prévisible sur un lieu nouveau. Ce gain vient du profil des athlètes (âge, niveau, forme) et du type d'épreuve bien plus que de la météo, dont l'apport isolé est nul en prédiction. La meilleure configuration est un polynôme de degré 3 avec interactions entre WBGT et groupe d'épreuves, sans terme de Mundlak, avec $\lambda = 0{,}1$. Mais les huit meilleures configurations tiennent en 0,012 de RMSE, et la configuration la plus simple (degré 1, sans interactions) n'est qu'à 0,008 de la meilleure. Ces écarts sont plus de dix fois inférieurs à l'erreur type entre plis : la validation croisée ne permet pas de les départager, et retenir le minimum revient à choisir en partie au hasard, ici le modèle le plus complexe. Or un polynôme de degré 3 propre à chaque groupe d'épreuves extrapole mal hors de la plage observée : un WBGT de 25 °C est au-delà des données en semi-marathon. Ce constat nous a conduits à adopter, en section 6.7, une règle de sélection qui privilégie le modèle le plus simple parmi ceux qui sont statistiquement équivalents. Le terme de Mundlak, lui, ne change rien en prédiction (2,990 contre 2,988).

L'effet de la chaleur triple avec les contrôles. L'effet moyen d'une hausse de 10 °C passe de 0,88 point (moindres carrés sur le WBGT seul) à 2,50 points avec les contrôles et les interactions, et à 2,65 points avec le terme de Mundlak. Les contrôles corrigent les biais identifiés en section 3.4, en particulier celui de l'âge, orienté vers le bas. Les interactions permettent surtout à l'effet de différer selon l'épreuve, au lieu d'imposer une pente commune dominée par le demi-fond, où la chaleur pèse peu. L'effet calculé reste toutefois une moyenne sur toutes les performances d'apprentissage, et il inclut des extrapolations cubiques pour les groupes dont la plage de WBGT n'atteint pas 25 °C.

Le terme de Mundlak donne un effet un peu plus fort (2,65 contre 2,50). Avec $\bar{W}_g$ en régresseur, le coefficient du WBGT ne mesure plus que l'effet intra-parcours : cet effet n'est donc pas plus faible que l'effet global, ce qui suggère que les facteurs confondants entre parcours qui subsistent une fois les contrôles introduits ne gonflent pas l'estimation. Cette lecture appelle deux réserves. Le WBGT et sa moyenne de parcours sont corrélés à 0,97, et la pénalité ridge tend à répartir l'effet entre deux variables aussi colinéaires : le coefficient intra-parcours dépend donc en partie de λ. Plus généralement, la pénalité rétrécit les effets : le ridge polynomial sur le WBGT seul, avec $\lambda = 1$, ne donne que 0,44 point, deux fois moins que les moindres carrés. Le λ qui optimise la prédiction n'est pas celui qui estime le mieux un effet. Il nous fallait donc estimer l'effet de la chaleur sans pénalité, tout en tenant compte de la dépendance entre coureurs d'une même course : c'est l'objet des modèles à effets mixtes.

6 Tenir compte de la dépendance : modèles à effets mixtes

Les modèles linéaires de la section précédente traitent chaque performance comme une observation indépendante. Or 16 à 18 % de la variance de y est commune aux coureurs d'une même course, d'un même parcours ou d'un même lieu, et la météo est en pratique une variable de course. Ignorer cette structure pose trois problèmes. Le premier est la pondération : chaque performance comptant autant, une course de 293 coureurs pèse 293 fois plus qu'une course d'un seul coureur dans l'estimation de l'effet du WBGT, alors qu'elle n'apporte qu'une seule situation météorologique ; et les vingt plus grosses courses, qui regroupent environ un tiers des performances, sont surtout fraîches. Le deuxième est la précision : les erreurs types usuelles supposent des observations indépendantes et sont trop optimistes. Le troisième est la confusion entre groupes : si les parcours chauds diffèrent des autres pour des raisons non mesurées (profil, plateau, organisation), l'effet estimé mélange la chaleur et ces différences. Les modèles à effets mixtes traitent directement les deux premiers problèmes, et nous verrons qu'ils permettent aussi d'aborder le troisième.

6.1 Le modèle à intercept aléatoire

Le modèle prolonge celui de la section 3.6 en remplaçant la constante μ par une partie linéaire :

$$y_{gj} = x_{gj}^{\top}\beta + u_g + \varepsilon_{gj}, \qquad u_g \sim \mathcal{N}(0, \tau^2), \qquad \varepsilon_{gj} \sim \mathcal{N}(0, \sigma^2), \tag{10}$$

où g indexe un groupe (une course ou un parcours) et j les n_g coureurs de ce groupe. La partie $x_{gj}^{\top}\beta$ est dite à *effets fixes* : ses paramètres sont communs à toute la population (effet du WBGT, de l'âge, du niveau). L'*effet aléatoire* u_g est un décalage commun à tous les coureurs du groupe. Pour une course, il représente le train, les lièvres, la tactique ou le vent dans la dernière ligne droite ; pour un parcours, le profil, les virages ou le revêtement, communs à toutes ses éditions. Les athlètes ne se répétant presque pas et leur niveau étant absorbé par le record personnel, c'est le groupe, et non l'athlète, qui porte l'effet partagé utile. L'écart ε_{gj} est propre au coureur : forme du jour, ancienneté du record.

Les hypothèses sont les suivantes : les u_g et les ε_{gj} sont indépendants entre eux et d'un groupe à l'autre ; leurs variances τ^2 et σ^2 sont les mêmes pour tous les groupes ; et surtout, u_g est indépendant des variables x_{gj}. Cette dernière hypothèse, dite d'*exogénéité*, est la plus fragile ; nous y reviendrons en section 6.6.

Pourquoi un effet « aléatoire » ? On pourrait ajouter une indicatrice par course, c'est-à-dire des effets fixes de course. Cela ajouterait près de 300 paramètres, mal estimés pour les petites courses et inutiles pour prédire une course nouvelle, dont l'effet est inconnu par définition. Le modèle mixte remplace ces paramètres par un seul, la *variance* τ^2 des effets de groupe : il décrit la population des courses plutôt que chaque course. Le rapport $\tau^2/(\tau^2 + \sigma^2)$ devient une ICC *conditionnelle* : la part de variance commune au groupe qui subsiste une fois le profil des athlètes pris en compte.

Deux coureurs d'un même groupe partagent u_g, d'où $\mathrm{Var}(y_{gj}) = \tau^2 + \sigma^2$ et $\mathrm{Cov}(y_{gj}, y_{gj'}) = \tau^2$ pour $j \neq j'$. Pour un groupe

de trois coureurs, la matrice de covariance de $y_g = (y_{g1}, y_{g2}, y_{g3})^\top$ s'écrit

$$V_g = \begin{pmatrix} \tau^2+\sigma^2 & \tau^2 & \tau^2 \\ \tau^2 & \tau^2+\sigma^2 & \tau^2 \\ \tau^2 & \tau^2 & \tau^2+\sigma^2 \end{pmatrix} = \tau^2\, \mathbf{1}\mathbf{1}^\top + \sigma^2 I_3,$$

et en général, pour un groupe de n_g coureurs,

$$V_g = \sigma^2\big(I_{n_g} + \gamma\, \mathbf{1}\mathbf{1}^\top\big), \qquad \gamma = \frac{\tau^2}{\sigma^2}, \tag{11}$$

où $\mathbf{1}$ est le vecteur de n_g uns. Le rapport γ de la variance de groupe à la variance individuelle est le seul paramètre de covariance à estimer en plus de σ^2. Les groupes étant indépendants, la matrice de covariance V de toutes les données est diagonale par blocs, à raison d'un bloc V_g par groupe.

6.2 Des moindres carrés ordinaires aux moindres carrés généralisés

Sous l'hypothèse d'exogénéité, l'erreur totale $u_g + \varepsilon_{gj}$ reste de moyenne nulle sachant x : les moindres carrés ordinaires restent sans biais. Mais le théorème de Gauss-Markov, qui garantit qu'ils sont les plus précis des estimateurs linéaires sans biais, suppose des erreurs non corrélées et de même variance, ce qui n'est plus le cas. Les 293 coureurs d'une même course partagent le même u_g : leurs écarts à la droite ne sont pas 293 informations indépendantes, car la part commune u_g ne se moyenne pas quand on ajoute des coureurs. Les moindres carrés ordinaires surestiment donc l'information apportée par les grosses courses.

Lorsque la covariance V des erreurs est connue, on remplace la somme des carrés des résidus par une distance qui tient compte des corrélations. L'estimateur des *moindres carrés généralisés* (MCG) est

$$\hat\beta_{\mathrm{MCG}} = \arg\min_\beta\, (y - X\beta)^\top V^{-1} (y - X\beta) = (X^\top V^{-1} X)^{-1} X^\top V^{-1} y.$$

Le théorème d'Aitken, ou théorème de Gauss-Markov généralisé, établit que c'est l'estimateur linéaire sans biais de variance minimale (Aitken, 1935). Son interprétation est simple : il revient à *blanchir* les données. Si l'on multiplie y et X par $V^{-1/2}$, les erreurs transformées ont pour covariance $V^{-1/2} V V^{-1/2} = I$: elles sont indépendantes et de même variance, et les moindres carrés ordinaires sur les données transformées redonnent exactement $\hat\beta_{\mathrm{MCG}}$. Le blanchiment donne moins de poids aux observations redondantes, c'est-à-dire très corrélées entre elles.

6.3 Le quasi-centrage

Inverser la matrice de covariance des quelque 8 000 performances d'apprentissage serait coûteux. La structure (11) permet heureusement un calcul explicite, qui éclaire en outre le fonctionnement du modèle.

Notons $J = \frac{1}{n_g}\mathbf{1}\mathbf{1}^\top$. Pour tout vecteur $v \in \mathbb{R}^{n_g}$, qui représente les valeurs d'une variable dans le groupe g, $Jv = \bar v\, \mathbf{1}$ remplace chaque composante par la moyenne du groupe, et $(I - J)v = v - \bar v\, \mathbf{1}$ donne les écarts à cette moyenne. Les matrices J et $I - J$ sont deux projections orthogonales complémentaires : $J^2 = J$, $(I-J)^2 = I - J$, $J(I-J) = 0$ et $J + (I - J) = I$. Comme $\mathbf{1}\mathbf{1}^\top = n_g J$, la covariance se décompose sur ces deux sous-espaces :

$$V_g = \sigma^2\big[(I - J) + (1 + n_g\gamma)\, J\big].$$

Autrement dit, V_g n'a que deux valeurs propres : σ^2 pour les écarts à la moyenne du groupe, et $\sigma^2(1 + n_g\gamma)$ pour la moyenne elle-même. C'est intuitif. Dans les écarts à la moyenne, u_g disparaît puisqu'il est commun à tous, et il ne reste que le bruit individuel, de variance σ^2. La moyenne du groupe contient au contraire u_g en entier : $\mathrm{Var}(\bar y_g) = \tau^2 + \sigma^2/n_g = \sigma^2(1 + n_g\gamma)/n_g$.

Puisque J et $I - J$ sont des projections orthogonales complémentaires, toute puissance de V_g agit séparément sur chaque sous-espace : $V_g^a = \sigma^{2a}\big[(I - J) + (1 + n_g\gamma)^a J\big]$. Avec $a = -1/2$, et appliqué à un vecteur v quelconque,

$$\sigma V_g^{-1/2} v = (v - \bar v\, \mathbf{1}) + \frac{\bar v}{\sqrt{1 + n_g\gamma}}\, \mathbf{1} = v - \omega_g\, \bar v\, \mathbf{1}, \qquad \omega_g = 1 - \frac{1}{\sqrt{1 + n_g\gamma}} \in [0\,;\, 1[.$$

Blanchir les données revient donc à retirer à chaque observation une fraction ω_g de la moyenne de son groupe. C'est le *quasi-centrage* :

$$\tilde{y}_{gj} = y_{gj} - \omega_g \bar{y}_g, \qquad \tilde{x}_{gj} = x_{gj} - \omega_g \bar{x}_g, \tag{12}$$

pour chaque colonne de X, constante comprise, qui devient $1-\omega_g$. L'estimateur des MCG est alors celui des moindres carrés ordinaires sur les données quasi-centrées, le facteur σ ne changeant pas β : $\hat{\beta}(\gamma) = (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top \tilde{y}$. Le calcul ne demande que les moyennes de groupe, et il est aussi rapide qu'une régression ordinaire.

Les deux sous-espaces portent deux types d'information. Les écarts à la moyenne du groupe, ou information *intra-groupe*, comparent les coureurs d'un même groupe entre eux ; les moyennes de groupe, ou information *inter-groupes*, comparent les groupes entre eux. Le quasi-centrage garde l'information intra intacte et réduit le poids de l'information inter du facteur $1 - \omega_g$. Trois régimes apparaissent selon γ. Pour $\gamma = 0$, $\omega_g = 0$ et l'on retrouve les moindres carrés ordinaires, qui utilisent les deux informations avec le même poids pour chaque ligne. Quand $\gamma \to \infty$, $\omega_g \to 1$ et l'on obtient l'estimateur intra, ou à effets fixes, qui n'utilise que l'information intra. Entre les deux, le modèle mixte réalise une mise en commun partielle : l'information intra en entier, l'information inter atténuée. Pour un γ donné, ω_g croît avec la taille du groupe : la moyenne d'un gros groupe est une mesure précise de son effet u_g, que le modèle retire donc davantage.

La conséquence pratique la plus importante concerne une variable constante au sein d'un groupe, comme le WBGT au sein d'une course : seules les moyennes de groupe en portent l'information. La moyenne des résidus du groupe g a pour variance $\tau^2 + \sigma^2/n_g$, et son poids dans les MCG est l'inverse de cette variance, soit, en unités de $1/\sigma^2$,

$$w_g = \frac{n_g}{1 + n_g\gamma} \xrightarrow[n_g \to \infty]{} \frac{1}{\gamma}. \tag{13}$$

Pour un petit groupe, $w_g \approx n_g$: le poids est celui des moindres carrés ordinaires. Pour un gros groupe, le poids *plafonne* à $1/\gamma$. Quand une course compte beaucoup de coureurs, sa moyenne est mesurée précisément, mais elle reste un seul tirage de l'effet de course u_g, et ajouter des coureurs ne réduit plus l'incertitude due à u_g. Le modèle mixte compte ainsi des courses plutôt que des coureurs.

6.4 Estimer γ : maximum de vraisemblance et REML

Tout ce qui précède suppose γ connu. L'estimation se fait donc en deux temps : pour un γ donné, $\hat{\beta}(\gamma)$ s'obtient par quasi-centrage ; on choisit ensuite le γ qui rend les données les plus vraisemblables. Si $y \sim \mathcal{N}(X\beta, V)$, la log-vraisemblance vaut

$$\ell(\beta, \sigma^2, \gamma) = -\frac{1}{2}\Big[N \ln 2\pi + \ln\det V + (y - X\beta)^\top V^{-1}(y - X\beta)\Big].$$

Ses deux termes se calculent explicitement. La matrice V_g a la valeur propre $\sigma^2(1 + n_g\gamma)$ une fois et la valeur propre σ^2 $(n_g - 1)$ fois, donc $\ln\det V = N \ln\sigma^2 + \sum_g \ln(1 + n_g\gamma)$; la forme quadratique est la norme des données blanchies, $\|\tilde{y} - \tilde{X}\beta\|^2/\sigma^2$. Pour γ fixé, le β qui maximise ℓ est $\hat{\beta}(\gamma)$, ce qui fait apparaître la somme des carrés résiduelle $\mathrm{RSS}(\gamma) = \|\tilde{y} - \tilde{X}\hat{\beta}(\gamma)\|^2$; l'annulation de la dérivée en σ^2 donne ensuite $\hat{\sigma}^2 = \mathrm{RSS}/N$. En reportant ces deux maximiseurs, on obtient la vraisemblance *profilée*, fonction de γ seul :

$$\ell_{\mathrm{ML}}(\gamma) = -\frac{1}{2}\Big[N \ln\hat{\sigma}^2(\gamma) + \sum_g \ln(1 + n_g\gamma) + N\Big] + \text{cste}.$$

Les deux termes s'opposent : le premier favorise un γ qui rend les résidus petits une fois les moyennes de groupe retirées, le second pénalise le fait d'attribuer beaucoup de variance aux groupes.

Le maximum de vraisemblance estime cependant les variances comme si β était connu, alors qu'il a été estimé sur les mêmes données. Il ignore les p degrés de liberté consommés par β et sous-estime les variances, exactement comme RSS/N sous-estime σ^2 en régression, puisque $\mathbb{E}[\mathrm{RSS}] = (N - p)\,\sigma^2$. Le même biais touche τ^2. La *vraisemblance restreinte* (REML) de Patterson et Thompson (1971) y remédie en estimant les variances à partir de la seule partie des données qui ne dépend pas de β : les *contrastes d'erreur* $A^\top y$, combinaisons linéaires de y orthogonales aux colonnes de X ($A^\top X = 0$). Il en existe $N - p$ linéairement indépendants, et leur loi ne dépend que de σ^2 et de γ. Leur log-vraisemblance s'écrit

$$\ell_R = -\frac{1}{2}\Big[\ln\det V + \ln\det(X^\top V^{-1} X) + (y - X\hat{\beta})^\top V^{-1}(y - X\hat{\beta})\Big] + \text{cste}.$$

Le terme supplémentaire $\ln\det(X^\top V^{-1}X)$ est la correction due à l'estimation de β. Comme $X^\top V^{-1}X = \tilde{X}^\top\tilde{X}/\sigma^2$, il vaut $\ln\det(\tilde{X}^\top\tilde{X}) - p\ln\sigma^2$, et l'annulation de la dérivée en σ^2 donne cette fois le diviseur sans biais, $\hat{\sigma}^2 = \mathrm{RSS}/(N-p)$. On en déduit la vraisemblance restreinte profilée

$$\ell_R(\gamma) = -\frac{1}{2}\Big[(N-p)\ln\hat{\sigma}^2(\gamma) + \sum_g \ln(1+n_g\gamma) + \ln\det(\tilde{X}^\top\tilde{X}) + (N-p)\Big] + \text{cste}, \tag{14}$$

dont on retient le maximum $\hat{\gamma}$, puis $\hat{\beta} = \hat{\beta}(\hat{\gamma})$, $\hat{\sigma}^2 = \mathrm{RSS}(\hat{\gamma})/(N-p)$ et $\hat{\tau}^2 = \hat{\gamma}\,\hat{\sigma}^2$. L'optimisation ne porte que sur une variable ; nous la menons en $t = \ln\gamma$ sur l'intervalle $[-10\,;\,6]$, par la méthode de Brent bornée (Brent, 1973). Travailler en $\ln\gamma$ supprime la contrainte $\gamma > 0$ et donne une fonction mieux conditionnée, γ pouvant varier sur plusieurs ordres de grandeur. Sur des données simulées de 600 groupes de 2 à 5 observations, avec $\tau^2 = 0{,}64$ et $\sigma^2 = 1$, cet estimateur donne $\hat{\tau}^2 = 0{,}669$ et $\hat{\sigma}^2 = 1{,}002$, en accord avec une implémentation de référence ; dans le cas limite $\gamma \to 0$, il redonne exactement les moindres carrés ordinaires.

6.5 Prédire l'effet d'un groupe : le BLUP

Le modèle estime la variance τ^2 des effets de groupe, pas les effets eux-mêmes. On peut néanmoins *prédire* l'effet u_g d'un groupe observé, par exemple pour savoir si une course a été rapide. Le couple (u_g, y_g) est gaussien, et pour un vecteur gaussien, $\mathbb{E}[u \mid y] = \mathbb{E}[u] + \mathrm{Cov}(u,y)\ \mathrm{Var}(y)^{-1}\big(y - \mathbb{E}[y]\big)$. Ici $\mathbb{E}[u_g] = 0$, $\mathrm{Cov}(u_g, y_g) = \tau^2\mathbf{1}^\top$, $\mathrm{Var}(y_g) = V_g$ et $\mathbb{E}[y_g] = X_g\beta$. Comme $\mathbf{1}$ est vecteur propre de V_g pour la valeur propre $\sigma^2(1+n_g\gamma)$, on a $\mathbf{1}^\top V_g^{-1} = \mathbf{1}^\top/\big(\sigma^2(1+n_g\gamma)\big)$, et donc

$$\hat{u}_g = \mathbb{E}[u_g \mid y_g] = \frac{\tau^2}{\sigma^2(1+n_g\gamma)}\sum_j \big(y_{gj} - x_{gj}^\top\beta\big) = \frac{n_g\gamma}{1+n_g\gamma}\big(\bar{y}_g - \bar{x}_g^\top\beta\big). \tag{15}$$

La moyenne des résidus du groupe, $\bar{y}_g - \bar{x}_g^\top\beta$, est l'estimation naïve de u_g. Elle contient cependant aussi la moyenne des bruits individuels, de variance σ^2/n_g. Le facteur

$$k_g = \frac{n_g\gamma}{1+n_g\gamma} = \frac{\tau^2}{\tau^2 + \sigma^2/n_g}$$

est la part de la variance de cette moyenne qui vient vraiment de u_g : c'est sa *fiabilité*. Le meilleur prédicteur linéaire sans biais (BLUP) rétrécit donc la moyenne des résidus vers 0, d'autant plus que le groupe est petit ou que τ^2 est faible. Une course de trois coureurs qui ont tous très bien couru n'est pas jugée aussi rapide que leur moyenne le suggère : le hasard explique une partie de l'écart. C'est un estimateur de *Bayes empirique*, la loi $\mathcal{N}(0,\tau^2)$ des effets de groupe jouant le rôle d'une loi a priori estimée sur l'ensemble des groupes. Le facteur de rétrécissement est lié au quasi-centrage par $k_g = 1 - (1-\omega_g)^2$, mais les deux quantités ont des rôles distincts : ω_g sert à estimer β, k_g à prédire u_g. Pour une course ou un lieu absent de l'apprentissage, enfin, aucune donnée ne renseigne sur u_g : sa prédiction est son espérance, 0, et le modèle prédit $x^\top\hat{\beta}$. C'est toujours le cas dans notre validation croisée par lieux, comme pour l'outil final.

6.6 Quel groupe, quel estimateur ?

Deux choix restaient à faire : le niveau de regroupement, course ou parcours, et la façon de traiter une éventuelle corrélation entre l'effet de groupe et les variables. Les deux sources d'information distinguées plus haut définissent deux estimateurs « purs » : l'estimateur *intra*, qui n'utilise que les écarts à la moyenne et compare chaque groupe à lui-même, et l'estimateur *inter*, qui n'utilise que les moyennes de groupe et compare les groupes entre eux. Les moindres carrés ordinaires comme l'estimateur à effets aléatoires sont des combinaisons pondérées de ces deux estimateurs, le modèle mixte réduisant d'autant plus le poids de l'information inter que ω_g est proche de 1.

L'estimateur à effets aléatoires suppose u_g indépendant de x_{gj}. Pour le parcours, c'est douteux : les parcours chauds diffèrent des autres par bien plus que la météo, et ces différences se retrouvent dans u_g. Les comparaisons entre parcours attribuent alors au WBGT ce qui revient à u_g : l'estimateur inter est biaisé, et l'estimateur à effets aléatoires hérite de ce biais en proportion du poids qu'il donne à l'information inter. L'information intra est au contraire protégée : retirer la moyenne du parcours fait disparaître u_g, quelle que soit sa corrélation avec le WBGT. Deux remèdes s'appuient sur cette propriété.

Le premier est l'estimateur à *effets fixes*, ou estimateur intra. On retire à y et à chaque variable sa moyenne de parcours,

$$y_{gj} - \bar{y}_g = (x_{gj} - \bar{x}_g)^\top\beta + (\varepsilon_{gj} - \bar{\varepsilon}_g),$$

puis on estime β par moindres carrés sans constante : c'est la limite $\omega_g \to 1$ du quasi-centrage. Cet estimateur a trois coûts. Les variables constantes au sein d'un parcours, comme l'altitude ou le groupe d'épreuves, sont absorbées par la moyenne et ne peuvent pas être estimées. L'effet n'est identifié que par la variation intra-parcours du WBGT, d'un écart-type d'environ 1 °C, qui provient des différentes éditions d'un même parcours, de l'écart d'horaire entre courses masculines et féminines, et de la durée de course, les coureurs lents subissant la montée de la température. Enfin, chaque moyenne de parcours consomme un degré de liberté, et la corrélation intra-course demeure, si bien que les erreurs types usuelles seraient fausses.

Le second remède est le modèle à effets aléatoires corrélés de Mundlak (1978). Au lieu de supprimer u_g, on modélise sa corrélation avec le WBGT :

$$u_g = \pi \bar{W}_g + \eta_g, \qquad \eta_g \text{ indépendant des variables.}$$

En reportant, $y_{gj} = x_{gj}^{\top}\beta + \pi \bar{W}_g + \eta_g + \varepsilon_{gj}$: le nouvel effet aléatoire η_g est exogène, et le modèle à effets aléatoires redevient valide à condition d'ajouter la moyenne $\bar{W}_g$ aux régresseurs. D'après la décomposition (9), le coefficient β_W du WBGT mesure alors l'effet intra-parcours, $\beta_W + \pi$ l'effet inter-parcours, et π leur différence : un π non nul signale une confusion entre parcours. Mundlak a montré que lorsque les moyennes de groupe de *toutes* les variables qui varient au sein des groupes sont ajoutées, l'estimateur obtenu coïncide exactement avec l'estimateur intra. Nous n'ajoutons ici que la moyenne du WBGT : on attend des valeurs proches, mais pas identiques. Par rapport aux effets fixes, cette approche conserve les variables constantes par parcours et fournit un modèle utilisable pour prédire.

Au niveau de la course, la question se pose différemment. Le WBGT y est quasi constant, l'écart entre le premier et le dernier coureur ne dépassant jamais 1,2 °C : un estimateur intra-course de l'effet du WBGT n'est pas identifiable en pratique, puisqu'il faudrait extrapoler à 10 °C un effet mesuré sur quelques dixièmes de degré. L'intercept aléatoire de course ne sert donc pas à séparer l'intra de l'inter : son rôle est la pondération (13), qui fait reposer l'estimation sur le nombre de courses plutôt que sur le nombre de coureurs. La protection contre la confusion entre groupes relève, elle, du niveau parcours.

Nous avons comparé cinq estimateurs de l'effet d'une hausse de 10 °C du WBGT, avec les mêmes variables (WBGT de degré 1, variables de contexte, vent, pluie, sexe et groupe d'épreuves) : moindres carrés ordinaires, effets aléatoires de course, effets aléatoires de parcours avec et sans terme de Mundlak, et effets fixes de parcours. L'estimateur à effets fixes n'utilise que les variables qui varient au sein d'un parcours (WBGT, vent, pluie, niveau, âge, forme, heure et sexe).

Les résultats se rangent exactement dans l'ordre du poids que chaque estimateur donne à l'information intra-parcours. Les moindres carrés ordinaires donnent un effet de 1,27 point; les effets aléatoires de parcours 1,93 point et ceux de course 1,97 point; le modèle de Mundlak 2,12 points; et les effets fixes 2,39 points. *Plus l'estimateur s'appuie sur la comparaison d'un parcours avec lui-même, plus l'effet de la chaleur est fort.* Les comparaisons entre parcours tirent donc l'effet vers le bas : une fois le profil des athlètes contrôlé, des différences non mesurées entre parcours restent corrélées au WBGT, dans le sens d'une atténuation, comme la plupart des biais identifiés en section 3.4. Les estimateurs à effets aléatoires, combinaisons pondérées de l'intra et de l'inter, se placent logiquement entre les deux extrêmes.

La comparaison entre moindres carrés ordinaires et effets aléatoires de course est particulièrement instructive. Avec exactement les mêmes variables, l'effet passe de 1,27 à 1,97 point, soit +55 %, et la seule différence est la pondération. Le modèle de course estime $\hat{\tau}^2 = 0{,}984$ et $\hat{\sigma}^2 = 8{,}046$, soit $\hat{\gamma} \approx 0{,}122$. D'après (13), une course de 6 coureurs reçoit alors un poids de 3,5 (contre 6 en moindres carrés ordinaires, avec $\omega_g = 0{,}24$), une course médiane de 14 coureurs un poids de 5,2 (contre 14, avec $\omega_g = 0{,}39$), et la plus grosse course, de 293 coureurs, un poids de 8,0 (contre 293, avec $\omega_g = 0{,}83$). Le poids de chaque course plafonne à $1/\hat{\gamma} \approx 8$ observations équivalentes : la plus grosse course pèse 2,3 fois plus qu'une course de 6 coureurs, contre 49 fois plus en moindres carrés ordinaires. L'estimation par moindres carrés ordinaires était dominée par quelques grosses courses, surtout fraîches; le modèle mixte répartit le poids sur les 294 courses d'apprentissage, dont de nombreuses petites courses chaudes. Que l'effet change autant montre combien l'estimation ordinaire dépendait de ces quelques courses.

Les deux estimateurs de l'effet intra-parcours, Mundlak et effets fixes, donnent 2,12 et 2,39 points : des valeurs proches mais non identiques, comme attendu, puisque le terme de Mundlak n'ajoute que la moyenne du WBGT et que les effets fixes n'utilisent ni la durée, ni l'altitude, ni le groupe d'épreuves. Ils concordent sur l'essentiel : l'effet intra-parcours est plus fort que l'effet estimé sans distinguer intra et inter, et le coefficient π est vraisemblablement négatif. D'un parcours à l'autre, les parcours chauds sont moins lents que ne le prédirait l'effet intra-parcours. Deux réserves tempèrent ce constat. L'effet intra repose sur une faible variation, l'écart-type intra-parcours du WBGT étant d'environ 1 °C contre plus de 4 °C au total : l'effet d'une hausse de 10 °C en est une extrapolation linéaire. Et ces estimations imposent un effet de degré 1 commun à toutes les épreuves, dont la moyenne mélange le marathon, où la chaleur pèse fortement, et le demi-fond, où elle pèse peu.

Les parts de variance, enfin, sont éclairantes. Une fois les variables contrôlées, la part de variance commune vaut 0,109 pour la course et 0,106 pour le parcours ($\hat{\tau}^2 = 0{,}961$, $\hat{\sigma}^2 = 8{,}141$), contre des ICC brutes de 0,18 et 0,17. Environ 40 % de ce qui semblait commun à une course était en fait le profil de son plateau (niveau, âge, forme). Le parcours n'explique pas plus de variance que la course : l'essentiel de ce qui est partagé l'est déjà au niveau du lieu et du parcours, et une course n'y ajoute presque rien.

6.7 Choisir la complexité : la règle d'un écart-type

Dans chaque pli de validation, les courses, les parcours et les lieux sont tous nouveaux : le BLUP vaut 0 et le modèle mixte prédit $x^\top \hat{\beta}$. Son éventuel avantage prédictif ne peut donc venir que d'une meilleure estimation de β, grâce à la pondération. Nous avons comparé six configurations du modèle à intercept aléatoire de course : WBGT de degré $D \in \{1, 2, 3\}$, avec ou sans interactions entre WBGT et groupe d'épreuves. Pour chacune, nous calculons la RMSE moyenne sur les cinq plis et son erreur type $s_{\text{plis}}/\sqrt{K}$, où s_{plis} est l'écart-type des RMSE des $K = 5$ plis.

La section 5.4 nous avait appris à nous méfier du simple minimum. La RMSE de validation croisée est elle-même une estimation bruitée, et les écarts entre configurations sont souvent bien plus petits que sa variabilité ; choisir le minimum revient alors à choisir en partie au hasard, et plus souvent le modèle le plus complexe, qui a plus de façons de s'ajuster au bruit. C'est aussi celui qui extrapole le plus mal : hors de la plage des données, un polynôme de degré 3 peut prendre n'importe quelle valeur. Nous appliquons donc la *règle d'un écart-type* (Breiman et al., 1984 ; Hastie et al., 2009) : on retient le modèle le plus simple parmi ceux dont la RMSE moyenne ne dépasse pas celle du meilleur de plus d'une erreur type,

$$\text{RMSE}(m) \le \text{RMSE}(m^\star) + \widehat{\text{se}}(m^\star), \qquad \widehat{\text{se}}(m^\star) = \frac{s_{\text{plis}}(m^\star)}{\sqrt{K}},$$

où $m^\star$ est le modèle de plus petite RMSE. Les modèles sous ce seuil sont statistiquement indiscernables du meilleur, et la simplicité sert alors à les départager : un modèle plus simple a moins de variance, extrapole mieux et s'interprète plus facilement. « Plus simple » signifie ici le degré le plus faible, puis l'absence d'interactions. La règle reste une heuristique : l'erreur type est calculée comme si les plis étaient indépendants, alors qu'ils partagent une partie de leurs données d'apprentissage.

Les six configurations tiennent en 0,019 de RMSE, de 3,009 (degré 1 avec interactions, erreur type 0,225) à 3,027 (degré 3 sans interactions), alors que les erreurs types valent 0,19 à 0,23. Le seuil de la règle, $3{,}009 + 0{,}225 = 3{,}233$, n'est dépassé par aucune d'entre elles, et la règle retient la plus simple : degré 1 sans interactions, de RMSE 3,013 et de R^2 0,163. Le degré 3 ne détériore pas sensiblement la RMSE ; le surcroît de complexité est simplement inutile.

Le modèle mixte retenu fait même légèrement moins bien que le ridge complet (2,990) et que le ridge le plus simple (2,996). L'écart, d'environ 0,02, est dix fois plus petit que l'erreur type : les deux modèles sont équivalents en prédiction. Que la pondération optimale des MCG n'améliore pas la prédiction s'explique de deux façons. La RMSE de validation donne le même poids à chaque performance : les grosses courses des plis de validation pèsent beaucoup dans la métrique, et les moindres carrés ordinaires, qui leur donnent aussi beaucoup de poids à l'estimation, sont alignés sur ce critère, alors que les MCG optimisent la précision de l'estimation de β sous le modèle. Le ridge bénéficie en outre de sa pénalité, qui réduit un peu la variance de ses coefficients.

L'intérêt du modèle mixte n'est donc pas prédictif ; il est *inférentiel*. Sa pondération reflète la quantité réelle d'information, le nombre de courses et non de coureurs, ce qui change sensiblement l'estimation de l'effet de la chaleur ; et il fournit un cadre pour distinguer effets intra et inter-parcours et quantifier l'incertitude. Une leçon plus générale se dessinait déjà à ce stade : la précision prédictive dépend très peu de la complexité du modèle, mais la forme de la courbe de dégradation en dépend beaucoup. Il faudrait donc la choisir séparément, à partir d'a priori physiologiques (section 10.4).

7 Laisser les données choisir la forme : le gradient boosting d'arbres

Les modèles des sections précédentes imposent une forme à la relation entre les variables et la performance : linéaire, ou polynomiale en WBGT, avec des interactions choisies à l'avance. Si l'effet de l'âge s'accélère après 35 ans, ou si l'effet de la chaleur dépend à la fois de l'épreuve et de l'heure, ces modèles ne le voient que si l'on a pensé à l'écrire. Le gradient boosting d'arbres n'impose aucune forme : il découvre lui-même les non-linéarités et les interactions. Nous voulions savoir si cette flexibilité améliore la prédiction sur des lieux nouveaux, et ce qu'elle dit de l'effet de la chaleur. Son prix est un risque accru de surapprentissage, que la validation croisée par lieux doit contrôler.

7.1 Arbres de régression et boosting

Un arbre de régression partitionne l'espace des variables en régions rectangulaires, les *feuilles*, par une suite de questions binaires du type « $x_j \le s$? », et prédit une constante w_l dans chaque feuille l ; par exemple « WBGT ≤ 20 °C ? », puis, pour les performances au-dessus, « durée attendue ≤ 60 min ? ». L'arbre est construit de façon gloutonne : à chaque nœud, on essaie toutes les variables j et tous les seuils s, on retient la coupure qui réduit le plus l'erreur, et l'on recommence dans chacune des deux parties. Cette construction lui donne quatre propriétés. Il capte naturellement les non-linéarités, plusieurs coupures successives sur une même variable dessinant une courbe en marches, et les interactions : une coupure sur la durée sous une coupure sur le WBGT signifie que l'effet de la chaleur dépend de la durée. Il est invariant par toute transformation croissante d'une variable, puisque seul l'ordre des valeurs compte pour choisir une coupure. Sa prédiction est en marches d'escalier, et constante au-delà des derniers seuils appris : un arbre *n'extrapole pas*, et au-dessus du WBGT le plus élevé vu à l'apprentissage, il prédit la même chose qu'à ce WBGT. Enfin, un arbre profond est très instable : quelques observations de plus ou de moins changent les premières coupures, et donc tout l'arbre ; un arbre peu profond est stable, mais trop simple.

Le *boosting* résout ce dilemme en combinant de nombreux arbres peu profonds. Il construit un modèle additif

$$\hat{y}_i = \sum_{m=1}^{n_{\text{arbres}}} \eta\, h_m(x_i),$$

en ajoutant les arbres h_m un par un, chacun corrigeant les erreurs des précédents. Avec la perte quadratique, l'intuition est simple : après $m-1$ arbres, il reste des résidus $r_i = y_i - \hat{y}_i$, et le m-ième arbre est ajusté sur ces résidus. Il cherche les régions où le modèle actuel se trompe systématiquement et y ajoute une correction. Pour une perte ℓ quelconque, la direction qui fait le plus baisser $\sum_i \ell(y_i, \hat{y}_i)$ est l'opposé du gradient, $-\partial_{\hat{y}_i} \ell(y_i, \hat{y}_i)$, appelé pseudo-résidu, qui coïncide avec le résidu pour la perte quadratique. Chaque arbre approche cette direction : le boosting est une *descente de gradient dans l'espace des fonctions*, où chaque pas est un arbre (Friedman, 2001).

Le taux d'apprentissage $\eta < 1$ multiplie chaque arbre avant de l'ajouter : le modèle ne fait qu'une partie du chemin indiqué par chaque arbre. Si un arbre corrigeait parfaitement le résidu, il n'en corrigerait alors qu'une fraction η, et il resterait $(1-\eta)^m$ du résidu initial après m arbres ; avec $\eta = 0{,}03$, il faut environ 75 arbres pour corriger 90 % d'un signal ($0{,}97^{75} \approx 0{,}10$). Ces petits pas régularisent : aucun arbre ne peut à lui seul ajuster le bruit, et une régularité doit être confirmée par de nombreux arbres successifs pour s'installer dans le modèle. Le prix est un plus grand nombre d'arbres, qu'il faut choisir.

7.2 Le critère de coupure au second ordre

Pour construire le m-ième arbre, on cherche l'arbre h qui minimise le risque régularisé

$$\sum_i \ell\big(y_i, \hat{y}_i + h(x_i)\big) + \kappa F + \frac{\lambda}{2} \sum_{l=1}^{F} w_l^2,$$

où $\hat{y}_i$ est la prédiction des $m-1$ arbres précédents et F le nombre de feuilles de h. Les deux termes de régularisation ont des rôles distincts : κ fait payer chaque feuille supplémentaire, si bien qu'un arbre doit « mériter » sa complexité, et λ pénalise la taille des valeurs w_l prédites dans les feuilles, comme le ridge pénalise la taille des coefficients. On approche la perte par son développement de Taylor à l'ordre 2 autour de la prédiction courante (Chen et Guestrin, 2016) :

$$\ell(y_i, \hat{y}_i + h_i) \approx \ell(y_i, \hat{y}_i) + G_i\, h_i + \tfrac{1}{2} H_i\, h_i^2, \qquad G_i = \partial_{\hat{y}_i} \ell(y_i, \hat{y}_i), \quad H_i = \partial^2_{\hat{y}_i} \ell(y_i, \hat{y}_i),$$

où G_i est le gradient et H_i le hessien, c'est-à-dire la courbure ; le premier terme ne dépend pas du nouvel arbre. Un arbre prédisant la même valeur w_l pour toutes les observations I_l de la feuille l, notons $G_l = \sum_{i \in I_l} G_i$ et $H_l = \sum_{i \in I_l} H_i$. L'objectif devient, à une constante près,

$$\sum_{l=1}^{F} \Big[G_l\, w_l + \tfrac{1}{2} (H_l + \lambda)\, w_l^2 \Big] + \kappa F.$$

Chaque crochet est un trinôme en w_l, de coefficient dominant positif puisque $H_l + \lambda > 0$. Sa dérivée s'annule en

$$w_l^\star = -\frac{G_l}{H_l + \lambda} = -\frac{\sum_{i \in I_l} G_i}{\sum_{i \in I_l} H_i + \lambda}, \tag{16}$$

où le crochet vaut $-\frac{1}{2}\,G_l^2/(H_l+\lambda)$: plus ce nombre est négatif, plus la feuille fait baisser la perte. Couper un ensemble d'observations I en deux parties I_a et I_b remplace un terme $-\frac{1}{2}G_I^2/(H_I+\lambda)$ par deux, et ajoute une feuille. La baisse de l'objectif, ou *gain*, vaut

$$\mathcal{G} = \frac{1}{2}\left[\frac{G_{I_a}^2}{H_{I_a}+\lambda} + \frac{G_{I_b}^2}{H_{I_b}+\lambda} - \frac{G_I^2}{H_I+\lambda}\right] - \kappa. \tag{17}$$

Une coupure n'est utile que si son gain est positif : κ est donc le gain minimal exigé pour couper. Le paramètre λ rétrécit le poids des feuilles vers 0, d'autant plus que la feuille contient peu d'observations : une feuille de trois performances ne peut pas, à elle seule, imposer une forte correction.

Pour la perte quadratique $\ell = \frac{1}{2}(y-\hat{y})^2$, on a $G_i = -r_i$ et $H_i = 1$, donc $H_l = n_l$, le nombre d'observations de la feuille, et le poids optimal $w_l^\star = \sum_{i\in I_l} r_i/(n_l+\lambda)$ est la moyenne des résidus de la feuille, rétrécie vers 0 : on retrouve l'intuition de la correction des résidus. Avec $\lambda = \kappa = 0$, le gain est la moitié de la réduction de la somme des carrés des résidus. En effet, $G_I^2/n_I = n_I\,\bar{r}_I^2$ et $\mathrm{SSE}(I) = \sum_{i\in I} r_i^2 - n_I\,\bar{r}_I^2$; dans la différence $\mathrm{SSE}(I) - \mathrm{SSE}(I_a) - \mathrm{SSE}(I_b)$, les sommes $\sum r_i^2$ se compensent, et il reste $n_a\bar{r}_a^2 + n_b\bar{r}_b^2 - n_I\bar{r}_I^2 = 2\,\mathcal{G}$. Le critère du boosting généralise donc le critère classique des arbres de régression. En pratique, la meilleure coupure sur une variable s'obtient en triant les observations, puis en calculant les sommes cumulées de G et de H : pour une coupure après la k-ième observation, G_{I_a} et H_{I_a} sont les sommes cumulées jusqu'à k, et les quantités de l'autre partie s'en déduisent par différence avec les totaux. Toutes les coupures sont ainsi évaluées en $O(n\log n)$ opérations au lieu de $O(n^2)$.

7.3 LightGBM et contrainte de monotonie

Nous avons utilisé LightGBM (Ke et al., 2017), qui implémente ce boosting de façon très efficace grâce à deux idées. Chaque variable est d'abord discrétisée une fois pour toutes en quelques centaines de classes : la recherche de coupure ne parcourt plus toutes les valeurs observées mais les bornes des classes, au prix d'une légère approximation des seuils. Les arbres croissent ensuite feuille par feuille : au lieu de couper tous les nœuds d'un même niveau, LightGBM coupe toujours la feuille dont la meilleure coupure a le plus grand gain. Pour un même nombre de feuilles, les arbres obtenus réduisent davantage la perte, mais peuvent devenir profonds et déséquilibrés ; il faut donc limiter le nombre de feuilles et l'effectif minimal par feuille.

Nos réglages de base sont les suivants : un taux d'apprentissage $\eta = 0{,}03$, au plus 15 feuilles par arbre, ce qui borne l'ordre des interactions représentables, au moins 40 performances par feuille, si bien qu'une feuille ne peut pas isoler une petite course, $\lambda = 1$ et $\kappa = 0$. Chaque arbre est en outre construit sur 80 % des variables et 80 % des performances, tirées au hasard à chaque itération : ce *boosting stochastique* décorrèle les arbres successifs et réduit la variance du modèle, comme dans une forêt aléatoire. Les variables sont celles du ridge complet : contexte (niveau, âge, forme, durée, altitude, heure, groupe d'épreuves, sexe), météo (WBGT, vent, pluie) et WBGT moyen du parcours.

La connaissance physiologique peut aussi être injectée dans le modèle. Nous avons imposé que la prédiction soit croissante en le WBGT, toutes choses égales par ailleurs : pour deux performances qui ne diffèrent que par le WBGT, $W' > W$ implique $f(x \text{ avec } W') \geq f(x \text{ avec } W)$, de sorte que plus chaud ne rend jamais plus rapide. Lorsqu'un arbre coupe sur le WBGT, la coupure n'est acceptée que si la feuille de gauche, de WBGT plus faible, prédit une valeur inférieure ou égale à celle de droite ; comme une telle coupure peut intervenir profondément dans l'arbre, des bornes sont propagées aux sous-arbres pour que la contrainte reste vraie dans tout l'arbre. Le modèle complet étant une somme d'arbres, et une somme de fonctions croissantes étant croissante, la contrainte est respectée par le modèle entier. L'imposer réduit la variance de la courbe estimée : un modèle libre peut produire, sur peu de courses chaudes, des creux et des bosses qui ne sont que du bruit.

Cette contrainte a des limites. Elle n'a de sens que si le WBGT est la seule variable thermique : si la température et l'humidité étaient aussi présentes, le modèle pourrait faire porter l'effet de la chaleur par ces variables non contraintes. Elle est discutable pour le demi-fond, où un air chaud peut être neutre, voire favorable. Elle impose une fonction croissante sur toute la plage, alors que la littérature situe un optimum entre 7,5 et 15 °C, si bien qu'un ralentissement par le froid serait interdit ; les données sous 7,5 °C sont toutefois rares. Enfin, une courbe contrainte à monter ne peut pas descendre : si l'effet réel est nul, l'estimation est biaisée vers le haut.

7.4 Choisir le nombre d'arbres sans tricher

Le nombre d'arbres est l'hyperparamètre principal du boosting. Au début, chaque arbre ajoute un signal réel et l'erreur de validation baisse. Puis les arbres n'ont plus de régularités générales à apprendre, et commencent à ajuster les particularités des données d'apprentissage : les lieux, les courses, le bruit. L'erreur d'apprentissage continue de baisser, mais l'erreur de validation remonte.

La pratique courante de l'arrêt précoce consiste à arrêter l'apprentissage quand l'erreur sur un ensemble de validation cesse de baisser. Mais si l'on évalue ensuite le modèle sur ce même ensemble, l'erreur annoncée est optimiste. La courbe d'erreur de validation est bruitée, et son minimum est atteint en partie parce que le bruit y est favorable : en moyenne, le minimum d'une courbe bruitée est plus bas que la valeur, au même point, de la courbe sans bruit, puisque $\mathbb{E}[\min_n Z_n] \leq \min_n \mathbb{E}[Z_n]$. Choisir et évaluer sur les mêmes données revient à évaluer avec une part de chance. Nous avons donc procédé autrement. Sur chaque pli k, le modèle est entraîné jusqu'à 1 500 arbres, en enregistrant la RMSE de validation $\mathrm{RMSE}_k(n)$ après chaque arbre n. Ces courbes sont moyennées sur les cinq plis,

$$\overline{\mathrm{RMSE}}(n) = \frac{1}{K} \sum_{k=1}^{K} \mathrm{RMSE}_k(n),$$

et l'on retient le nombre d'arbres $n^\star$ qui minimise la courbe moyenne. Le choix porte ainsi sur un seul paramètre commun aux cinq plis, et non sur un arrêt propre à chaque pli, ce qui réduit fortement l'optimisme dû à la sélection. Le modèle final est réentraîné sur tous les lieux d'apprentissage avec $n^\star$ arbres.

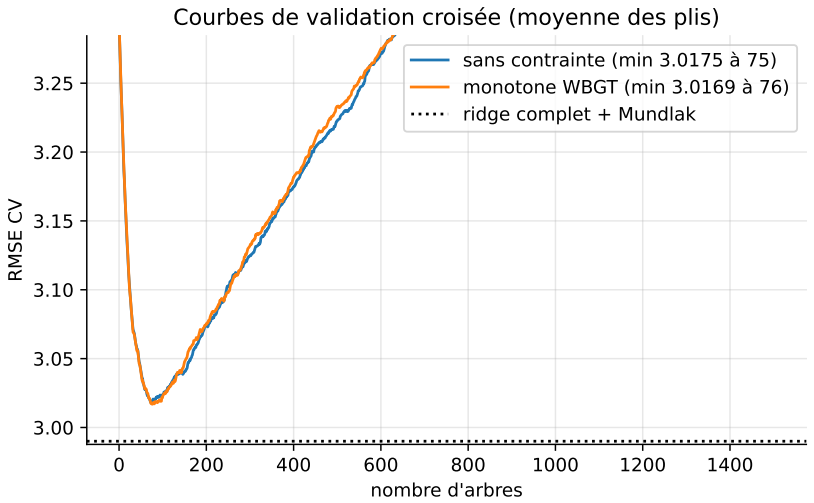


Figure 6 : RMSE de validation croisée par lieux du gradient boosting selon le nombre d'arbres (moyenne des cinq plis), sans contrainte et avec contrainte de monotonie en WBGT. La ligne pointillée indique la RMSE du ridge complet avec terme de Mundlak.

Les deux courbes tombent rapidement pendant les premières dizaines d'arbres, atteignent leur minimum vers 75 arbres, puis remontent régulièrement (figure 6) : vers 600 arbres, la RMSE dépasse 3,25 et rejoint la valeur obtenue avec un seul arbre. Avec un taux d'apprentissage de 0,03, 75 arbres correspondent à peu près au nombre nécessaire pour capter l'essentiel d'un signal simple : le modèle s'arrête dès qu'il a appris les régularités générales. Au-delà, chaque arbre apprend des particularités des lieux d'apprentissage, qui ne se transposent pas aux lieux de validation, et le surapprentissage est rapide.

Deux enseignements en sont ressortis. D'abord, la contrainte de monotonie ne coûte rien : le modèle monotone obtient une RMSE de 3,0169 avec 76 arbres, contre 3,0175 avec 75 arbres sans contrainte. Imposer que la chaleur ne fasse jamais courir plus vite ne contredit donc pas les données, et l'on peut injecter cette connaissance physiologique sans perte de précision. Ensuite, le boosting ne fait pas mieux que les modèles linéaires : avec 3,017, il fait jeu égal avec le modèle mixte (3,013) et légèrement moins bien que le ridge (2,990 à 2,996), des écarts inférieurs à 0,03 alors que l'erreur type entre plis vaut environ 0,19. La flexibilité des arbres n'apporte rien de mesurable. Le signal qui se transpose d'un lieu à l'autre est donc essentiellement lisse et proche de l'additif (effets de l'âge, du niveau, de la forme, de la durée), ce que les modèles linéaires captent déjà ; les non-linéarités et les interactions que les arbres pourraient découvrir sont soit absentes, soit trop faibles pour être distinguées du bruit avec quelque 300 courses.

7.5 Le WBGT résume-t-il bien la météo ? Que coûte une validation mal construite ?

Deux expériences ont complété l'étude du boosting, avec un nombre d'arbres choisi à chaque fois par la courbe de validation croisée. La première compare quatre jeux de variables météorologiques, les autres variables restant les mêmes : le WBGT accompagné du vent et de la pluie ; les composantes brutes (température de l'air, humidité, vent, rayonnement, pluie) ; le WBGT et ses composantes ; et aucune variable météorologique. Deux hypothèses s'opposaient. Si le résumé physique du WBGT perd de l'information utile, par exemple si l'humidité pèse plus que ne le dit la formule (1), les composantes brutes devraient mieux prédire ; si au contraire ce résumé est pertinent, il devrait faire au moins aussi bien avec moins de variables, donc moins de façons de surapprendre.

Les quatre jeux tiennent en 0,01 de RMSE : 3,017 avec le WBGT, 3,008 avec les composantes brutes comme avec le WBGT et ses composantes, et 3,014 sans aucune variable météorologique. Le modèle sans météo fait donc aussi bien que le modèle avec le WBGT, et l'avantage des composantes brutes, vingt fois plus petit que l'erreur type entre plis, ne permet de conclure ni que le WBGT perd de l'information, ni qu'il la résume bien. Sur ces données, on ne peut pas départager les jeux de variables par leur pouvoir prédictif.

Ce résultat ne contredit pas l'effet de la chaleur estimé en section 6.6, d'environ 2 points de y pour 10 °C. Il illustre la différence entre *estimer un effet* et *améliorer une prédiction*. Si la chaleur agit avec une pente $b \approx 0{,}2$ point par degré et que le WBGT varie avec un écart-type d'environ 4,4 °C, la variance de y due à la chaleur vaut au plus $b^2\ \mathrm{Var}(W) \approx 0{,}04 \times 19{,}5 \approx 0{,}8$. Rapportée à une variance résiduelle d'environ $3^2 = 9$, elle ferait baisser la RMSE d'au plus $\sqrt{9} - \sqrt{9 - 0{,}8} \approx 0{,}8/(2\times3) \approx 0{,}13$, et seulement si l'effet était connu parfaitement. Le gain réel est bien plus faible, pour trois raisons : une grande partie de la variation du WBGT est déjà expliquée par le groupe d'épreuves et l'heure, piste chaude le soir et marathon frais le matin ; l'effet est hétérogène, fort au marathon et nul en demi-fond, où se trouve la moitié des courses chaudes ; et l'effet est estimé sur quelque 300 courses, dont peu de chaudes, si bien que l'erreur d'estimation absorbe une partie du gain. Un gain potentiel de quelques centièmes, noyé dans une variabilité entre plis de 0,19, est invisible en validation croisée. La qualité de l'outil se jugera donc sur l'estimation de l'effet et sur son incertitude, et non sur la RMSE.

La seconde expérience compare, pour le même modèle, la validation croisée par lieux et une validation croisée aléatoire à cinq plis sur les lignes. Avec des plis aléatoires, la RMSE annoncée tombe à 2,378, soit une performance surestimée de 21 %, et le nombre d'arbres retenu atteint 1 498, à la limite de la recherche : vingt fois plus qu'avec les plis par lieux. Avec des plis aléatoires, chaque course a des coureurs en apprentissage et en validation ; le modèle peut alors mémoriser l'effet propre de chaque course (sa date, son lieu, sa météo, son plateau, son déroulement) et le restituer aux coureurs de la même course en validation. Plus il ajoute d'arbres, plus il mémorise finement, et plus il « prédit » bien : la courbe de validation ne remonte plus. Un modèle sélectionné ainsi serait doublement trompeur : sa performance annoncée serait fausse, et son nombre d'arbres, choisi pour mémoriser, le rendrait fortement surajusté sur un lieu nouveau, c'est-à-dire exactement dans l'usage prévu de l'outil. La figure 6 montre ce que coûtent 1 500 arbres sur des lieux nouveaux : c'est la confirmation empirique de la fuite d'information décrite en section 4.1.

8 Une troisième famille : les réseaux de neurones

Nous avions jusqu'ici deux grandes familles de modèles : des modèles linéaires, dont la forme est fixée à l'avance, et des arbres, flexibles mais en marches d'escalier. Les réseaux de neurones forment une troisième famille, flexible comme les arbres mais produisant des fonctions lisses. Leur forme lisse pourrait convenir à des effets réguliers comme ceux de l'âge, du niveau ou du WBGT, que les arbres découpent en marches. Nous les présentons sans supposer de connaissance préalable.

8.1 Qu'est-ce qu'un réseau de neurones ?

Comme tous les modèles de cette étude, un réseau de neurones est une fonction paramétrée f_θ qui associe une prédiction $\hat{y} = f_\theta(x)$ à un vecteur de variables x, et dont les paramètres θ sont appris en minimisant une perte sur des exemples. Sa particularité est d'appartenir à une famille de fonctions très riche : avec assez de paramètres, il peut représenter presque n'importe quelle relation entre x et y, sans qu'il faille en préciser la forme. Les réseaux de neurones sont à l'origine des progrès récents en reconnaissance d'images, en traduction automatique ou en génération de texte, des problèmes où les données sont massives et non structurées et où personne ne sait écrire à la main la forme de la relation. Ils s'appliquent aussi aux données tabulaires comme les nôtres, mais avec moins de succès.

L'unité de base est le *neurone*, qui calcule une combinaison linéaire de ses entrées puis lui applique une fonction non linéaire

σ, appelée *activation* :

$$h = \sigma\Big(\sum_{r=1}^{d} w_r\, x_r + b\Big) = \sigma(w^\top x + b),$$

où les w_r sont les *poids* et b le *biais*. Dans cette section, σ désigne une fonction d'activation et non un écart-type. Un neurone n'a rien de mystérieux : si σ est l'identité, c'est exactement une régression linéaire ; si σ est la sigmoïde $z \mapsto 1/(1+e^{-z})$, c'est une régression logistique.

Un réseau assemble des neurones en *couches*. Une couche de m neurones recevant tous le même vecteur $h \in \mathbb{R}^d$ s'écrit $h' = \sigma(Wh + b)$, avec $W \in \mathbb{R}^{m\times d}$ et $b \in \mathbb{R}^m$, chaque ligne de W contenant les poids d'un neurone et σ s'appliquant composante par composante. Le *perceptron multicouche* enchaîne L couches, la sortie de l'une étant l'entrée de la suivante :

$$h_0 = x, \qquad h_k = \sigma(W_k\, h_{k-1} + b_k) \quad (k = 1, \dots, L), \qquad \hat{y} = w_{L+1}^\top h_L + b_{L+1}. \tag{18}$$

Les couches intermédiaires sont dites *cachées*, car on n'observe ni leurs entrées ni leurs sorties. Le nombre de neurones d'une couche est sa *largeur*, le nombre de couches la *profondeur* du réseau. Une couche qui reçoit d entrées et compte m neurones a $(d+1)\,m$ paramètres : leur nombre croît vite avec la largeur.

Sans activation, un réseau ne serait qu'une régression linéaire déguisée, puisque la composition de deux fonctions affines est affine : $W_2(W_1x+b_1)+b_2 = (W_2W_1)\,x + (W_2b_1+b_2)$. C'est l'activation qui donne au réseau sa capacité à représenter des relations non linéaires. La sigmoïde est lisse mais sa dérivée devient très faible pour $|z|$ grand, ce qui ralentit l'apprentissage des réseaux profonds. L'activation ReLU, $\max(0, z)$, de dérivée 0 ou 1, fait du réseau une fonction affine par morceaux. L'activation SiLU, $z \mapsto z\,\mathrm{sig}(z)$ où sig est la sigmoïde, en est une version lisse et dérivable partout, et c'est celle que nous utilisons. L'activation ReLU donne une intuition géométrique de la puissance des réseaux. Chaque neurone de la première couche « plie » l'espace le long de l'hyperplan $w^\top x + b = 0$: il vaut 0 d'un côté et croît linéairement de l'autre. En dimension un, une somme $\sum_k c_k \max(0, x - s_k)$ est une ligne brisée dont les coudes sont placés en s_k et dont la pente change de c_k à chaque coude ; avec assez de coudes, une ligne brisée approche n'importe quelle courbe continue. C'est l'idée du théorème suivant.

Théorème (approximation universelle ; Cybenko, 1989 ; Hornik, 1991 ; Leshno et al., 1993)**.** *Soit σ une fonction d'activation continue et non polynomiale. Pour toute fonction continue g définie sur un compact $K \subset \mathbb{R}^d$ et pour tout $\varepsilon > 0$, il existe un réseau à une seule couche cachée de N neurones,*

$$f_N(x) = \sum_{k=1}^{N} c_k\, \sigma(w_k^\top x + b_k),$$

tel que $\sup_{x\in K} |g(x) - f_N(x)| < \varepsilon$.

Ce théorème dit qu'aucune relation continue n'est hors de portée d'un réseau assez large. Il faut aussi savoir ce qu'il ne dit pas. Il garantit l'existence de poids qui conviennent, mais ne dit pas comment les trouver. Le nombre de neurones nécessaire peut être gigantesque. Il porte sur l'approximation d'une fonction connue sur tout K, et non sur l'apprentissage à partir d'un échantillon fini et bruité : un réseau capable de tout représenter est aussi capable de représenter le bruit, c'est-à-dire de surapprendre. Enfin, il ne dit rien du comportement hors de K : un réseau n'extrapole pas de façon fiable. Le théorème n'utilise qu'une couche cachée, mais la profondeur est souvent plus économe : certaines fonctions exigent un nombre exponentiel de neurones avec une seule couche, et seulement un nombre polynomial avec plusieurs couches (Telgarsky, 2016).

8.2 Comment un réseau apprend

On cherche les paramètres θ (toutes les matrices W_k et tous les biais) qui minimisent le risque empirique, ici l'erreur quadratique moyenne $\hat{\mathcal{R}}(\theta) = \frac{1}{n}\sum_i (y_i - f_\theta(x_i))^2$. Contrairement aux moindres carrés, il n'existe pas de formule fermée, et la fonction à minimiser n'est pas convexe : elle a de nombreux minima locaux et points-selles. On procède par descente de gradient, en partant de poids tirés au hasard et en avançant pas à pas dans la direction opposée au gradient, $\theta \leftarrow \theta - \eta\, \nabla_\theta \hat{\mathcal{R}}(\theta)$, où η est le taux d'apprentissage. Trop grand, les pas font diverger l'optimisation ; trop petit, elle est très lente. Rien ne garantit d'atteindre le minimum global, mais en pratique les minima atteints sont souvent bons. Le résultat dépend toutefois du tirage initial : deux apprentissages avec des graines aléatoires différentes donnent deux réseaux différents.

Il faut calculer le gradient de la perte par rapport à des milliers de paramètres. La *rétropropagation* le fait efficacement par la règle de dérivation des fonctions composées, appliquée couche par couche de la sortie vers l'entrée. Prenons un réseau à

une couche cachée, $z = W_1 x + b_1$, $h = \sigma(z)$, $\hat{y} = w_2^\top h + b_2$, et la perte d'une observation $\ell = \frac{1}{2}(\hat{y} - y)^2$. En notant $\delta = \hat{y} - y$ l'erreur de prédiction et $\odot$ le produit composante par composante,

$$\frac{\partial \ell}{\partial b_2} = \delta, \qquad \frac{\partial \ell}{\partial w_2} = \delta\, h, \qquad \frac{\partial \ell}{\partial z} = (\delta\, w_2) \odot \sigma'(z), \qquad \frac{\partial \ell}{\partial W_1} = \frac{\partial \ell}{\partial z}\, x^\top, \qquad \frac{\partial \ell}{\partial b_1} = \frac{\partial \ell}{\partial z}.$$

L'erreur δ est propagée en arrière à travers les poids w_2, puis multipliée par la dérivée de l'activation. Le calcul réutilise les quantités de la passe avant et coûte à peu près autant qu'une prédiction. On comprend aussi pourquoi la sigmoïde gêne les réseaux profonds : sa dérivée, inférieure à $1/4$, est multipliée une fois par couche, et le gradient s'éteint en remontant vers l'entrée.

Calculer le gradient sur toutes les données à chaque pas serait coûteux. On le calcule plutôt sur un *mini-lot* de n_{lot} observations tirées au hasard (128 ou 256 ici). Le gradient d'un mini-lot est un estimateur sans biais du gradient complet, plus bruité mais beaucoup moins coûteux, et ce bruit aide même à sortir des minima locaux médiocres et des points-selles. Une *époque* est un passage complet sur les données, en mini-lots tirés dans un ordre aléatoire.

Avec un taux d'apprentissage unique, les paramètres dont le gradient est grand avancent trop vite, et ceux dont le gradient est petit trop lentement. L'optimiseur Adam (Kingma et Ba, 2015) adapte le pas de chaque paramètre à partir de deux moyennes mobiles, celle du gradient g_t et celle de son carré :

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\, g_t, \qquad v_t = \beta_2 v_{t-1} + (1-\beta_2)\, g_t^2, \qquad \theta_t = \theta_{t-1} - \eta\, \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon},$$

où $\hat{m}_t = m_t/(1-\beta_1^t)$ et $\hat{v}_t = v_t/(1-\beta_2^t)$ corrigent le biais dû à l'initialisation des moyennes à 0, avec par défaut $\beta_1 = 0{,}9$ et $\beta_2 = 0{,}999$. Le rapport $\hat{m}_t/\sqrt{\hat{v}_t}$ est de l'ordre de 1 quand le gradient est régulier et plus petit quand il est bruité : chaque paramètre avance d'environ η dans une direction stable, et prudemment dans une direction incertaine.

Un réseau a beaucoup de paramètres : celui que nous utilisons en compte environ 11 000, pour quelque 6 400 performances d'apprentissage. Il peut donc, en principe, mémoriser les données d'apprentissage, bruit compris, et doit être régularisé. Nous avons combiné trois régularisations. Le *weight decay* découplé (Loshchilov et Hutter, 2019) rétrécit les poids vers 0 à chaque pas, $\theta \leftarrow \theta - \eta\,\lambda\,\theta$, comme une régression ridge ; avec Adam, cette version découplée diffère d'une pénalité $\lambda\|\theta\|^2$ ajoutée à la perte, dont le gradient serait divisé par $\sqrt{\hat{v}_t}$ et donc appliqué très inégalement aux paramètres. Le *dropout* (Srivastava et al., 2014) met à zéro chaque neurone d'une couche cachée avec une probabilité p, indépendamment à chaque mini-lot, les neurones conservés étant multipliés par $1/(1-p)$ pour que l'espérance de la sortie ne change pas. Le réseau ne peut alors compter sur aucun neurone particulier, ni sur une combinaison fragile de neurones, et l'effet est proche d'une moyenne d'un très grand nombre de sous-réseaux ; en prédiction, tous les neurones sont utilisés. L'*arrêt précoce*, enfin, mesure la perte de validation à chaque époque, garde les poids qui l'ont rendue minimale, et arrête l'apprentissage après un nombre fixé d'époques sans amélioration, la *patience*.

8.3 Le réseau retenu

Un réseau ne traite que des nombres. Pour une variable catégorielle, nous avons utilisé des *embeddings* plutôt que l'encodage *one-hot*. Un embedding associe à chaque modalité m un vecteur appris $e_m \in \mathbb{R}^{d_e}$, rangé dans une table E à raison d'une ligne par modalité. C'est équivalent à multiplier l'encodage one-hot de la modalité par E, soit $e_m = E^\top \mathbb{1}_m$, c'est-à-dire à une première couche linéaire sans biais appliquée au one-hot. Les vecteurs sont appris en même temps que le reste du réseau, et deux modalités aux effets proches finissent avec des vecteurs proches. Pour une variable à très nombreuses modalités, un embedding de petite dimension résume des milliers de colonnes one-hot en un vecteur dense qui partage l'information entre modalités semblables. Nos variables catégorielles n'ont que 5 et 2 modalités, si bien que l'embedding n'apporte pas grand-chose ici ; une modalité inconnue à l'apprentissage reçoit un vecteur réservé.

Notre réseau est un perceptron multicouche dont l'entrée concatène les variables numériques standardisées et un embedding par variable catégorielle :

$$h_0 = \big(x^{\text{num}},\, e_{\text{groupe}},\, e_{\text{sexe}}\big), \qquad h_k = \text{Dropout}\big(\text{SiLU}(W_k\, h_{k-1} + b_k)\big), \qquad \hat{y} = w_{L+1}^\top h_L + b_{L+1}.$$

Les variables numériques sont celles du boosting (niveau, âge, forme, durée, altitude, heure, WBGT, vent, pluie et WBGT moyen du parcours), plus les indicatrices de manquant de l'âge et de la forme, soit 12 colonnes. L'embedding du groupe

d'épreuves est de dimension 4 et celui du sexe de dimension 3, si bien que h_0 a 19 composantes. La cible est elle aussi standardisée sur l'apprentissage, puis les prédictions sont ramenées à l'échelle de y. Pour une architecture à deux couches cachées de 128 et 64 neurones, le réseau compte $(19+1)\times128 = 2\,560$ paramètres pour la première couche, $(128+1)\times64 = 8\,256$ pour la seconde, 65 pour la sortie et 33 pour les deux tables d'embedding, soit 10 914 paramètres.

Deux réseaux entraînés avec des graines différentes donnent des prédictions différentes : c'est une source de variance propre à l'optimisation non convexe. Nous moyennons donc les prédictions de n_{mod} réseaux entraînés avec des graines différentes. Si ces prédicteurs ont chacun une variance s^2 et une corrélation ρ deux à deux, leur moyenne a pour variance

$$\operatorname{Var}\left(\frac{1}{n_{\text{mod}}}\sum_{m=1}^{n_{\text{mod}}} f_m\right) = \rho\, s^2 + \frac{1-\rho}{n_{\text{mod}}}\, s^2,$$

qui baisse avec n_{mod} tant que les réseaux ne sont pas parfaitement corrélés, sans aucun coût en biais.

8.4 Le surapprentissage, observé

Pour voir le surapprentissage à l'œuvre, nous avons d'abord entraîné un réseau de 128 et 64 neurones, sans dropout ni weight decay, avec un taux d'apprentissage de $3\cdot10^{-3}$, sur quatre plis de lieux, en suivant l'erreur sur le cinquième pli, formé de quatorze lieux nouveaux.

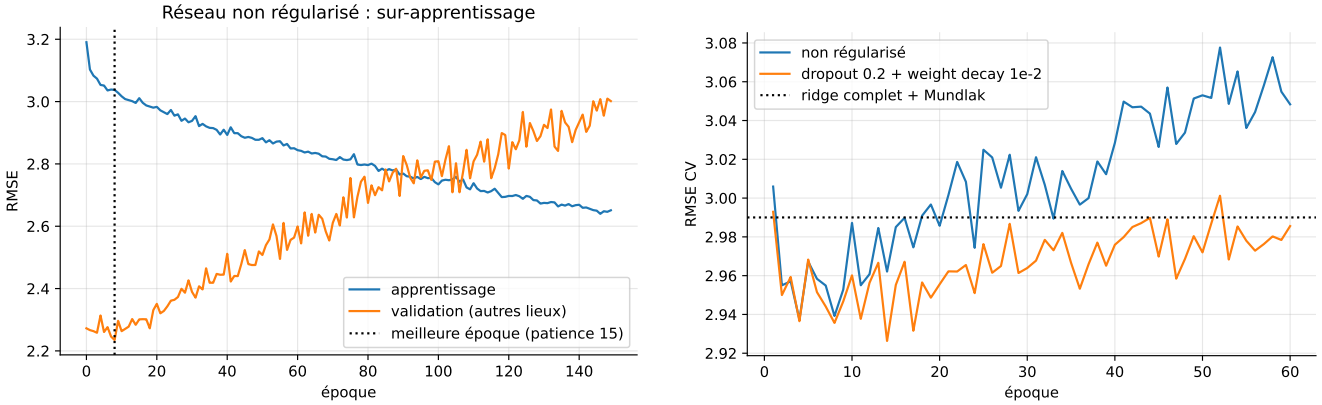


Figure 7 : À gauche, RMSE d'apprentissage (quatre plis) et de validation (pli 0, lieux nouveaux) d'un réseau non régularisé au fil des époques ; la ligne pointillée marque la meilleure époque de validation. À droite, RMSE de validation croisée (moyenne des trois premiers plis) selon le nombre d'époques, sans régularisation et avec dropout et weight decay ; la ligne pointillée indique la RMSE du ridge complet sur les cinq plis.

La figure 7 (à gauche) montre la signature typique du surapprentissage. La RMSE d'apprentissage baisse sans interruption, de 3,19 à la première époque à 2,65 à la 150e : le réseau s'ajuste de mieux en mieux aux lieux qu'il voit. La RMSE de validation atteint au contraire son minimum dès la 9e époque, puis remonte presque linéairement jusqu'à 3,00. À partir de là, chaque époque améliore l'ajustement aux lieux d'apprentissage au détriment des lieux nouveaux : avec environ 11 000 paramètres pour 6 435 performances d'apprentissage, le réseau a largement de quoi mémoriser le bruit et les particularités de chaque lieu. L'arrêt précoce, avec une patience de 15 époques, interrompt l'apprentissage à la 24e époque et recharge les poids de la 9e : la RMSE de validation vaut alors 2,235, contre 3,002 à la fin de l'apprentissage. Le surapprentissage coûte donc 0,77 point de RMSE, soit 34 % ; sans arrêt précoce, le réseau fait même nettement moins bien que le modèle constant sur ce pli (2,647). Que l'erreur de validation soit d'abord inférieure à l'erreur d'apprentissage n'a rien d'un paradoxe : le pli 0 est le plus facile des cinq, ses lieux ayant des performances moins dispersées, et c'est l'évolution des deux courbes qui compte. La valeur 2,235 est d'ailleurs optimiste, l'époque d'arrêt ayant été choisie sur ce même pli, au point le plus bas d'une courbe bruitée.

Comme pour le boosting, nous avons donc choisi le nombre d'époques sur la courbe de validation croisée moyenne. Faute de temps de calcul, cette recherche porte sur les trois premiers plis et 60 époques au plus, pour deux réglages d'un réseau de 128 et 64 neurones avec un taux d'apprentissage de 10^{-3} : sans régularisation, et avec dropout ($p = 0{,}2$) et weight decay ($\lambda = 10^{-2}$). Le réseau non régularisé atteint son minimum dès la 4e époque (RMSE de 2,937), puis remonte au-delà de 3,05 à partir de la 40e ; le réseau régularisé atteint le sien à la 14e époque (2,926), et sa courbe reste entre 2,93 et 3,00 pendant

les 60 époques (figure 7, à droite). La régularisation n'améliore presque pas la meilleure valeur, mais elle rend le réseau beaucoup moins sensible au nombre d'époques, ce qui est précieux puisque ce nombre est choisi sur une courbe bruitée.

La comparaison avec les autres modèles demande une précaution : les trois premiers plis sont plus faciles que la moyenne, et il faut confronter le réseau aux autres modèles sur les mêmes plis. Le ridge complet y obtient 2,936 sans terme de Mundlak et 2,938 avec, le modèle mixte 2,977 et le modèle constant 3,281. La ligne pointillée de la figure, qui représente le ridge sur les cinq plis, flatte donc le réseau : à plis égaux, le réseau régularisé ne devance le ridge que de 0,01, et le réseau non régularisé fait jeu égal avec lui. Ces écarts sont très inférieurs à l'erreur type entre plis, d'autant que les courbes oscillent de 0,02 à 0,03 d'une époque à l'autre : le réseau ne fait pas mieux qu'un modèle linéaire bien spécifié. C'est le résultat attendu sur des données tabulaires de taille modeste (Grinsztajn et al., 2022), et il confirme le diagnostic tiré du boosting : le signal qui se transpose d'un lieu à l'autre est lisse et presque additif, et un modèle linéaire le capte déjà.

On aurait pu, enfin, apprendre un embedding par course ou par lieu, l'équivalent neuronal d'un intercept aléatoire. Ce serait inutile ici : toutes les courses et tous les lieux évalués sont nouveaux, et leur vecteur n'aurait jamais été appris. C'est le problème du *démarrage à froid*, le même qui annule le BLUP du modèle mixte en validation. Le record personnel joue déjà le rôle de l'effet individuel de l'athlète, mesuré hors de la course.

9 Régler, puis comparer sur des villes jamais vues

Nous disposions à ce stade de quatre familles de modèles, construites avec des réglages de départ raisonnables. Deux questions restaient ouvertes : peut-on améliorer ces modèles en réglant mieux leurs hyperparamètres ? Et, une fois chaque modèle réglé, lequel est le meilleur, avec quelle certitude ? Pour répondre à la seconde, nous avons utilisé pour la première et unique fois l'ensemble de test mis de côté au début de l'étude.

9.1 La recherche aléatoire des hyperparamètres

Un modèle a deux sortes de réglages. Les *paramètres* sont appris à partir des données par l'algorithme lui-même : coefficients d'une régression, valeurs des feuilles d'un arbre, poids d'un réseau. Les *hyperparamètres* sont fixés avant l'apprentissage et en déterminent la forme ou l'intensité : taux d'apprentissage, nombre de feuilles, pénalité, architecture d'un réseau, taux de dropout. Ils règlent surtout la complexité du modèle, c'est-à-dire le compromis entre biais et variance, et ne peuvent pas être appris en minimisant l'erreur d'apprentissage, qui choisirait toujours le modèle le plus complexe. On les choisit donc en minimisant une estimation de l'erreur sur des données non vues, ici la RMSE de validation croisée par lieux.

La recherche sur grille essaie toutes les combinaisons d'un ensemble de valeurs fixé pour chaque hyperparamètre. Avec q hyperparamètres et k valeurs chacun, il faut k^q évaluations : 5 valeurs pour 7 hyperparamètres demandent déjà $5^7 = 78\,125$ validations croisées. La recherche aléatoire tire au hasard N configurations dans l'espace de recherche. Bergstra et Bengio (2012) ont montré qu'à budget égal elle explore mieux qu'une grille, pour une raison simple : en pratique, seuls quelques hyperparamètres comptent vraiment, et l'on ne sait pas d'avance lesquels. Une grille de N points n'essaie que $N^{1/q}$ valeurs distinctes de chaque hyperparamètre, alors qu'un tirage aléatoire en essaie N de chacun. Elle offre de plus une garantie simple. Appelons « bonne » une configuration située dans les 5 % meilleures de l'espace de recherche. Chaque tirage a une probabilité 0,05 d'en être une, donc la probabilité qu'au moins un des N tirages soit bon vaut $1 - 0{,}95^N$, qui dépasse 95 % dès $N = 60$, quelle que soit la dimension de l'espace. Avec nos budgets, 16 tirages donnent une probabilité de 56 % d'atteindre les 5 % meilleures configurations, et de 81 % d'atteindre les 10 % meilleures.

Chaque hyperparamètre est tiré selon une loi adaptée à sa nature. Pour les paramètres d'échelle, comme les taux d'apprentissage et les pénalités, dont l'effet dépend de l'ordre de grandeur plutôt que de la valeur absolue, nous utilisons une loi *log-uniforme* : on tire U uniformément sur $[\ln a\,;\,\ln b]$ et l'on prend $x = e^U$. La densité de x est alors $1/\big(x\ln(b/a)\big)$ sur $[a\,;\,b]$, et

$$\mathbb{P}(x \le c) = \frac{\ln(c/a)}{\ln(b/a)},$$

si bien que chaque ordre de grandeur reçoit la même probabilité : sur $[0{,}001\,;\,0{,}1]$, $\mathbb{P}(x < 0{,}01) = 1/2$. Avec une loi uniforme sur $[0{,}01\,;\,0{,}1]$ au contraire, 56 % des tirages tomberaient au-dessus de 0,05 et 11 % seulement sous 0,02 : les petites valeurs, souvent les meilleures, ne seraient presque jamais essayées. Les proportions suivent une loi uniforme, les effectifs une loi uniforme sur les entiers, et les options discrètes un choix uniforme dans une liste.

Pour le gradient boosting, 16 configurations ont été tirées, chacune évaluée sur les cinq plis avec la contrainte de monotonie et un nombre d'arbres choisi par la courbe moyenne : taux d'apprentissage log-uniforme entre 0,02 et 0,1, nombre de feuilles entre 4 et 48, effectif minimal par feuille entre 20 et 250, pénalité λ log-uniforme entre 0,1 et 50, fractions de variables et de lignes uniformes entre 0,5 et 1, et gain minimal κ parmi 0, 0,001 et 0,01. Pour le réseau, plus coûteux, 5 configurations ont été évaluées sur trois plis : architecture parmi une couche de 32 neurones, deux couches de 64 et 32 ou de 128 et 64, et trois couches de 64, 64 et 32 ; dropout uniforme entre 0 et 0,3 ; taux d'apprentissage log-uniforme entre $3 \cdot 10^{-4}$ et $3 \cdot 10^{-3}$; weight decay log-uniforme entre 10^{-5} et $3 \cdot 10^{-2}$; dimension des embeddings parmi 2, 4 et 8 ; mini-lots de 128 ou 256.

Choisir la meilleure de N configurations sur la RMSE de validation croisée introduit un *biais de sélection*. Chaque RMSE estimée contient une part de bruit, et la configuration retenue est celle dont l'estimation est la plus basse, ce qui favorise celles dont le bruit a été favorable :

$$\mathbb{E}\Big[\min_{k \le N} \widehat{\mathrm{RMSE}}_k\Big] \le \min_{k \le N} \mathbb{E}\big[\widehat{\mathrm{RMSE}}_k\big].$$

C'est la même inégalité que pour le choix du nombre d'arbres, à l'échelle de la configuration entière. Dans le cas le plus simple, où N configurations auraient la même erreur réelle et des erreurs d'estimation indépendantes de même écart-type s, la plus favorable serait en moyenne inférieure de $1{,}8\,s$ à l'erreur réelle pour $N = 16$: c'est l'espérance du maximum de 16 variables normales centrées réduites, qui croît comme $\sqrt{2 \ln N}$. En pratique l'effet est plus faible, car toutes les configurations sont évaluées sur les mêmes plis et leurs erreurs d'estimation sont fortement corrélées. Le score de validation croisée du gagnant reste néanmoins optimiste, et c'est le rôle de l'ensemble de test que de le corriger.

Pour le gradient boosting, la surface explorée s'est révélée être un plateau. Les six meilleures configurations tiennent en 0,005 de RMSE alors que leurs hyperparamètres sont très différents, avec des taux d'apprentissage de 0,02 à 0,06 et de 31 à 159 arbres : la valeur précise des hyperparamètres compte très peu, ce qui est exactement la situation décrite par Bergstra et Bengio (2012). La meilleure configuration tirée (taux de 0,020, 21 feuilles, au moins 218 performances par feuille, $\lambda = 0{,}12$, 86 % des variables et 59 % des lignes par arbre, 159 arbres) obtient 3,0278, un peu moins bien que le réglage de départ (3,0169). Ce réglage appartient pourtant à l'espace de recherche, mais aucun des seize tirages n'est tombé dans une région aussi bonne, ce qui n'a rien de surprenant avec une chance sur deux d'atteindre les 5 % meilleures configurations ; l'écart, de 0,011, est de toute façon sans conséquence pratique, et nous avons conservé la configuration tirée. Une tendance nette se dégage : cinq des six meilleures configurations exigent au moins 129 performances par feuille. Une feuille aussi peuplée ne peut isoler ni une course ni même un petit lieu : ces arbres sont fortement régularisés, ce qui confirme que le signal transposable est lisse. Le même réglage sans contrainte de monotonie obtient enfin 3,0335 avec 130 arbres : la contrainte ne coûte toujours rien.

Pour le réseau, les cinq configurations tiennent en 0,018, avec des architectures aussi différentes qu'une seule couche de 32 neurones et trois couches de 64, 64 et 32. La configuration la moins régularisée (dropout de 0,08, sans weight decay) est la dernière, et la meilleure, de RMSE 2,922 sur trois plis, a le dropout le plus fort : trois couches de 64, 64 et 32 neurones, dropout de 0,27, taux d'apprentissage de $1{,}2 \cdot 10^{-3}$, weight decay de $3{,}4 \cdot 10^{-3}$, embeddings de dimension 4, mini-lots de 256 et 14 époques. Le taux d'apprentissage et le nombre d'époques vont de pair : avec un taux de 3 à $4 \cdot 10^{-4}$, il faut 24 à 58 époques pour atteindre le minimum. Sur les mêmes plis, le ridge obtenait 2,936 à 2,938 : l'avance du meilleur réseau, de 0,015, est très inférieure à l'erreur type, et en partie l'effet du biais de sélection. Le réseau final moyenne cinq réseaux de ce réglage.

9.2 L'évaluation finale

Tous les modèles ont été réentraînés sur l'ensemble des 79 lieux d'apprentissage, avec les hyperparamètres choisis par validation croisée, puis évalués une seule fois sur les 21 lieux de test (2 355 performances, 102 courses). Cette évaluation est honnête parce qu'aucun choix n'a été fait en regardant le test. Neuf modèles sont comparés : le modèle constant ; les moyennes par épreuve et sexe ; les moindres carrés sur le WBGT seul ; le meilleur ridge complet, avec terme de Mundlak ; le modèle à intercept aléatoire de course retenu par la règle d'un écart-type ; le gradient boosting réglé, avec et sans contrainte de monotonie ; l'ensemble de cinq réseaux ; et un *ensemble* qui moyenne les prédictions du modèle mixte, du boosting monotone et des réseaux.

L'idée de ce dernier ensemble repose sur une inégalité de convexité. Si e_1, e_2, e_3 sont les erreurs de trois modèles sur une performance, l'erreur de leur moyenne est la moyenne des erreurs, et $\left(\frac{e_1+e_2+e_3}{3}\right)^2 \le \frac{e_1^2+e_2^2+e_3^2}{3}$; en moyennant sur les performances,

$$\mathrm{MSE}(\text{ensemble}) \le \frac{\mathrm{MSE}_1 + \mathrm{MSE}_2 + \mathrm{MSE}_3}{3}.$$

L'ensemble fait toujours au moins aussi bien que la moyenne de ses membres, et d'autant mieux que leurs erreurs sont peu corrélées. Des modèles de familles différentes se trompent a priori de façons différentes.

Avec 21 lieux seulement, la RMSE de test est elle-même incertaine : un autre tirage de lieux de test donnerait une autre valeur. Pour quantifier cette incertitude, nous utilisons le *bootstrap* (Efron, 1979). On voudrait connaître la distribution d'une statistique sur des échantillons tirés de la population, mais on ne dispose que d'un échantillon. L'idée du bootstrap est de remplacer la population par l'échantillon lui-même : on tire avec remise, dans l'échantillon, de nouveaux échantillons de même taille, et l'on recalcule la statistique sur chacun. La dispersion des B valeurs obtenues imite celle qu'on observerait sur de vrais nouveaux échantillons, et l'intervalle de confiance percentile à 95 % est formé des quantiles d'ordre 0,025 et 0,975 des B répliques. Nous prenons $B = 2\,000$: un quantile d'ordre 0,025 est alors estimé à partir des 50 répliques les plus extrêmes, ce qui le rend stable.

Le bootstrap suppose cependant que les unités rééchantillonnées sont indépendantes. Les erreurs de prédiction d'une même course, et même d'un même lieu, étant corrélées, rééchantillonner les performances une à une sous-estimerait l'incertitude, exactement comme les erreurs types naïves. Nous rééchantillonnons donc les *lieux* : on tire 21 lieux avec remise parmi les 21 lieux de test, on réunit toutes leurs performances, et l'on recalcule la RMSE. L'unité de rééchantillonnage est ainsi la même que l'unité de regroupement de la validation. Pour comparer deux modèles A et B, enfin, on ne compare pas leurs deux intervalles : on calcule la différence de leurs RMSE sur chacune des mêmes répliques, puis l'intervalle de cette différence. C'est beaucoup plus précis, car

$$\operatorname{Var}(R_A - R_B) = \operatorname{Var}(R_A) + \operatorname{Var}(R_B) - 2\,\operatorname{Cov}(R_A, R_B),$$

et la covariance est fortement positive : un lieu difficile à prédire augmente l'erreur de tous les modèles à la fois. Si l'intervalle de la différence exclut 0, l'écart est significatif au seuil de 5 %. Le modèle constant sert de référence (tableau 2).

Tableau 2 : Évaluation finale sur les 21 lieux de test (2 355 performances). Intervalles de confiance à 95 % par bootstrap des lieux ($B = 2\,000$) ; l'écart au modèle constant est calculé réplique par réplique.

Modèle	RMSE	IC 95 %	Écart au constant	IC 95 % de l'écart	R^2	MAE
ensemble (mixte, boosting, réseaux)	2,877	[2,50 ; 3,27]	−0,314	[−0,52 ; −0,17]	0,172	2,136
mixte (intercept de course)	2,896	[2,52 ; 3,29]	−0,295	[−0,51 ; −0,14]	0,162	2,149
boosting monotone	2,898	[2,52 ; 3,29]	−0,294	[−0,49 ; −0,16]	0,161	2,151
réseaux (ensemble de 5)	2,902	[2,51 ; 3,30]	−0,289	[−0,50 ; −0,14]	0,158	2,160
boosting libre	2,902	[2,52 ; 3,30]	−0,289	[−0,47 ; −0,16]	0,158	2,155
ridge complet avec Mundlak	2,944	[2,49 ; 3,41]	−0,247	[−0,53 ; −0,11]	0,133	2,214
moindres carrés sur le WBGT	3,142	[2,73 ; 3,61]	−0,050	[−0,14 ; +0,05]	0,013	2,383
constant	3,191	[2,70 ; 3,71]	0	–	−0,018	2,422
moyennes par épreuve et sexe	3,305	[2,78 ; 3,86]	+0,113	[−0,03 ; +0,22]	−0,092	2,501

Les modèles qui utilisent le profil des athlètes battent nettement le modèle constant : ils réduisent la RMSE de 0,25 à 0,31 point, et tous les intervalles de ces écarts excluent 0. Leur R^2 de test va de 0,13 à 0,17 : environ un sixième de la variance des performances est prévisible sur un lieu jamais vu. Le reste, forme du jour, tactique, ancienneté du record, ne l'est pas. Les modèles naïfs, eux, ne font pas mieux que la constante. Le WBGT seul gagne 0,05 point, avec un intervalle qui contient 0 : la chaleur, prise seule, ne prédit pas la performance. Les moyennes par épreuve et sexe font même moins bien que la constante, comme en validation croisée.

L'ordre entre les meilleurs modèles n'est pas établi. Cinq modèles tiennent en 0,025 de RMSE, et le modèle mixte, les deux boostings et les réseaux en 0,006 ; leurs écarts au modèle constant ont des intervalles qui se chevauchent presque entièrement. Les familles de modèles sont équivalentes en prédiction. Un renversement mérite toutefois d'être noté : le ridge, légèrement meilleur en validation croisée, est le moins bon des modèles avec contrôles sur le test, alors que le modèle mixte, légèrement moins bon en validation croisée, est parmi les meilleurs. Le ridge retenu est un polynôme de degré 3 avec interactions, choisi par la plus petite RMSE, alors que le modèle mixte est de degré 1, choisi par la règle d'un écart-type. Ce renversement va dans le sens de notre crainte : un modèle plus complexe, choisi sur des écarts non significatifs, se transpose moins bien à de nouveaux lieux. L'écart entre les deux, de 0,048, reste cependant trop faible pour le prouver.

L'ensemble est le meilleur modèle, mais gagne peu. Conformément à l'inégalité de convexité, son erreur quadratique est

inférieure à la moyenne de celles de ses trois membres :

$$2{,}877^2 = 8{,}28 \;<\; \tfrac{1}{3}\big(2{,}896^2 + 2{,}898^2 + 2{,}902^2\big) = 8{,}40.$$

Le gain n'est pourtant que de 1,5 %, parce que les trois modèles se trompent presque toujours dans le même sens sur les mêmes performances : la corrélation entre leurs erreurs est de 0,97 à 0,99. Ce qu'ils ne savent pas prédire, la forme du jour, aucun d'eux ne le sait. De même, les cinq réseaux de l'ensemble ont, pris séparément, des RMSE de test de 2,89 à 2,92 : moyenner les graines ne rend pas le réseau meilleur que son meilleur membre, mais évite de dépendre d'une graine malchanceuse.

Les intervalles sont larges : celui de la RMSE de l'ensemble va de 2,50 à 3,27. Il n'y a que 21 lieux, et quelques-uns pèsent très lourd : Portland compte à lui seul 686 performances (29 % du test) et Valencia 415 (18 %). Selon que ces lieux sont tirés zéro, une ou deux fois dans une réplique, la RMSE change beaucoup. L'intervalle de l'écart au modèle constant est deux fois plus étroit, parce que la différence élimine la part commune de difficulté. On remarque enfin que les RMSE de test sont inférieures à celles de validation croisée (2,88 à 2,94 contre 2,99 à 3,03 pour les modèles avec contrôles, 3,19 contre 3,30 pour la constante) : les lieux de test sont un peu moins hétérogènes que la moyenne des plis, et ce sont les écarts entre modèles qu'il faut comparer, non les niveaux absolus.

Ce bilan a orienté toute la suite du travail. En prédiction, les quatre familles de modèles se valent : un modèle linéaire mixte de degré 1 fait aussi bien qu'un boosting réglé ou qu'un ensemble de réseaux. Le choix du modèle de l'outil ne pouvait donc pas se faire sur la précision des prédictions. Il devait se faire sur la qualité de l'estimation de l'effet de la chaleur : lisibilité de la courbe de dégradation, absence de biais et incertitude honnête.

10 Ce que les modèles ont appris de la chaleur

L'outil n'a pas besoin de la meilleure prédiction d'un chrono, mais d'une estimation fiable de l'*effet* des conditions météorologiques. Puisque les modèles se valent en prédiction, nous les avons ouverts pour voir ce qu'ils ont appris. Cette étape a fait apparaître le résultat le plus important de l'étude : des modèles de précision identique racontent des histoires différentes sur la chaleur.

10.1 Attribuer une prédiction aux variables : les valeurs de Shapley

Pour un modèle linéaire, la contribution d'une variable à une prédiction se lit directement : c'est le produit de son coefficient par sa valeur. Pour un boosting de 159 arbres, il n'existe rien de tel, puisqu'une même variable intervient dans des centaines de coupures, en interaction avec les autres. La théorie des jeux coopératifs répond pourtant à une question analogue : comment répartir équitablement le gain d'une coalition entre ses joueurs, quand l'apport de chacun dépend des autres (Shapley, 1953) ? Les « joueurs » sont ici les p variables, et le « gain » est la prédiction. Pour une performance x, notons $v(S) = \mathbb{E}\big[f(X) \mid X_S = x_S\big]$ la prédiction attendue quand on ne connaît que les variables de l'ensemble S, les autres étant remplacées par leur distribution dans les données ; $v(\varnothing) = \mathbb{E}[f(X)]$ est la prédiction moyenne et $v(\{1,\dots,p\}) = f(x)$ la prédiction complète. La *valeur de Shapley* de la variable j est

$$\phi_j(x) = \sum_{S \subseteq \{1,\dots,p\}\setminus\{j\}} \frac{|S|!\,(p-|S|-1)!}{p!}\,\big[v(S\cup\{j\}) - v(S)\big]. \tag{19}$$

La différence $v(S\cup\{j\})-v(S)$ est l'apport marginal de j quand il rejoint l'ensemble S. Le coefficient $|S|!\,(p-|S|-1)!/p!$ est la probabilité que, dans un ordre d'arrivée des variables tiré au hasard parmi les $p!$ ordres possibles, les variables arrivées avant j soient exactement celles de S. La valeur de Shapley est donc l'apport marginal de j moyenné sur tous les ordres d'arrivée : aucun ordre n'est privilégié. Avec deux variables, par exemple, $\phi_1(x) = \tfrac{1}{2}\big[v(\{1\}) - v(\varnothing)\big] + \tfrac{1}{2}\big[v(\{1,2\}) - v(\{2\})\big]$ est la moyenne de l'apport de la variable 1 quand elle arrive en premier et quand elle arrive en second. Les valeurs de Shapley sont l'unique répartition qui vérifie quatre propriétés : l'efficacité, $f(x) = \phi_0 + \sum_j \phi_j(x)$ avec $\phi_0 = \mathbb{E}[f(X)]$, qui décompose exactement la prédiction ; la symétrie, qui donne la même contribution à deux variables jouant le même rôle ; la nullité de la contribution d'une variable qui ne change jamais la prédiction ; et l'additivité, qui fait s'additionner les contributions d'une somme de modèles, comme un boosting. La formule demande 2^{p-1} termes par variable, mais pour les arbres, l'algorithme TreeSHAP calcule les valeurs exactes en temps polynomial (Lundberg et Lee, 2017 ; Lundberg et al., 2020). Nous l'avons appliqué au boosting monotone, sur les lieux de test.

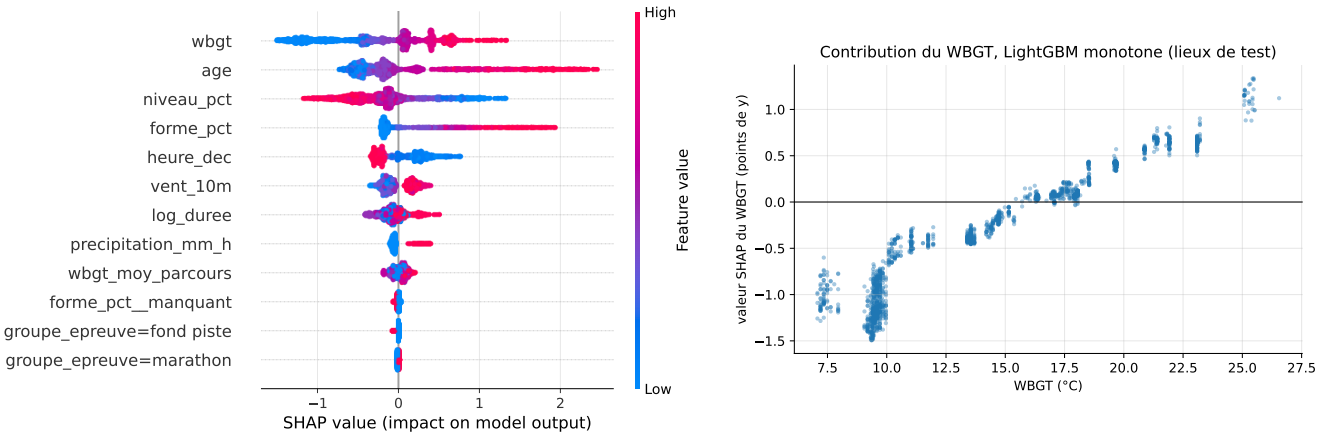


Figure 8 : Valeurs de Shapley du boosting monotone sur les lieux de test. À gauche, une ligne par variable et un point par performance, coloré selon la valeur de la variable (`niveau_pct` : niveau ; `heure_dec` : heure de départ ; `log_duree` : logarithme de la durée attendue ; `wbgt_moy_parcours` : WBGT moyen du parcours). À droite, contribution du WBGT selon sa valeur.

L'importance globale d'une variable est la moyenne de $|\phi_j|$ sur les performances, en points de y. Le WBGT est la variable la plus importante du modèle, avec une contribution moyenne de 0,55 point, devant l'âge (0,50), le niveau (0,39), la forme (0,29), l'heure (0,24), le vent (0,16), la durée attendue (0,13), la pluie (0,07) et le WBGT moyen du parcours (0,07) ; les indicatrices de groupe d'épreuves reçoivent des contributions quasi nulles (figure 8). La contribution du WBGT croît, en marches, de −1,4 point vers 9,5 °C à +1,2 point vers 25 °C. Les points y forment des bandes verticales, chaque bande correspondant à une course dont tous les coureurs partagent le même WBGT ; et les contributions sont mesurées par rapport à la prédiction moyenne ϕ_0, et non par rapport au WBGT de référence. Le sens des effets est celui attendu : un WBGT élevé, un âge élevé, une forme éloignée du record, un vent fort, la pluie et une longue durée ralentissent par rapport au record. Une heure tardive est associée à des performances plus proches du record, car les réunions de piste du soir offrent pistes rapides et lièvres. Un athlète plus lent que la médiane de son épreuve court aussi plus près de son record ; plusieurs explications sont possibles, comme un record moins exceptionnel ou la sélection par la marge de troncature, et le modèle ne permet pas de les départager.

Ce résultat semble contredire celui de la section 7.5, où retirer toutes les variables météorologiques ne dégradait pas la RMSE. Les deux sont compatibles. Le WBGT est très lié au groupe d'épreuves et à l'heure : quand il est présent, une partie de l'information qu'il porte pourrait aussi l'être par ces variables, et la valeur de Shapley lui en attribue le crédit ; quand il est absent, l'heure, la durée et le groupe prennent le relais. Une forte valeur de Shapley ne signifie ni qu'une variable est indispensable à la prédiction, ni qu'elle a un effet causal : elle décrit le modèle, pas le monde. Pour mesurer l'effet de la chaleur à profil d'athlète donné, il fallait un autre outil.

10.2 Dépendance partielle et courbe de dégradation

La *dépendance partielle* d'un modèle f en une variable v (Friedman, 2001) est la fonction

$$\mathrm{PD}_v(\xi) = \frac{1}{n}\sum_{i=1}^{n} f\big(x_i \text{ avec } x_{i,v} = \xi\big) :$$

pour chaque valeur ξ, on impose $x_{i,v} = \xi$ à toutes les performances, les autres variables gardant leurs valeurs observées, et l'on moyenne les prédictions. C'est la réponse à la question : « que prédirait le modèle, en moyenne sur nos athlètes et nos courses, si la variable v valait ξ pour tout le monde ? » Contrairement à la moyenne de y par classe de WBGT, qui compare des courses différentes, la dépendance partielle compare les mêmes performances sous deux valeurs de la variable : la composition des épreuves, l'âge et le niveau sont identiques d'une valeur à l'autre, ce qui neutralise le paradoxe de Simpson au sein du modèle. Avant la moyenne, chaque performance i a sa propre courbe $\xi \mapsto f(x_i \text{ avec } x_{i,v} = \xi)$, dite courbe ICE (Goldstein et al., 2015). Leur dispersion renseigne sur les interactions : si toutes les courbes ICE sont parallèles, l'effet de v est le même pour toutes les performances ; si elles divergent, il dépend des autres variables.

La courbe de dégradation est la dépendance partielle en WBGT, recentrée sur la référence :

$$\Delta(W) = \mathrm{PD}_{\mathrm{WBGT}}(W) - \mathrm{PD}_{\mathrm{WBGT}}(W_{\mathrm{ref}}), \tag{20}$$

en points de y, c'est-à-dire approximativement en pourcentage de vitesse. C'est exactement la quantité dont l'outil a besoin (4) : la dégradation moyenne de la performance quand le WBGT passe de 15 °C à W, à profil d'athlète inchangé. Pour un modèle linéaire de degré 1 sans interaction, toutes les courbes ICE sont des droites parallèles et $\Delta(W) = \beta_W\,(W - W_{\text{ref}})$. Si le modèle contient le terme de Mundlak $\bar{W}_g$, on ne le modifie pas : on mesure l'effet d'un changement de WBGT sur un parcours donné, c'est-à-dire l'effet intra-parcours. Deux précautions s'imposent à la lecture. Aux extrémités de la grille, peu de performances ont été observées, et la courbe y repose sur très peu de courses ou prolonge simplement la forme du modèle; nos figures grisent les 2,5 % extrêmes des données de chaque côté. Et imposer un WBGT de 27 °C à une course courue au petit matin d'hiver crée des combinaisons qui n'existent pas dans les données : la dépendance partielle reste une description du modèle, dont l'interprétation causale repose sur les contrôles inclus et sur l'absence de facteur confondant omis.

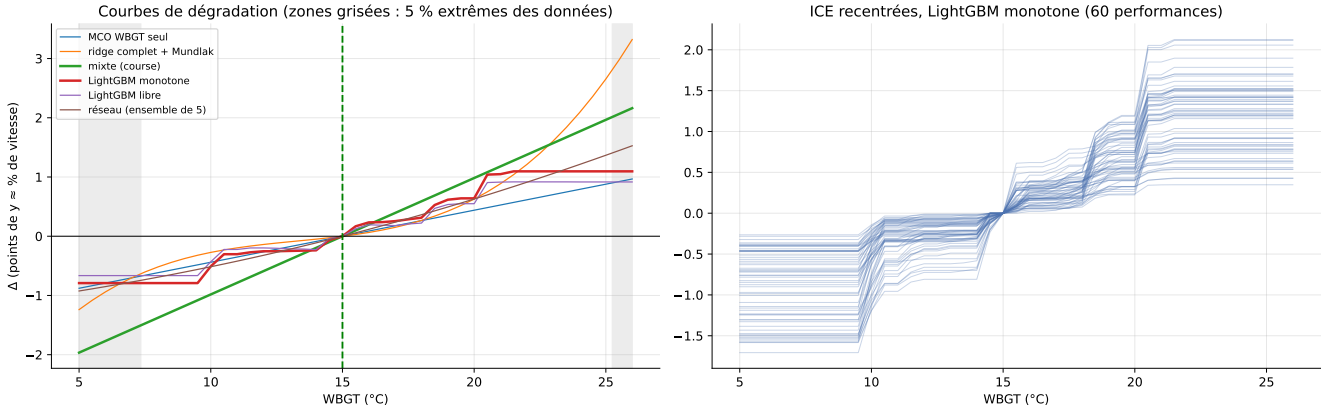


Figure 9 : À gauche, courbes de dégradation $\Delta(W)$ de six modèles, moyennées sur les performances d'apprentissage, toutes épreuves confondues; les zones grisées couvrent les 2,5 % extrêmes des données de chaque côté. À droite, courbes ICE recentrées du boosting monotone pour 60 performances tirées au hasard.

Les courbes de dégradation des six modèles ont toutes le même sens : plus chaud, plus lent (figure 9). Mais leur amplitude et leur forme diffèrent nettement au-delà de 20 °C. À 25 °C, la dégradation vaut environ +0,9 point pour les moindres carrés sur le WBGT seul, qui ne contrôlent aucun facteur confondant; +1,1 pour les deux boostings, dont la courbe en marches devient constante au-delà de 21 °C environ; +1,4 pour l'ensemble de réseaux, dont la courbe est lisse et presque linéaire; +1,9 pour le modèle mixte, dont la courbe est une droite; et +2,6 pour le ridge complet, dont le polynôme de degré 3 est convexe. Les arbres plafonnent : au-delà du dernier seuil appris sur le WBGT, faute de courses chaudes en nombre suffisant, ils prédisent la même chose quel que soit le WBGT. Le polynôme de degré 3, à l'inverse, s'envole : sa courbure est portée par les quelques courses les plus chaudes, et dépasse 3 points dans la zone grisée, où les données manquent. Côté frais, tous les modèles prédisent une performance plus rapide qu'à 15 °C, avec un écart entre eux qui se creuse sous 7,5 °C, de −0,8 à −1,9 point à 5 °C. Les courbes ICE du boosting, enfin, sont loin d'être parallèles : à 25 °C, la dégradation va d'environ +0,4 à +2,1 points selon la performance. L'effet de la chaleur dépend donc des autres variables, épreuve, durée ou heure, ce qui justifie d'estimer un effet par groupe d'épreuves. Les marches, situées vers 10, 14,5, 18,5 et 20,5 °C, sont les seuils de coupure des arbres, communs à toutes les performances.

Nous étions donc face à un constat embarrassant : cinq modèles de précision indiscernable donnent, pour une hausse de 10 °C, des effets allant du simple au triple. La précision prédictive ne permet pas de choisir entre eux; c'est la forme qu'ils imposent ou n'imposent pas à la courbe qui fait la différence. Il fallait choisir le modèle de l'outil sur d'autres critères, et mesurer l'incertitude de sa courbe.

10.3 Incertitude sur la courbe : le bootstrap des lieux

Pour l'outil, les modèles sont désormais réentraînés sur tous les lieux, apprentissage et test réunis. Le test a déjà servi à l'évaluation, et il n'y a plus aucun choix à faire en le regardant : l'utiliser pour estimer l'effet ne crée aucune fuite, et 21 lieux de plus améliorent la précision.

L'incertitude sur $\Delta(W)$ vient surtout du petit nombre de lieux et de courses : chaque course n'apporte qu'une situation météorologique, et les courses chaudes sont rares. Nous l'estimons par un bootstrap des lieux, mais cette fois en réentraînant le modèle sur chaque réplique. On tire avec remise autant de lieux qu'il y en a dans les données, on réunit toutes leurs

performances et l'on réentraîne le modèle sur cet échantillon, puis on calcule la courbe de dégradation du modèle réentraîné sur une population de référence fixe ; après B répétitions, on prend, point par point de la grille, les quantiles d'ordre 0,025 et 0,975 des B courbes. On obtient une bande de confiance *ponctuelle* à 95 % : pour chaque valeur de WBGT, l'intervalle contient la vraie valeur de la courbe avec une probabilité d'environ 95 %. Ce n'est pas une bande *simultanée*, et la probabilité que la courbe entière reste dans la bande est plus faible. Ce bootstrap mesure l'incertitude due à l'échantillon de lieux, y compris la variabilité de l'estimation de tous les coefficients, mais pas celle due à un mauvais choix de forme du modèle.

Deux précautions sont essentielles. La courbe est toujours calculée sur la même population de référence, et non sur l'échantillon bootstrap, dont la composition change à chaque réplique : sinon, la variabilité mesurée mélangerait celle du modèle et celle de la population sur laquelle on moyenne. Et chaque copie d'un lieu tiré plusieurs fois doit devenir un lieu distinct, avec ses propres courses. Sans cette précaution, les courses d'un lieu tiré deux fois deviendraient des courses de taille double, faites de paires de lignes identiques : un modèle mixte y verrait une variance intra-course artificiellement faible et pourrait estimer $\gamma \to \infty$, avec des effets aberrants. Dans la logique du bootstrap, chaque tirage représente d'ailleurs un nouveau lieu de la population.

10.4 Le modèle retenu pour l'outil

Pour l'outil, ce qui compte est l'effet des conditions : estimé avec le moins de biais possible, assorti d'une incertitude honnête, lisible par épreuve, et sans extrapolation fantaisiste. Nous avons retenu un modèle linéaire à intercept aléatoire de course, dont les termes sont choisis a priori d'après la physiologie et la littérature. Pour la performance j de la course g,

$$y_{gj} = u_g + \sum_e \mathbb{1}_e P_e(W_{gj}) + \beta_{W,\text{niv}} \frac{\text{niveau}_{gj}}{10} (W_{gj} - W_{\text{ref}}) + \sum_e \mathbb{1}_e \beta_{\text{alt},e} \, \text{alt}_g + \beta_{\text{vent}} \, \text{vent}_{gj} + \beta_{\text{pluie}} \, \text{pluie}_{gj} + x_{gj}^{\top} \beta + \varepsilon_{gj}, \quad (21)$$

avec $u_g \sim \mathcal{N}(0, \tau^2)$ et $\varepsilon_{gj} \sim \mathcal{N}(0, \sigma^2)$. Le terme P_e est un polynôme du WBGT propre à chaque groupe d'épreuves e, et $\mathbb{1}_e$ vaut 1 pour les performances du groupe e : l'effet de la chaleur peut ainsi croître avec la durée de l'effort. Les polynômes s'écrivent dans la base $\psi(W)$, nulle en W_{ref}, et leur degré est choisi par validation croisée par lieux. Le terme $\beta_{W,\text{niv}}$ multiplie l'écart de WBGT à la référence par le niveau de l'athlète, en dizaines de points : il teste le résultat de Ely et al. (2007), selon lequel les coureurs lents sont plus affectés par la chaleur. L'altitude au-delà de 500 m, alt_g, a une pente propre à chaque groupe ; les pistes de nos données étant toutes sous 300 m, son coefficient est nul pour les deux groupes de piste, et l'outil refusera toute altitude supérieure à celle observée pour le groupe. Les contrôles x_{gj} regroupent l'âge, la forme, l'heure, la durée attendue, le niveau, le sexe et le groupe d'épreuves. Nous n'avons pas inclus de terme de Mundlak : avec un effet propre à chaque groupe, il faudrait une moyenne de parcours par groupe, et nous avons vu que l'effet intra-parcours n'est pas plus faible que l'effet estimé sans distinction.

Ce choix écarte les deux autres candidats sérieux. La courbe du boosting monotone est contrainte à être croissante : si l'effet réel est nul, elle est biaisée vers le haut, et son intervalle bootstrap ne peut pas contenir de valeurs négatives au-dessus de la référence ; elle est aussi en marches, et plafonne au-delà des derniers seuils appris. La courbe du réseau est lisse, mais elle ne se décompose pas par épreuve, et son incertitude demanderait de réentraîner des ensembles de réseaux des centaines de fois. Le modèle linéaire mixte donne une courbe lisse, propre à chaque épreuve, dont chaque terme a une interprétation et un intervalle de confiance.

La validation croisée par lieux donne une RMSE de 3,024 pour un effet linéaire du WBGT dans chaque groupe, 3,028 en degré 2 et 3,042 en degré 3 : le degré 1 est retenu, les données ne permettant pas d'estimer une courbure propre à chaque groupe, et la règle d'un écart-type aurait fait le même choix.

Une difficulté inattendue : la vraisemblance REML est bimodale. En estimant ce modèle, nous avons constaté que la log-vraisemblance restreinte profilée $\ell_R(\gamma)$ n'a pas toujours un seul maximum. Outre le maximum intérieur, elle peut remonter vers la borne $\gamma \to \infty$, qui correspond aux effets fixes de course (figure 10). La cause principale est l'hétéroscédasticité : l'écart-type de y au sein d'une course vaut environ 1,9 point en demi-fond et 3,6 au marathon, alors que le modèle suppose un σ^2 commun. En traitant chaque course comme un effet fixe, le modèle absorbe une partie de cette hétérogénéité dans les moyennes de course, ce que la vraisemblance peut récompenser. Sur l'échantillon complet, le maximum intérieur est atteint en $\ln \hat{\gamma} = -2{,}12$, soit $\hat{\gamma} = 0{,}120$, avec $\hat{\tau}^2 = 0{,}945$ et $\hat{\sigma}^2 = 7{,}873$: la course explique 11 % de la variance résiduelle. La vraisemblance descend ensuite jusqu'à environ $-16\,585$ vers $\ln \gamma \approx 2{,}8$, puis remonte jusqu'à $-16\,396$ à la borne

$\ln\gamma = 6$; le maximum intérieur (−16 192) l'emporte de plus de 200 unités de log-vraisemblance. Mais dans une réplique bootstrap, la borne pourrait l'emporter : les variables de niveau course (WBGT, altitude, groupe d'épreuves) ne seraient alors plus identifiées que par l'infime variation qui subsiste au sein des courses, et leurs effets deviendraient aberrants.

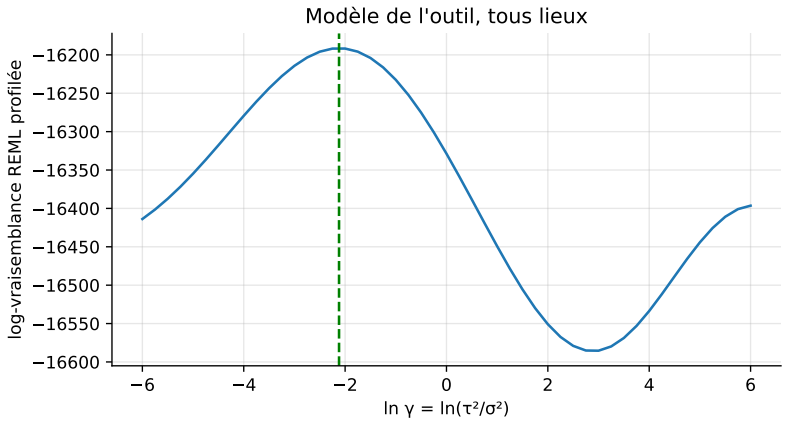


Figure 10 : Log-vraisemblance restreinte profilée du modèle de l'outil, estimé sur tous les lieux, en fonction de $\ln\gamma$. La ligne pointillée marque le maximum intérieur, en $\ln\hat{\gamma} = -2{,}12$; la remontée vers la borne droite correspond aux effets fixes de course.

Nous avons résolu cette difficulté en fixant γ à sa valeur estimée sur l'échantillon complet, $\hat{\gamma}$, dans toutes les répliques. Chaque réplique calcule alors un estimateur des moindres carrés généralisés avec une matrice de covariance *de travail* $V = V(\hat{\gamma})$ fixée, $\hat{\beta} = (X^{\top}V^{-1}X)^{-1}X^{\top}V^{-1}y$. Cet estimateur reste sans biais même si V n'est pas la vraie covariance : comme $\mathbb{E}[y] = X\beta$,

$$\mathbb{E}[\hat{\beta}] = (X^{\top}V^{-1}X)^{-1}X^{\top}V^{-1}X\beta = \beta,$$

quelle que soit la matrice V utilisée. Une matrice imparfaite ne coûte que de la précision. Sa variance n'est en revanche plus celle que donnerait la formule du modèle : si la vraie covariance est Σ, elle vaut

$$\mathrm{Var}(\hat{\beta}) = (X^{\top}V^{-1}X)^{-1}\,X^{\top}V^{-1}\,\Sigma\,V^{-1}X\,(X^{\top}V^{-1}X)^{-1},$$

la variance dite « sandwich », celle des équations d'estimation généralisées (Liang et Zeger, 1986). Le bootstrap des lieux estime cette variance sans avoir à connaître Σ : l'incertitude obtenue est robuste à une covariance mal spécifiée. Une alternative plus complète aurait consisté à estimer un σ^2 propre à chaque groupe d'épreuves.

L'effet de la chaleur par groupe d'épreuves. La dégradation $\Delta(W)$ est calculée séparément sur les performances de référence de chaque groupe, avec un intervalle obtenu par 300 répliques bootstrap (tableau 3 et figure 11). Les valeurs situées au-delà du centile 99 du WBGT observé pour le groupe sont signalées comme des extrapolations.

Tableau 3 : Dégradation Δ estimée par le modèle de l'outil depuis un WBGT de 15 °C, en points de y (approximativement en pourcentage de vitesse), avec intervalles de confiance à 95 % par bootstrap des lieux (300 répliques).

Groupe d'épreuves	WBGT de 20 °C	WBGT de 25 °C
demi-fond piste	+0,02 [−0,43 ; +0,35]	+0,04 [−0,86 ; +0,69]
fond piste	+0,41 [−0,01 ; +1,08]	+0,82 [−0,02 ; +2,17]
route courte	+0,76 [+0,24 ; +1,25]	+1,52 [+0,48 ; +2,51]
semi-marathon	+0,89 [+0,47 ; +1,34]	+1,78 [+0,93 ; +2,68] (extrapolé)
marathon	+1,57 [+1,16 ; +2,06]	+3,14 [+2,32 ; +4,12]

L'effet croît avec la durée de l'effort, comme le prévoit la physiologie : la chaleur stockée s'accumule et la dérive cardiovasculaire s'installe au fil de l'effort. Il est nul en demi-fond, où un 800 m ou un 1 500 m est trop court pour que la thermorégulation limite la performance ; l'intervalle, centré sur 0, exclut un effet supérieur à 0,7 point à 25 °C. Il vaut environ 0,8 point en fond sur piste, avec un intervalle qui touche 0, puis environ 1,5 point sur route courte. Il atteint environ 3 points au marathon entre 15 et 25 °C, soit environ 4 min 45 s sur un marathon couru en 2 h 30, l'ordre de grandeur rapporté par Ely et al. (2007). Le semi-marathon à 25 °C est une extrapolation, aucune course n'ayant été observée au-delà de 22 °C. Les

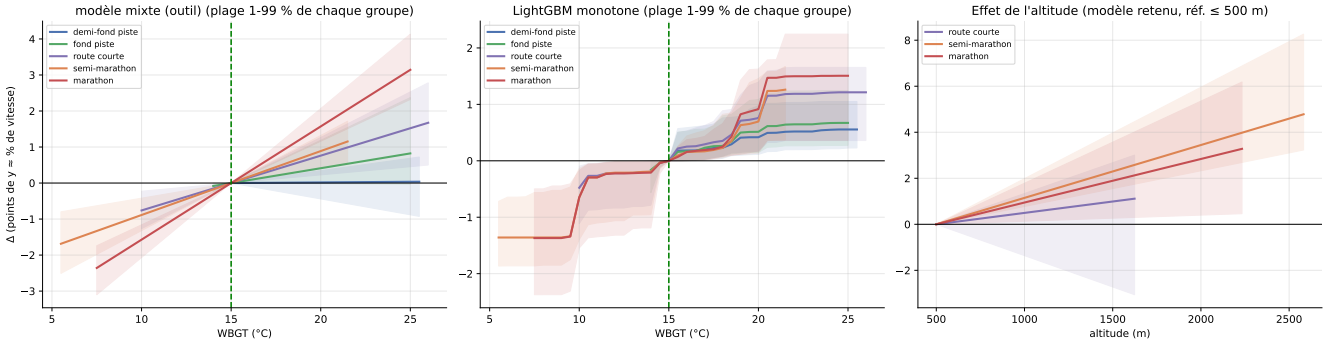


Figure 11 : Courbes de dégradation par groupe d'épreuves, sur la plage des centiles 1 à 99 du WBGT de chaque groupe, avec bandes de confiance ponctuelles à 95 % par bootstrap des lieux : modèle de l'outil (à gauche, 300 répliques) et boosting monotone (au centre, 50 répliques). À droite, effet de l'altitude estimé par le modèle de l'outil, par rapport à une altitude inférieure à 500 m.

effets étant linéaires, celui de 25 °C est le double de celui de 20 °C ; or les moyennes par classes suggéraient une accélération au-delà de 20 °C au marathon, si bien que le modèle peut sous-estimer légèrement l'effet vers 25 °C et le surestimer vers 18 à 20 °C. Pondéré par les effectifs des groupes, l'effet d'une hausse de 10 °C vaut environ 1,7 point, un peu moins que les estimations de la section 6.6 (1,9 à 2,4 points), obtenues sur les seuls lieux d'apprentissage avec un effet commun à toutes les épreuves, mais du même ordre de grandeur.

Les autres termes complètent le tableau. Le vent coûte 0,36 point pour 2 m/s de plus à 10 m (intervalle [0,08 ; 0,63]), à WBGT égal : son effet rafraîchissant passe déjà par le WBGT, et il reste l'effet mécanique, le vent de face n'étant pas compensé par le vent de dos. La pluie, trop rare, ne permet pas de conclure (+0,34 pour 1 mm/h, intervalle [−0,53 ; 2,00]). L'écart entre coureurs lents et rapides prédit par Ely et al. (2007) n'est pas détecté au marathon : pour une hausse de 10 °C, un coureur de niveau +10 perd 0,17 point de moins qu'un coureur de niveau −10, avec un intervalle [−1,24 ; 0,86] ; nos données ne contiennent que de bons coureurs, sur une plage de niveaux étroite. L'altitude, enfin, coûte à 1 500 m environ 1,9 point au marathon (intervalle [0,05 ; 3,65]) et 2,3 points au semi-marathon ([1,55 ; 4,48]), et reste indéterminée sur route courte (+0,99, intervalle [−2,95 ; 2,80]). Ces effets reposent sur 3 à 6 lieux par groupe, d'où la largeur des intervalles, et peuvent aussi refléter les parcours propres à ces villes.

Le boosting monotone, gardé comme point de comparaison, donne le même classement des épreuves et des valeurs proches jusqu'à 20 °C, mais il plafonne au-delà : environ +1,5 point au marathon à 25 °C, contre 3,1 pour le modèle mixte. La contrainte de monotonie a un autre effet, visible en demi-fond : sa courbe ne peut pas descendre sous 0 au-dessus de 15 °C, et monte jusqu'à environ +0,5 point avec un intervalle qui exclut 0, alors que le modèle mixte trouve un effet nul. C'est le biais annoncé : quand l'effet réel est nul, une courbe contrainte à monter ne peut que le surestimer. Les deux modèles s'accordent en revanche côté frais : au marathon, courir à 7 ou 8 °C plutôt qu'à 15 °C fait gagner de 1,4 à 2,4 points.

11 L'incertitude de prédiction

Deux incertitudes ne doivent pas être confondues. L'*intervalle de confiance* porte sur un paramètre ou un effet moyen, ici la courbe de dégradation $\Delta(W)$: il traduit l'imprécision due à la taille finie de l'échantillon, et se resserrerait jusqu'à zéro avec plus de lieux et de courses. L'*intervalle de prédiction* $\hat{I}(x) = [\hat{q}_{\text{bas}}(x) ; \hat{q}_{\text{haut}}(x)]$ porte sur une observation future : il doit contenir la performance y d'un athlète avec une probabilité $1 - \alpha$. Même avec un modèle parfait, connu sans erreur, il reste aussi large que le bruit individuel, et ne se resserre pas avec les données. Un outil honnête doit pouvoir dire les deux ; nous avons cherché à construire des intervalles de prédiction à 90 % ($\alpha = 0{,}1$).

11.1 Régression quantile et perte pinball

La moyenne minimise la perte quadratique et la médiane la perte absolue. Plus généralement, le quantile d'ordre α d'une variable Y, la valeur q telle que $\mathbb{P}(Y \le q) = \alpha$, minimise l'espérance de la *perte pinball*

$$\rho_\alpha(y, q) = \max\big(\alpha\,(y - q),\ (\alpha - 1)(y - q)\big) = \begin{cases} \alpha\,(y - q) & \text{si } y \ge q, \\ (1 - \alpha)\,(q - y) & \text{si } y < q. \end{cases}$$

En effet, pour une variable Y de fonction de répartition F continue,

$$\mathbb{E}[\rho_\alpha(Y,q)] = \alpha \int_q^{+\infty} (y-q)\,\mathrm{d}F(y) + (1-\alpha)\int_{-\infty}^{q} (q-y)\,\mathrm{d}F(y),$$

dont la dérivée en q vaut $-\alpha\big(1-F(q)\big) + (1-\alpha)\,F(q) = F(q) - \alpha$. Elle s'annule quand $F(q) = \alpha$, et la fonction est convexe : le minimum est atteint au quantile d'ordre α. Une prédiction trop basse coûte α par unité et une prédiction trop haute $1-\alpha$: pour $\alpha = 0{,}95$, être trop bas coûte 19 fois plus qu'être trop haut, et l'on place q assez haut pour que 95 % des observations soient en dessous. Pour $\alpha = 0{,}5$, on retrouve la perte absolue et la médiane.

En minimisant la perte pinball moyenne sur les données au lieu de l'erreur quadratique, un modèle estime un quantile conditionnel $\hat{q}_\alpha(x)$: c'est la *régression quantile* (Koenker et Bassett, 1978). Deux boostings, pour les ordres 0,05 et 0,95, donnent un intervalle de prédiction « brut » à 90 %, dont la largeur s'adapte à x. Rien ne garantit cependant sa couverture : appris sur les données d'apprentissage, ces quantiles ignorent l'erreur d'estimation du modèle lui-même et la différence entre les lieux d'apprentissage et un lieu nouveau.

11.2 La prédiction conforme

La *prédiction conforme* (Vovk et al., 2005) corrige ce défaut en calibrant l'intervalle sur un ensemble séparé de n observations, non utilisées pour l'apprentissage. On calcule sur cet ensemble un *score de non-conformité* s_i, d'autant plus grand que l'observation i est mal prédite, puis le seuil $\hat{q}$, égal à la $\lceil (n+1)(1-\alpha) \rceil$-ième plus petite valeur des scores (et $+\infty$ si cet indice dépasse n). On retient comme intervalle de prédiction l'ensemble des valeurs y dont le score serait inférieur ou égal à $\hat{q}$.

La garantie repose sur une seule hypothèse : les scores des n observations de calibration et celui d'une nouvelle observation sont *échangeables*, c'est-à-dire que leur loi jointe est inchangée quand on les permute. C'est le cas s'ils sont indépendants et de même loi, mais l'hypothèse est plus faible. Sous cette hypothèse, et en l'absence d'égalités, le rang du nouveau score parmi les $n+1$ scores est uniforme sur $\{1,\dots,n+1\}$: le nouveau score est donc inférieur ou égal à la k-ième plus petite valeur de calibration avec une probabilité d'au moins $k/(n+1)$. Avec $k = \lceil (n+1)(1-\alpha) \rceil$, on obtient

$$\mathbb{P}\big(y \in \hat{I}(x)\big) \geq \frac{\lceil (n+1)(1-\alpha) \rceil}{n+1} \geq 1-\alpha. \tag{22}$$

La garantie vaut en échantillon fini, quelle que soit la qualité du modèle et sans aucune hypothèse sur la loi des données : un mauvais modèle donne des intervalles larges, mais toujours bien calibrés. La correction $n+1$ compte, le quantile empirique ordinaire sous-couvrant légèrement, surtout pour un petit ensemble de calibration.

Nous avons comparé deux scores. Le score conforme simple, $s_i = |y_i - \hat{y}(x_i)|$, est l'erreur absolue d'un modèle de la moyenne ; l'intervalle $\hat{y}(x) \pm \hat{q}$ est de largeur constante, aussi large pour un 800 m que pour un marathon. La régression quantile conformalisée (CQR, Romano et al., 2019) part au contraire des quantiles bruts, avec le score $s_i = \max\big(\hat{q}_{\text{bas}}(x_i) - y_i,\ y_i - \hat{q}_{\text{haut}}(x_i)\big)$, qui mesure de combien y_i dépasse l'intervalle brut et qui est négatif si y_i est à l'intérieur. L'intervalle $[\hat{q}_{\text{bas}}(x) - \hat{q}\,;\ \hat{q}_{\text{haut}}(x) + \hat{q}]$ garde la largeur adaptative des quantiles bruts, élargie, ou rétrécie si $\hat{q} < 0$, juste assez pour atteindre la couverture voulue. Dans les deux cas, la garantie est *marginale* : elle porte sur la proportion de performances couvertes en moyenne, et ne garantit pas la couverture *conditionnelle* à un sous-groupe, comme les marathons. Certains groupes peuvent être sur-couverts et d'autres sous-couverts, la moyenne restant correcte.

Nous avons entraîné trois boostings, la moyenne avec contrainte de monotonie et les quantiles d'ordres 0,05 et 0,95, sur quatre plis de lieux, calibré sur le cinquième pli, et évalué sur les lieux de test. Calibrer sur des lieux que le modèle n'a pas vus devait reproduire la situation d'un lieu nouveau. L'échangeabilité n'est cependant qu'approchée : calibration et test portent sur des lieux différents, et les performances d'une même course sont corrélées.

11.3 Une garantie qui ne tient pas, et pourquoi

Sur les lieux de test, les quantiles bruts couvrent 86,8 % des performances, pour une largeur moyenne de 8,13 points. L'intervalle conforme simple ($\hat{q} = 3{,}655$) couvre 83,4 % pour une largeur de 7,31, et la CQR ($\hat{q} = -0{,}211$) 84,2 % pour une largeur de 7,71. Les pertes pinball sur le test valent 0,242 pour le quantile d'ordre 0,05 et 0,355 pour celui d'ordre 0,95. Les intervalles calibrés sous-couvrent donc : ils ne couvrent que 83 à 84 % des performances au lieu des 90 % garantis, et font même moins bien que les quantiles bruts.

La garantie (22) n'est pas fausse : c'est son hypothèse qui n'est pas satisfaite. Le pli de calibration est le pli 0, le plus facile des cinq : le modèle constant y obtenait une RMSE de 2,65, contre 3,19 sur les lieux de test. Ses performances, moins dispersées, donnent des scores plus petits que ceux des lieux de test : les scores de calibration et de test ne sont pas échangeables, le seuil $\hat{q}$ est trop petit et l'intervalle trop étroit. Le signe du seuil de la CQR le montre bien : $\hat{q}$ est négatif, ce qui signifie que, sur le pli de calibration, les quantiles bruts semblaient trop larges, et la CQR les a rétrécis alors qu'ils étaient déjà un peu trop étroits pour les lieux de test. Une garantie conforme ne vaut que si l'ensemble de calibration est représentatif des données sur lesquelles on l'applique. Avec des données groupées par lieux, très hétérogènes d'un lieu à l'autre, un pli de 14 lieux ne suffit pas à représenter la variabilité entre lieux. Deux remèdes sont possibles : calibrer sur plusieurs plis, en utilisant les prédictions hors pli de la validation croisée, ou calibrer par groupe d'épreuves.

La CQR adapte bien la largeur à l'épreuve : 5,0 points en demi-fond, 6,3 en fond sur piste, 8,4 sur route courte, 9,7 au semi-marathon et 10,4 au marathon, ce qui reflète l'hétéroscédasticité observée dès l'exploration. Sa couverture varie pourtant de 79,6 % en demi-fond à 88,6 % au semi-marathon, avec 86,8 % en fond sur piste, 85,1 % sur route courte et 85,8 % au marathon : la garantie, déjà approchée en moyenne, ne vaut pas groupe par groupe.

Ces intervalles de prédiction, d'environ ±4 points, sont bien plus larges que l'intervalle de confiance de la courbe de dégradation, de ±0,4 à ±1 point. Le premier porte sur le chrono d'une performance individuelle et inclut la forme du jour, la tactique et l'ancienneté du record, un bruit d'écart-type proche de 2,8 points qui ne diminue pas avec la taille de l'échantillon ; le second porte sur l'effet moyen des conditions, qui se précise avec les données. Pour régler une allure, c'est Δ et son intervalle de confiance qui comptent : la question est « de combien ralentir pour fournir le même effort », et non « quel chrono vais-je faire ». La borne haute de l'intervalle de confiance donne une allure prudente. L'intervalle de prédiction rappelle, lui, qu'un chrono individuel reste très incertain, quelles que soient les conditions.

12 L'outil : la vitesse à effort égal

12.1 Du modèle à la vitesse équivalente

L'outil reçoit la vitesse Y visée en conditions de référence, les conditions du jour $\mathscr{C}$ (température, humidité, vent à 10 m, rayonnement global, pluie, altitude, ainsi que la date, l'heure et le lieu, qui fixent la position du soleil), l'épreuve et le sexe. Les conditions de référence $\mathscr{C}_{\text{ref}}$ sont un WBGT de 15 °C, un vent de 2 m/s à 10 m, l'absence de pluie et une altitude d'au plus 500 m. Le calcul suit cinq étapes.

Le WBGT du jour est d'abord calculé par le modèle de Liljegren. La pression est déduite de l'altitude z, en mètres, par la formule barométrique de l'atmosphère standard,

$$p(z) = 1013{,}25\left(1 - 2{,}2557 \cdot 10^{-5}\, z\right)^{5{,}2559} \text{ hPa},$$

qui découle de l'équilibre hydrostatique d'une atmosphère dont la température décroît linéairement avec l'altitude : $2{,}2557 \cdot 10^{-5} = L/T_0$, avec un gradient thermique $L = 0{,}0065$ K/m et une température au sol $T_0 = 288{,}15$ K, et $5{,}2559 = g_0 M/(RL)$, où g_0 est l'accélération de la pesanteur, M la masse molaire de l'air et R la constante des gaz parfaits. À 1 000 m, la pression est inférieure de 11 % à celle du niveau de la mer.

On construit ensuite le profil implicite de l'athlète. Sa vitesse Y correspond, sur la distance d, à un temps $t_Y = d/Y$, que l'on traite comme son record : son niveau vaut $100 \ln(t_Y / t^{\text{RP}}_{\text{méd}})$, où $t^{\text{RP}}_{\text{méd}}$ est le record médian du sexe et de l'épreuve, et sa durée attendue vaut $t_Y/60$ minutes.

La dégradation $\Delta = f(\mathscr{C}) - f(\mathscr{C}_{\text{ref}})$ est alors calculée sur un ensemble de performances réelles de la même épreuve et du même sexe, jusqu'à 200 : on leur donne le profil de l'athlète, on impose les conditions $\mathscr{C}$, puis les conditions de référence (WBGT, vent, pluie *et* altitude), et l'on moyenne la différence des prédictions. C'est une moyenne de courbes ICE, qui intègre sur les autres variables (âge, forme, heure) observées pour ce type de course. Les conditions de référence doivent fixer toutes les variables météorologiques : sinon, Δ mélangerait l'effet des conditions du jour et celui des conditions observées dans la population de référence.

La vitesse équivalente est enfin $X = Y\, e^{-\Delta/100}$, d'après (5). Son intervalle de confiance vient des 300 modèles bootstrap : avec $\Delta_{0{,}025}$ et $\Delta_{0{,}975}$ les quantiles des dégradations bootstrap, $X_{\text{bas}} = Y\, e^{-\Delta_{0{,}975}/100}$ et $X_{\text{haut}} = Y\, e^{-\Delta_{0{,}025}/100}$. La fonction $\Delta \mapsto Y e^{-\Delta/100}$ étant décroissante, la borne basse de la vitesse correspond à la borne haute de la dégradation, et les quantiles se transportent sans approximation. L'approximation au premier ordre $X \approx Y(1 - \Delta/100)$ serait d'autant moins bonne que Δ est grand, Δ étant exprimé en pourcents logarithmiques.

La dernière étape est un garde-fou : si le WBGT du jour sort de la plage observée pour le groupe d'épreuves (entre ses centiles 1 et 99), ou si l'altitude dépasse celle observée pour ce groupe, l'outil ne répond pas. Ces plages vont de 16,0 à 25,6 °C en demi-fond, de 13,5 à 25,2 °C en fond sur piste, de 9,8 à 27,4 °C sur route courte, de 5,2 à 21,8 °C au semi-marathon et de 7,3 à 25,1 °C au marathon. Un modèle linéaire prolongerait docilement sa droite au-delà des données ; nous avons préféré un outil qui ne répond pas à un outil qui répond faux.

12.2 L'inversion : de la vitesse courue à la vitesse de référence

Le problème inverse est le suivant : « j'ai couru à la vitesse X dans les conditions $\mathscr{C}$; quelle vitesse cela vaut-il en conditions de référence ? » Il s'agit de trouver la racine Y de

$$r(Y) = Y\, e^{-\Delta(\mathscr{C};\,Y)/100} - X.$$

Comme Δ dépend de Y, par le niveau et la durée attendus de l'athlète, il n'y a pas de formule fermée, et nous résolvons numériquement par la méthode de Brent (1973). On encadre d'abord la racine, $r(0{,}8\,X) < 0 < r(1{,}25\,X)$, puisque la dégradation reste de quelques pourcents. La dichotomie garantit alors la convergence : on coupe l'intervalle en deux et l'on garde la moitié où r change de signe, si bien que la largeur est divisée par deux à chaque itération et qu'une précision de 10^{-7} est atteinte en une trentaine d'itérations. La méthode de Brent combine cette sécurité avec deux méthodes plus rapides, la sécante, qui remplace r par la droite passant par deux points, et l'interpolation quadratique inverse, qui utilise une parabole passant par trois points. Elle utilise la méthode rapide quand celle-ci fait progresser, et se replie sur la dichotomie sinon : la convergence est garantie dès que $r(a)\,r(b) < 0$, et rapide quand r est régulière.

12.3 Quelques exemples

Le calcul du WBGT a d'abord été contrôlé sur deux situations : 20 °C et 50 % d'humidité à l'ombre donnent un WBGT de 15,2 °C, proche de la référence, et 30 °C, 70 % d'humidité et un soleil de 600 W/m² donnent 31,0 °C, au-delà du drapeau noir de l'ACSM. Un marathonien qui court à $Y = 4{,}80$ m/s en conditions de référence (2 h 26 min 30 s), par 22 °C et 60 % d'humidité à l'ombre (WBGT de 18,1 °C), perd $\Delta = +0{,}93$ point : l'outil conseille $X = 4{,}7554$ m/s, avec un intervalle de confiance de 4,7365 à 4,7734 m/s, et l'inversion retrouve exactement la vitesse de départ, $Y = 4{,}80000$ m/s.

Prenons un marathonien de 2 h 30 en conditions de référence. Par temps frais, 15 °C à l'ombre et 70 % d'humidité (WBGT de 12,4 °C, sous la référence), l'outil lui conseille de courir plus vite : 2 h 28 min 49 s (intervalle de 2 h 28 min 17 s à 2 h 29 min 20 s). Par 22 °C, 70 % d'humidité et un soleil de 300 W/m² (WBGT de 21,9 °C), son marathon de référence en vaut 2 h 33 min 10 s, avec un intervalle de 2 h 31 min 47 s à 2 h 34 min 38 s. L'effet est quasiment identique pour une marathonienne de 2 h 50 dans les mêmes conditions (+2,12 %, soit 2 h 53 min 38 s) : le modèle ne distingue pas les sexes dans l'effet de la chaleur. Par 27 °C et 80 % au soleil, le WBGT (27,5 °C) dépasse le centile 99 observé au marathon, et l'outil refuse de répondre. À 1 500 m d'altitude et par 15 °C, le marathon perd environ 1 % (2 h 31 min 35 s), mais l'intervalle, de 2 h 28 min 44 s à 2 h 34 min 35 s, contient la référence : l'effet de l'altitude reste très incertain. Sur 10 km, une coureuse de 35 min en référence en vaut 35 min 31 s par 25 °C, 75 % d'humidité et 300 W/m² (WBGT de 25,2 °C). Sur piste, enfin, même par 28 °C (WBGT de 22,4 °C), l'allure ne change pas : un 1 500 m en 3 min 50 s reste à 3 min 50 s, avec un intervalle qui ne dépasse pas une ou deux secondes de part et d'autre.

12.4 Un abaque température–humidité

Un coureur raisonne en température et en humidité, pas en WBGT. L'abaque traduit l'outil dans ces termes : pour une épreuve, un sexe, une vitesse de référence, un vent et un rayonnement donnés, on calcule le WBGT sur une grille de températures (5 à 40 °C) et d'humidités (10 à 100 %), puis la dégradation Δ dans chaque case. À vent, pluie et altitude fixés, le modèle ne dépend de la météo qu'à travers le WBGT : il suffit donc d'évaluer Δ et ses quantiles bootstrap sur une grille de valeurs de WBGT couvrant la plage du groupe, puis d'interpoler pour chaque case. Chaque situation est représentée par deux panneaux : l'estimation centrale de Δ, et la borne haute de son intervalle de confiance à 95 %, c'est-à-dire le ralentissement le plus fort compatible avec les données, la borne prudente pour fixer une allure (figure 12).

Au marathon, les isolignes de WBGT descendent de gauche à droite : à température égale, l'humidité augmente la charge thermique, et le soleil ajoute à lui seul plusieurs degrés de WBGT par rapport à l'ombre. La dégradation va de −2,3 % pour un WBGT de 8 à 10 °C, où l'on court plus vite qu'en référence, à +3,0 % vers 25 °C ; la borne prudente va de −1,3 à +4,5 %. À

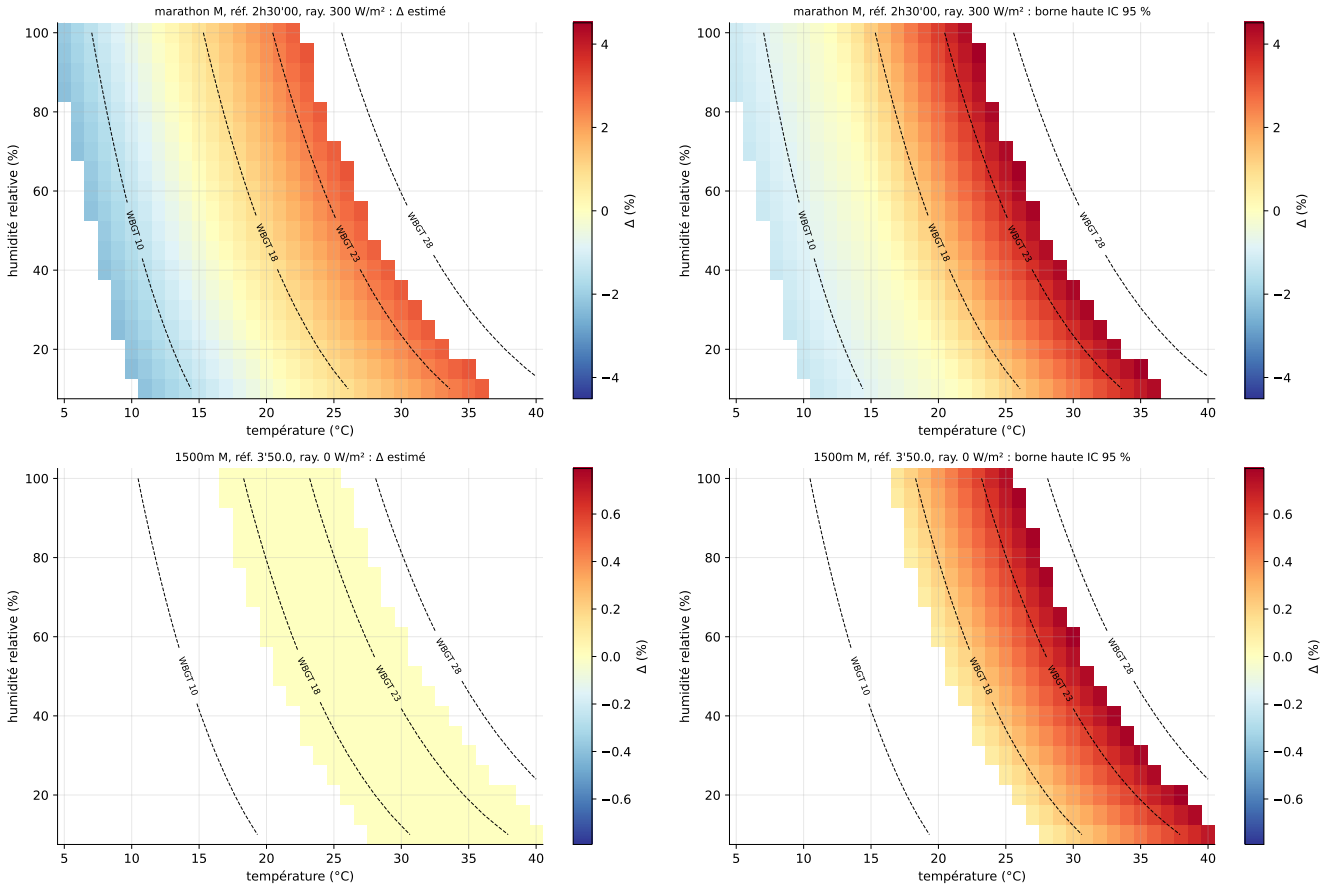


Figure 12 : Abaque de la dégradation Δ selon la température et l'humidité relative, pour un marathon masculin de 2 h 30 en référence, avec un soleil de 300 W/m² (en haut), et un 1 500 m masculin de 3 min 50 s, couru en soirée sans soleil (en bas). À gauche, estimation centrale ; à droite, borne haute de l'intervalle de confiance à 95 %. Les isolignes de WBGT 10, 18, 23 et 28 °C correspondent aux seuils de l'ACSM ; les cases blanches sortent de la plage observée pour le groupe d'épreuves.

22 °C, 70 % d'humidité et au soleil, l'outil conseille 2 h 33 min 10 s, soit environ 3 min 38 s au kilomètre au lieu de 3 min 33 s. Le tableau 4 donne les chronos équivalents pour quelques combinaisons. Au total, 41 % des cases sont blanches, en chaleur humide comme en froid sec : l'outil refuse d'y répondre plutôt que d'extrapoler une droite. Sur 1 500 m, la dégradation est nulle (moins de 0,01 point en valeur absolue) sur toute la plage couverte, de 16 à 25,6 °C, et la borne haute reste sous 0,8 %, moins de deux secondes sur 3 min 50 s. Mais 70 % de la grille est blanche : nos données ne contiennent pas de réunion de piste fraîche, et l'outil ne dit rien d'un 1 500 m par temps frais.

Tableau 4 : Chronos équivalents à un marathon masculin de 2 h 30 en conditions de référence, selon la température et l'humidité relative, avec un soleil de 300 W/m² et un vent de 2 m/s : estimation centrale, puis chrono prudent (borne de l'intervalle de confiance à 95 %). Un tiret signale une combinaison hors de la plage observée.

	10 °C	15 °C	20 °C	25 °C	30 °C
HR 30 %	2 h 27'03 / 2 h 28'20	2 h 28'48 / 2 h 29'20	2 h 30'34 / 2 h 30'51	2 h 32'21 / 2 h 33'30	2 h 34'09 / 2 h 36'11
HR 50 %	2 h 27'40 / 2 h 28'41	2 h 29'34 / 2 h 29'45	2 h 31'30 / 2 h 32'14	2 h 33'27 / 2 h 35'09	–
HR 70 %	2 h 28'14 / 2 h 29'00	2 h 30'16 / 2 h 30'24	2 h 32'20 / 2 h 33'28	2 h 34'27 / 2 h 36'38	–
HR 90 %	2 h 28'46 / 2 h 29'18	2 h 30'55 / 2 h 31'21	2 h 33'06 / 2 h 34'37	–	–

Le conseil d'allure qui en découle est simple. Sur 1 500 m, aucun ajustement n'est justifié. Au marathon, il faut ralentir de 1 à 1,5 % par tranche de 5 °C de WBGT au-dessus de 15 °C, et viser la borne prudente si l'on ne connaît pas sa tolérance à la chaleur. Ces chiffres sont des moyennes pour des coureurs de bon niveau, acclimatés ou non, sans distinction ; la tolérance individuelle, l'acclimatation et l'hydratation peuvent peser beaucoup plus. Au-delà de 23 °C de WBGT, seuil du drapeau rouge de l'ACSM, l'enjeu devient la sécurité plus que le chrono.

13 Discussion

13.1 La troncature, revisitée avec le modèle final

L'exploration avait montré que la troncature des listes atténue la pente brute de la chaleur, et nous avions retenu une marge minimale de 5 % comme compromis. Restait à vérifier que nos conclusions n'en dépendent pas. Nous avons réestimé le modèle de l'outil pour plusieurs marges minimales M, sur les performances valides de marge au moins égale à M, et calculé dans chaque groupe d'épreuves l'effet d'une hausse du WBGT de 15 à 25 °C (tableau 5). Si la troncature atténue l'effet de la chaleur, cet effet doit augmenter avec M.

Tableau 5 : Effet d'une hausse du WBGT de 15 à 25 °C, en points de y, estimé par le modèle de l'outil selon la marge de troncature minimale M exigée.

M	Performances	Demi-fond piste	Fond piste	Route courte	Semi-marathon	Marathon
0 %	14 221	−0,06	0,50	1,08	1,74	3,36
3 %	12 275	0,01	0,53	1,30	1,71	3,23
5 %	10 398	0,04	0,82	1,52	1,78	3,14
8 %	7 637	−0,02	0,79	1,62	1,88	3,16
12 %	4 514	−0,34	1,86	1,72	1,44	3,02

L'effet de la troncature est borné. Au marathon, l'effet reste entre 3,0 et 3,4 points quand M varie de 0 à 12 % : le résultat principal est robuste au choix de la marge. Sur route courte, il passe de 1,1 à 1,7 point quand M augmente, dans le sens d'une atténuation par la troncature. Le demi-fond reste proche de 0 quel que soit M. Les valeurs à $M = 12$ % reposent sur des échantillons réduits de moitié, et le fond sur piste y devient instable. Au marathon, l'effet diminue même légèrement quand M augmente, à l'inverse de la pente brute : une fois les contrôles introduits, la troncature n'y biaise plus l'effet de façon détectable, et ces écarts restent dans la marge d'incertitude des estimations.

13.2 Validité de la cible

La cible $y = 100 \ln(t/t^{\mathrm{RP}})$ suppose un effort maximal et un record représentatif du niveau du jour. Le record peut être ancien : y croît fortement avec l'âge, et l'âge, la forme et le niveau ne corrigent qu'en moyenne. Nos données ne suivent pas les

athlètes, si bien que la comparaison se fait entre coureurs semblables, et non chez un même coureur ; un plan intra-athlète, observant le même coureur dans des conditions différentes, serait plus convaincant. Enfin, les 6 222 performances sans record publié, débutants sur la distance ou données manquantes, ont été exclues : l'échantillon surreprésente les coureurs expérimentés.

13.3 Les biais possibles et leur sens

Plusieurs biais subsistent, et la plupart tirent l'effet estimé vers zéro. L'erreur de mesure de la météo en est le premier. Notre météo vient d'une réanalyse de 9 à 30 km de résolution, sans microclimat (îlot de chaleur urbain, tribunes) ; sur piste, l'heure est celle du début de la réunion et non de la course. Si l'on observe $W^{\text{obs}} = W + \epsilon_W$ au lieu du vrai WBGT W, avec une erreur ϵ_W indépendante de W et de y, alors $\text{Cov}(W^{\text{obs}}, y) = \beta_W \text{Var}(W)$ et $\text{Var}(W^{\text{obs}}) = \text{Var}(W) + \text{Var}(\epsilon_W)$, si bien que la pente estimée tend vers

$$\beta_W \frac{\text{Var}(W)}{\text{Var}(W) + \text{Var}(\epsilon_W)} < \beta_W.$$

C'est le *biais d'atténuation* : une erreur de mesure aléatoire tire toujours l'effet vers zéro, et d'autant plus que la variation utile du WBGT est faible, ce qui est le cas de la variation intra-parcours. La sélection sous-estime aussi l'effet : par forte chaleur, les abandons ne sont pas listés, et certains coureurs renoncent ou gèrent leur course. L'effet est alors sous-estimé pour le chrono maximal, mais c'est en partie ce qu'un coureur veut savoir : de combien ralentir pour finir.

La confusion entre lieux reste possible. La chaleur est surtout observée entre lieux, avec un écart-type intra-parcours d'environ 1 °C seulement, et le pays, le plateau et le profil des parcours ne sont contrôlés qu'imparfaitement, même si les effets fixes et le terme de Mundlak concordent avec les effets aléatoires. L'hétéroscédasticité, ensuite, n'est que contournée : l'écart-type intra-course de y double entre la piste et le marathon, et le modèle mixte à σ^2 commun a une vraisemblance bimodale, contournée en fixant γ mais pas corrigée. Les intervalles de prédiction, enfin, dépendent de l'échangeabilité, et un pli de calibration non représentatif leur fait perdre la couverture garantie.

13.4 Généralisation et pistes d'amélioration

Nos données couvrent des coureurs de bon niveau, un WBGT de 5 à 28 °C, la piste uniquement entre 13,5 et 26 °C en soirée, et l'altitude uniquement sur route. Rien ne permet d'extrapoler aux coureurs populaires, plus touchés selon Ely et al. (2007), aux canicules, aux championnats sous climat tropical ou au demi-fond par temps froid. Pour l'entraînement à allure sous-maximale, « même effort » renvoie plutôt à la fréquence cardiaque ou à la perception de l'effort, et l'outil ne s'y transpose pas directement.

Plusieurs pistes permettraient d'aller plus loin. Des listes de résultats complètes, abandons compris, supprimeraient la troncature, et des identifiants d'athlètes autoriseraient un plan intra-athlète. Les heures réelles de départ, des stations météorologiques proches et le profil des parcours réduiraient l'erreur de mesure et la confusion entre lieux. Sur le plan statistique, un modèle mixte hétéroscédastique, avec un σ^2 propre à chaque groupe d'épreuves, traiterait la bimodalité à sa source ; des effets aléatoires croisés athlète × course, ou un modèle bayésien hiérarchique qui rétrécirait l'effet de la chaleur d'un groupe d'épreuves vers celui des autres, permettraient d'estimer une courbure commune. Une calibration conforme sur plusieurs plis, ou par groupe d'épreuves, rétablirait la couverture des intervalles de prédiction. Un modèle conjoint de l'abandon et de la performance traiterait la sélection, et des données de fréquence cardiaque permettraient de transposer l'outil à l'entraînement.

14 Conclusion

À effort égal, quand le WBGT passe de 15 à 25 °C, la chaleur ne coûte rien de mesurable sur 800 m et 1 500 m, environ 1,5 % sur 5 et 10 km et environ 3 % au marathon. Le vent coûte environ 0,2 % par m/s à WBGT égal, et l'altitude pèse sur route, avec une grande incertitude. En prédiction, les quatre familles de modèles se valent, et environ un sixième de la variance des performances est prévisible sur un lieu nouveau ; le reste relève de la forme du jour.

Le chemin pour y parvenir a sans doute autant d'intérêt que le résultat. Chaque difficulté rencontrée a appelé un outil précis : la troncature des listes, la loi normale tronquée et une marge minimale ; les facteurs confondants, des contrôles, des interactions et la décomposition de Mundlak ; la dépendance entre coureurs d'une même course, la validation croisée par lieux, les moindres carrés généralisés et le bootstrap des lieux ; le désaccord entre des modèles de précision égale, un

modèle interprétable choisi sur des critères physiologiques ; la bimodalité de la vraisemblance, une covariance de travail ; la sous-couverture des intervalles conformes, l'examen de l'hypothèse d'échangeabilité. Quatre leçons méthodologiques s'en dégagent : valider par groupes quand les données sont structurées ; estimer l'incertitude par un bootstrap des mêmes groupes ; distinguer prédire et estimer un effet ; et préférer un outil qui donne un intervalle honnête et refuse d'extrapoler.

Références

Aitken A. C. (1935). On least squares and linear combination of observations. *Proceedings of the Royal Society of Edinburgh* 55, 42–48.

Armstrong L. E. et al. (2007). American College of Sports Medicine position stand. Exertional heat illness during training and competition. *Medicine & Science in Sports & Exercise* 39(3), 556–572.

Bergstra J., Bengio Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research* 13, 281–305.

Breiman L., Friedman J., Olshen R., Stone C. (1984). *Classification and Regression Trees*. Wadsworth.

Brent R. P. (1973). *Algorithms for Minimization without Derivatives*. Prentice-Hall.

Chen T., Guestrin C. (2016). XGBoost : a scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

Cybenko G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems* 2(4), 303–314.

Efron B. (1979). Bootstrap methods : another look at the jackknife. *The Annals of Statistics* 7(1), 1–26.

Ely M. R., Cheuvront S. N., Roberts W. O., Montain S. J. (2007). Impact of weather on marathon-running performance. *Medicine & Science in Sports & Exercise* 39(3), 487–493.

Friedman J. H. (2001). Greedy function approximation : a gradient boosting machine. *The Annals of Statistics* 29(5), 1189–1232.

Goldstein A., Kapelner A., Bleich J., Pitkin E. (2015). Peeking inside the black box : visualizing statistical learning with plots of individual conditional expectation. *Journal of Computational and Graphical Statistics* 24(1), 44–65.

Grinsztajn L., Oyallon E., Varoquaux G. (2022). Why do tree-based models still outperform deep learning on typical tabular data ? *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*.

Hastie T., Tibshirani R., Friedman J. (2009). *The Elements of Statistical Learning*, 2e édition. Springer.

Hersbach H. et al. (2020). The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society* 146, 1999–2049.

Hornik K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks* 4(2), 251–257.

Ke G., Meng Q., Finley T., Wang T., Chen W., Ma W., Ye Q., Liu T.-Y. (2017). LightGBM : a highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems* 30.

Kingma D. P., Ba J. (2015). Adam : a method for stochastic optimization. *International Conference on Learning Representations*.

Kish L. (1965). *Survey Sampling*. Wiley.

Koenker R., Bassett G. (1978). Regression quantiles. *Econometrica* 46(1), 33–50.

Leshno M., Lin V. Y., Pinkus A., Schocken S. (1993). Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. *Neural Networks* 6(6), 861–867.

Liang K.-Y., Zeger S. L. (1986). Longitudinal data analysis using generalized linear models. *Biometrika* 73(1), 13–22.

Liljegren J. C., Carhart R. A., Lawday P., Tschopp S., Sharp R. (2008). Modeling the wet bulb globe temperature using standard meteorological measurements. *Journal of Occupational and Environmental Hygiene* 5(10), 645–655.

Lorenzo S., Halliwill J. R., Sawka M. N., Minson C. T. (2010). Heat acclimation improves exercise performance. *Journal of Applied Physiology* 109(4), 1140–1147.

Loshchilov I., Hutter F. (2019). Decoupled weight decay regularization. *International Conference on Learning Representations*.

Lundberg S. M., Lee S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems* 30.

Lundberg S. M., Erion G., Chen H., DeGrave A., Prutkin J. M., Nair B., Katz R., Himmelfarb J., Bansal N., Lee S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence* 2(1), 56–67.

Mantzios K. et al. (2022). Effects of weather parameters on endurance running performance : discipline-specific analysis of 1258 races. *Medicine & Science in Sports & Exercise* 54(1), 153–161.

Mundlak Y. (1978). On the pooling of time series and cross section data. *Econometrica* 46(1), 69–85.

Patterson H. D., Thompson R. (1971). Recovery of inter-block information when block sizes are unequal. *Biometrika* 58(3), 545–554.

Racinais S. et al. (2015). Consensus recommendations on training and competing in the heat. *British Journal of Sports Medicine* 49(18), 1164–1173.

Romano Y., Patterson E., Candès E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems* 32.

Rønnestad B. R. et al. (2022). Heat suit training increases hemoglobin mass in elite cross-country skiers. *Scandinavian Journal of Medicine & Science in Sports* 32(7), 1089–1098.

Shapley L. S. (1953). A value for n-person games. In *Contributions to the Theory of Games*, vol. II, 307–317. Princeton University Press.

Srivastava N., Hinton G., Krizhevsky A., Sutskever I., Salakhutdinov R. (2014). Dropout : a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research* 15, 1929–1958.

Telgarsky M. (2016). Benefits of depth in neural networks. *Conference on Learning Theory*, 1517–1539.

Vovk V., Gammerman A., Shafer G. (2005). *Algorithmic Learning in a Random World*. Springer.

Zippenfenig P. (2023). Open-Meteo.com Weather API. Zenodo, doi:10.5281/zenodo.7970649.